IncEventGS: Pose-Free Gaussian Splatting from a Single Event Camera

Jian Huang[1,2] Chengrui Dong[1,2] Xuanhua Chen[2,3] Peidong Liu[2*]

[1]Zhejiang University [2]Westlake University [3]Northeastern University

{huangjian39, dongchengrui, chenxuanhua, liupeidong}@westlake.edu.cn

https://github.com/WU-CVGL/IncEventGS

README

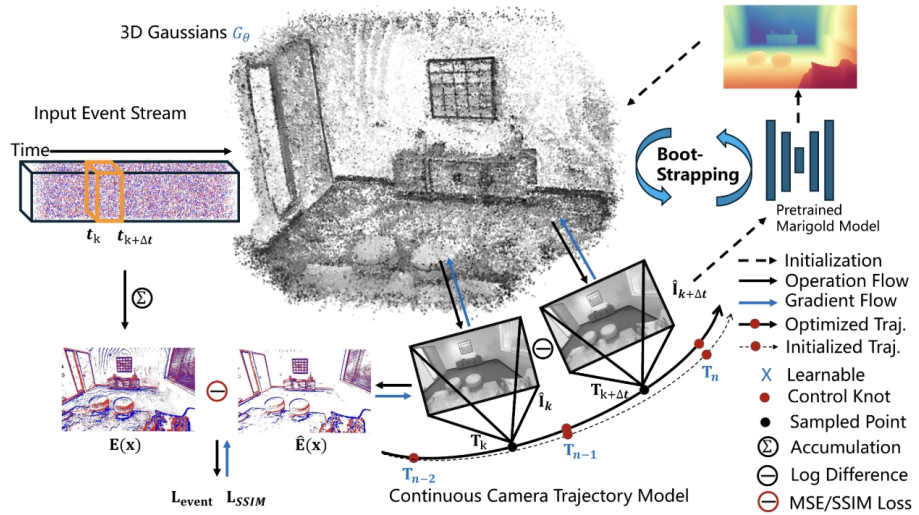
News

2025.04.04 🔥Our paper has been selected as **CVPR 2025 Highlight**!

2025.03.03 🔥Our paper has been accepted by CVPR 2025!

2024.10.11 Our paper is available on arXiv.

Overview



CVPR Highlight 2025



分享者：李铭豪，陈倩琦，梁意睿

IncEventGS: Pose-Free Gaussian Splatting from a Single Event Camera

背景:

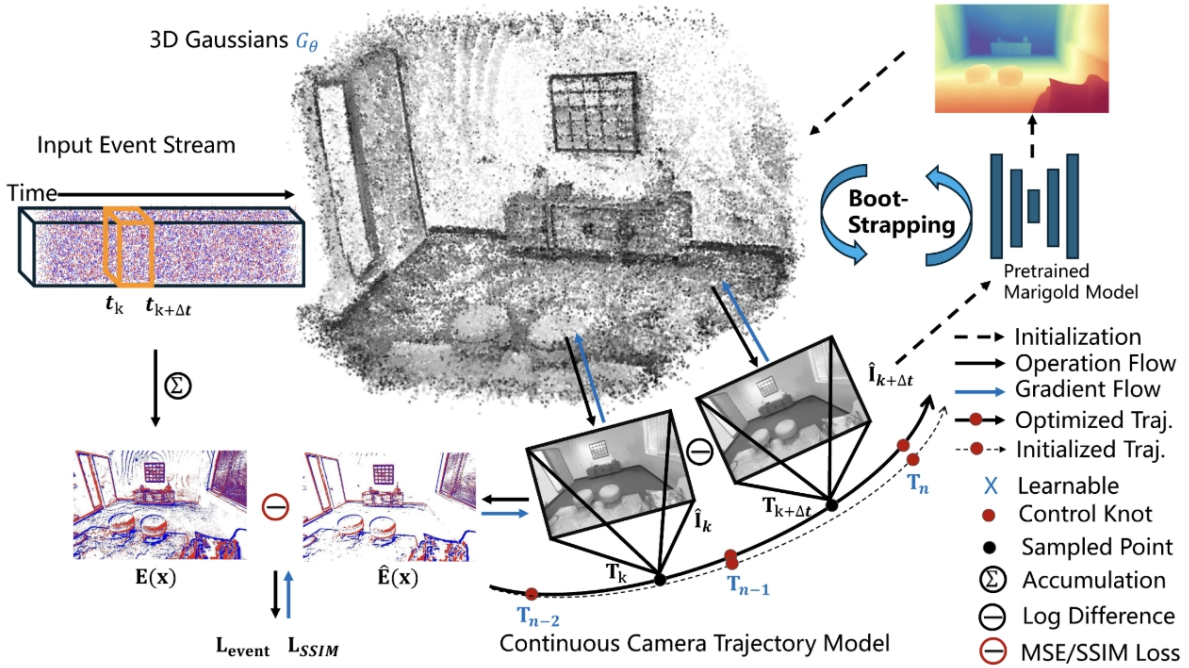
针对传统 RGB 相机高速运动场景会失败的问题

- 运动模糊、低时间分辨率、HDR 差，强光和暗光场景容易失效

核心目标:

仅利用单个视角的事件相机，实现无位姿（pose-free）的 3DGs 重建

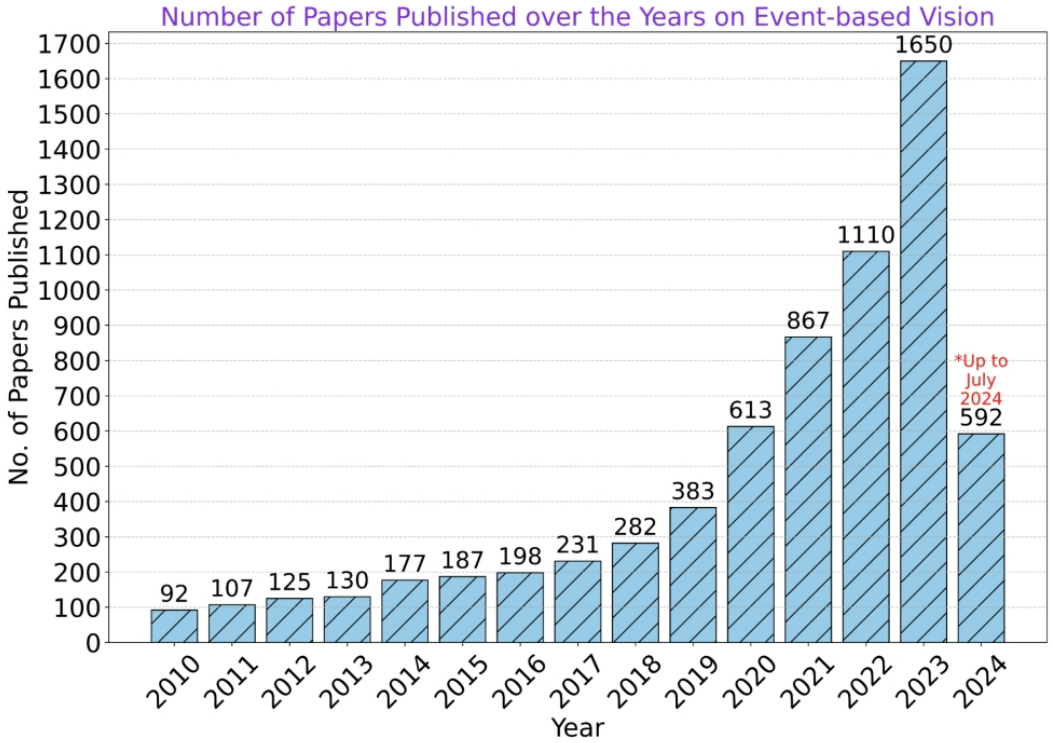
- 相机位姿估计（Pose Estimation）
- 相机运动轨迹图
- 3D场景重建



CVPR Highlight 2025

事件相机

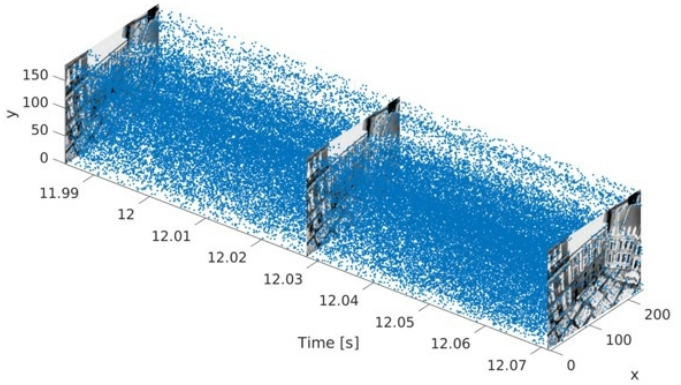
核心出装：事件相机



https://arxiv.org/html/2408.13627v1

https://www.google.com/imgres?q=event%20camera%20dataset





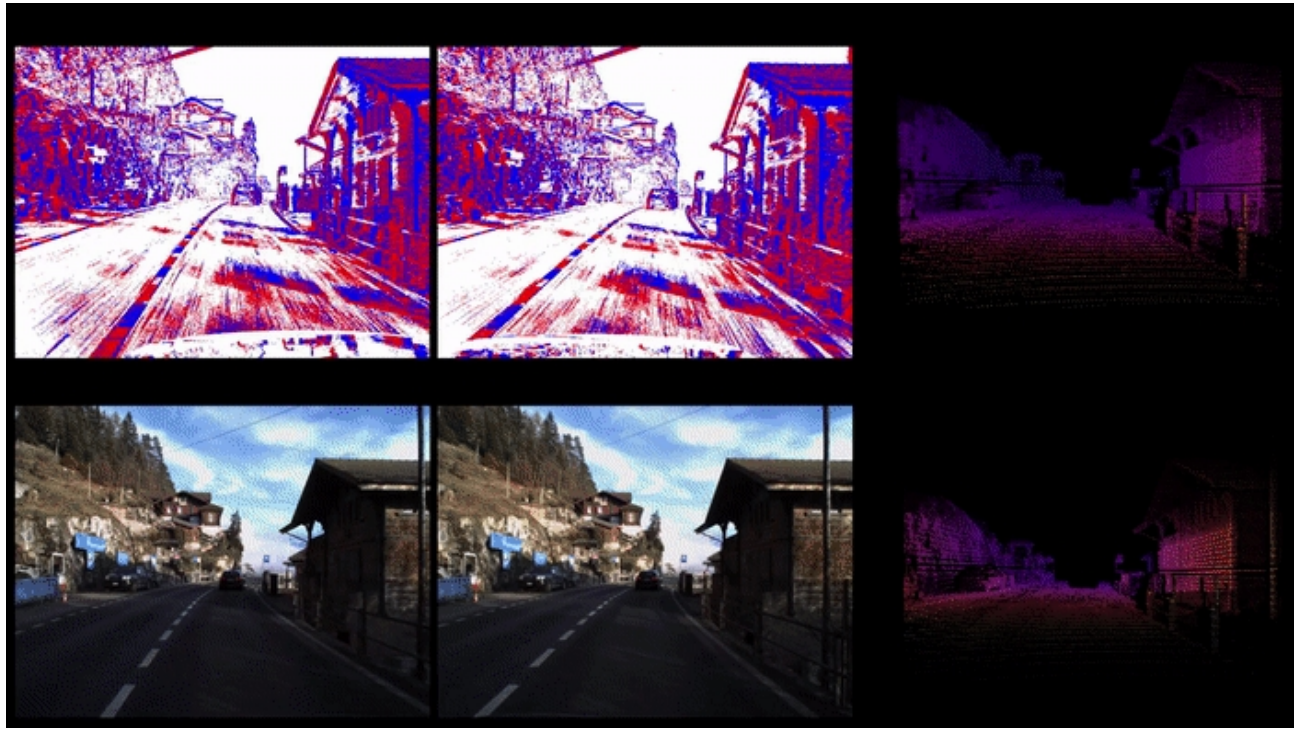


Fig1. 事件相机数据可视化

事件相机

核心出装：事件相机

工作机理：只有当像素亮度发生变化时（并且达到某一个设定的阈值），才会主动输出事件（event）

$$\Delta log\ I(x,y,t) > C$$

输出形式：

$$e_i = (x_i, y_i, t_i, p_i)$$

参数	含义
x_i, y_i	像素位置
t_i	时间戳（微秒级）
p_i	极性 polarity

https://arxiv.org/html/2408.13627v1

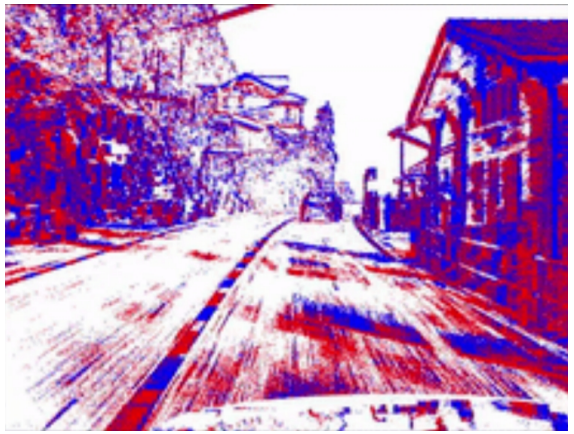
普通相机

每隔固定时间拍一张完整图片 I (x,y)
帧率：30 FPS ｜ 60 FPS ｜ 120 FPS；
问题：运动模糊高延迟





事件相机



预训练深度模型

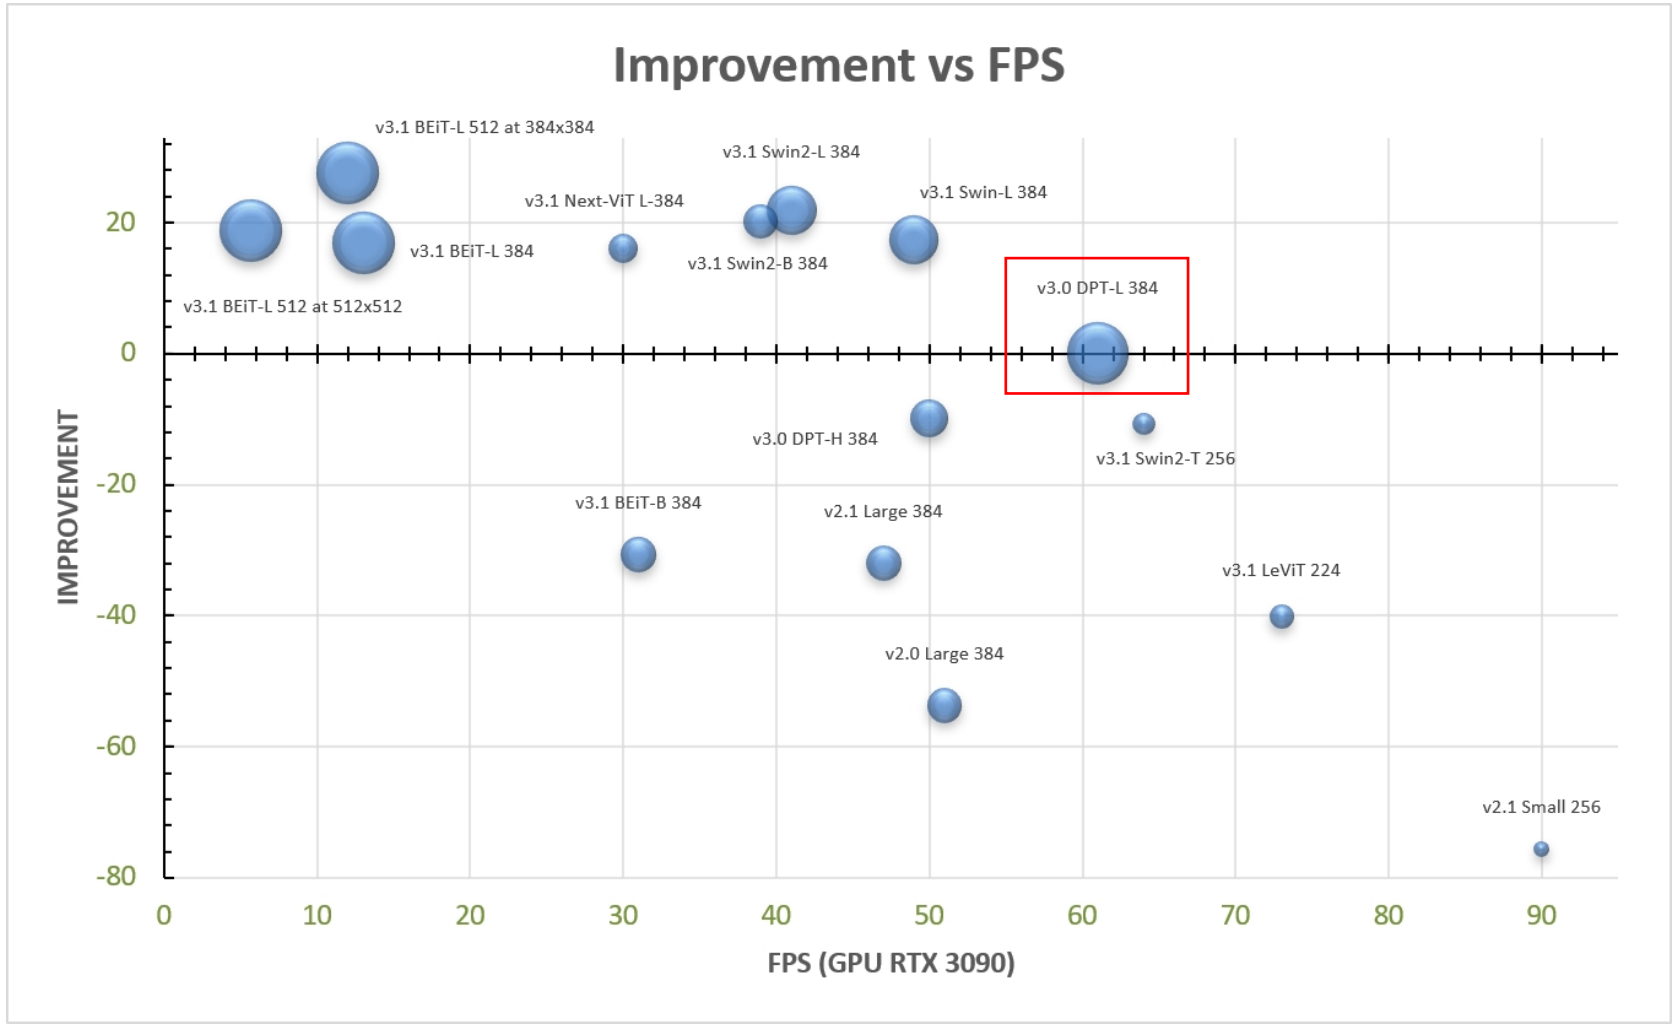
（Pre-trained Monocular Depth Estimation Model）单目深度估计模型 Model Zoo

输入：Image I(x,y)

输出：Depth Map D(x,y)

现代通常是 DPT + Backbone





https://pytorch.org/hub/intelisl_midas_v2/

3DGs

两大阶段：

- 初始化3D 高斯
- 投影与可微渲染

使用SFM（COLMAP 工具），生成初始化的表示3D场景结构的稀疏点云，3D高斯体是一个具有透明度实心椭球：

其中包含四大属性：

- 位置（mean） （x, y, z）
- 朝向和形状的各向异性的协方差 ∑
  - *对角 & 非对角之分*
- 高斯椭球各个视角颜色 c
  - SH：一个函数让不同视角看到的色彩不同
- 不透明度 α

$$\Sigma = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$ 正常球形 (r=1)

$$\Sigma = \begin{bmatrix} 9 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$ 拉长椭球

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{3/2}|\mathbf{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^\top \mathbf{\Sigma}^{-1}(\mathbf{x}-\mu)\right)$$

https://zhuanlan.zhihu.com/p/679809915

https://research.nvidia.com/labs/toronto-ai/3DGUT

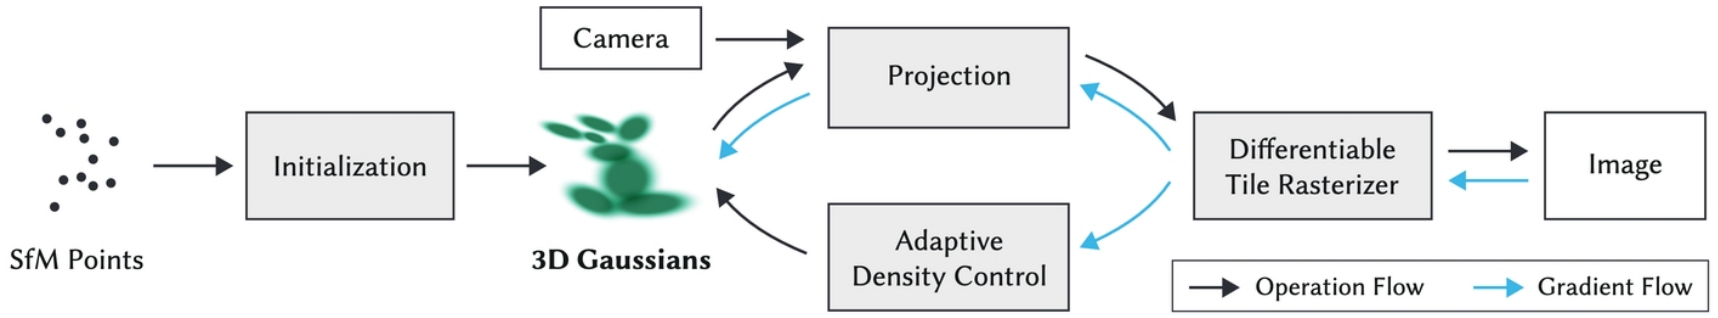


Fig. 2. Optimization starts with the sparse SfM point cloud and creates a set of 3D Gaussians. We then optimize and adaptively control the density of this set of Gaussians. During optimization we use our fast tile-based renderer, allowing competitive training times compared to SOTA fast radiance field methods. Once trained, our renderer allows real-time navigation for a wide variety of scenes.

3DGs

两大阶段：

- 初始化3D 高斯
- 投影与可微渲染

对于给定的视角 d，将3D高斯椭球体投影(projection)到2D高斯椭圆

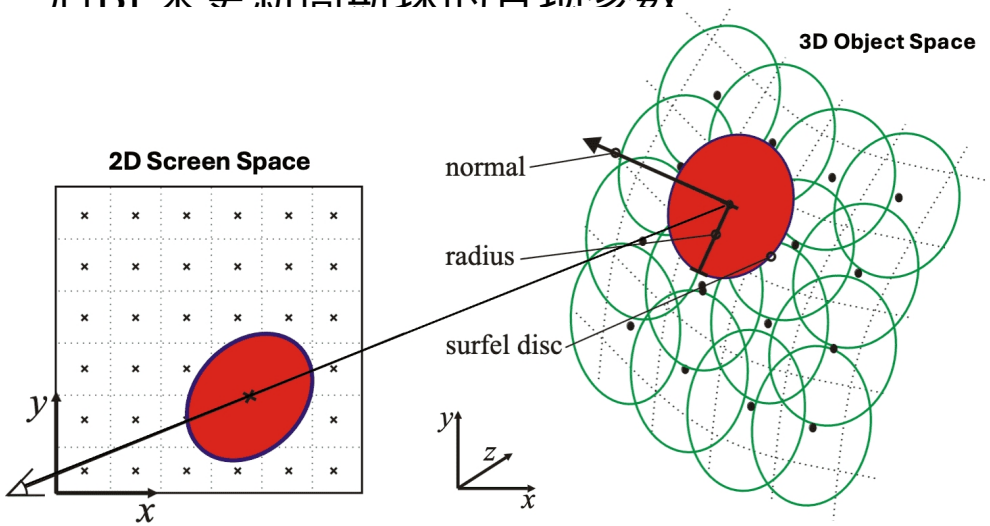
首先，将屏幕 (scree) 或图像分成 $n \times n$ 分块 （blocks）

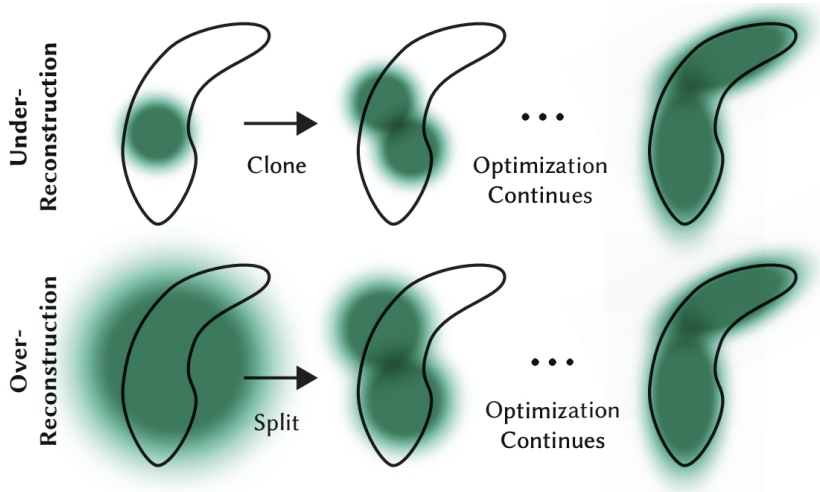
【修正阶段】针对视锥体和每个分块，执行高斯体剔除操作 (剪枝)，剔除远离视锥的高斯体 or 冗余的高斯体，将每个高斯体分配到对应的分块，并根据距离相机远近（高斯体深度）对高斯体进行排序；

$$G = (e_i, e_{i+1}, e_{i+2} \dots e_{i+n})$$

对于每个像素，利用排序后的高斯列表，按照从前到后的顺序累计颜色和透明度，当像素的透明度值 α 达到目标饱和度阈值时，停止渲染

【优化阶段】将渲染出来的图像与真实图像进行对比，计算 L_1 损失和 SSIM 损失, 然后BP来更新高斯球的各项参数



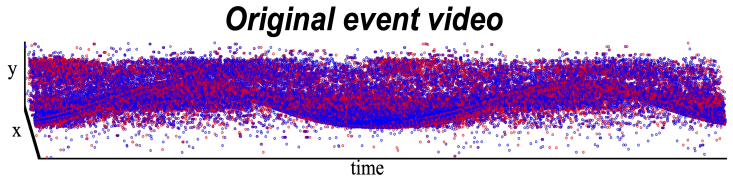


https://zhuanlan.zhihu.com/p/679809915

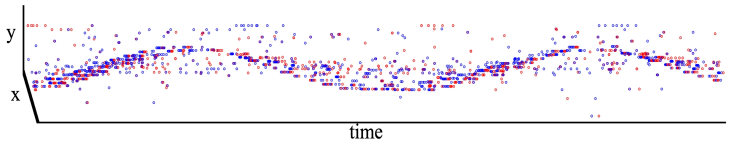
https://research.nvidia.com/labs/toronto-ai/3DGUT

https://leeyngdo.github.io/blog/computer-graphics/2024-04-09-gaussian-splatting/

Six Hardware-friendly Event Subsampling Methods

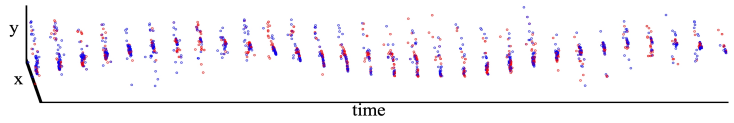


Spatial:



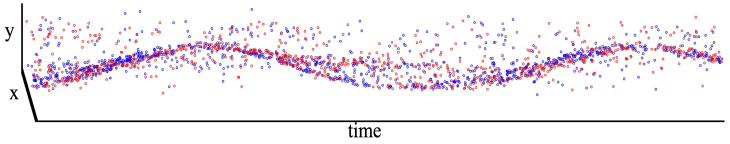
只保留固定行和列上的事件

Temporal:



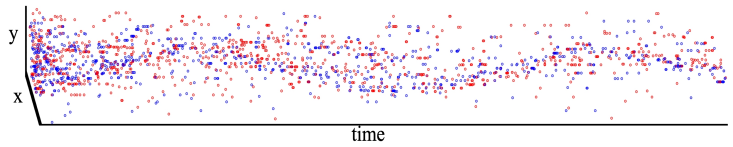
只保留固定时间窗口内的一部分事件

Random:



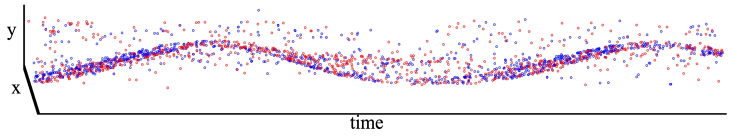
每个事件按概率保留

Event Count:



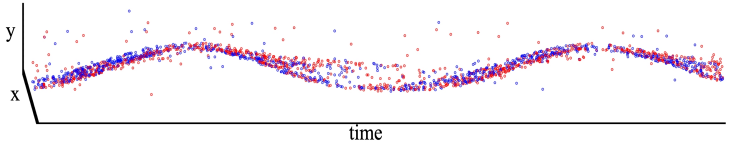
把空间窗口内的事件聚合起来，超过阈值才在下采样输出中触发事件

Corner-based:



只保留角点事件

Causal Density-based:



优先保留局部时空密度高的事件

连续事件片段选择策略

Fixed Time Window Sampling 固定时间窗口采样：

0–50ms → chunk 1
50–100ms → chunk 2
100–150ms → chunk 3

Fixed Event Number Window Sampling 固定事件数量窗口采样：

第 1–50,000 个 events → window 1
第 50,001–100,000 个 events → window 2
第 100,001–150,000 个 events → window 3

Sliding Window Sampling 滑动窗口采样：

0–50ms → window 1
10–60ms → window 2
20–70ms → window 3

Random Temporal Crop 随机时间裁剪：

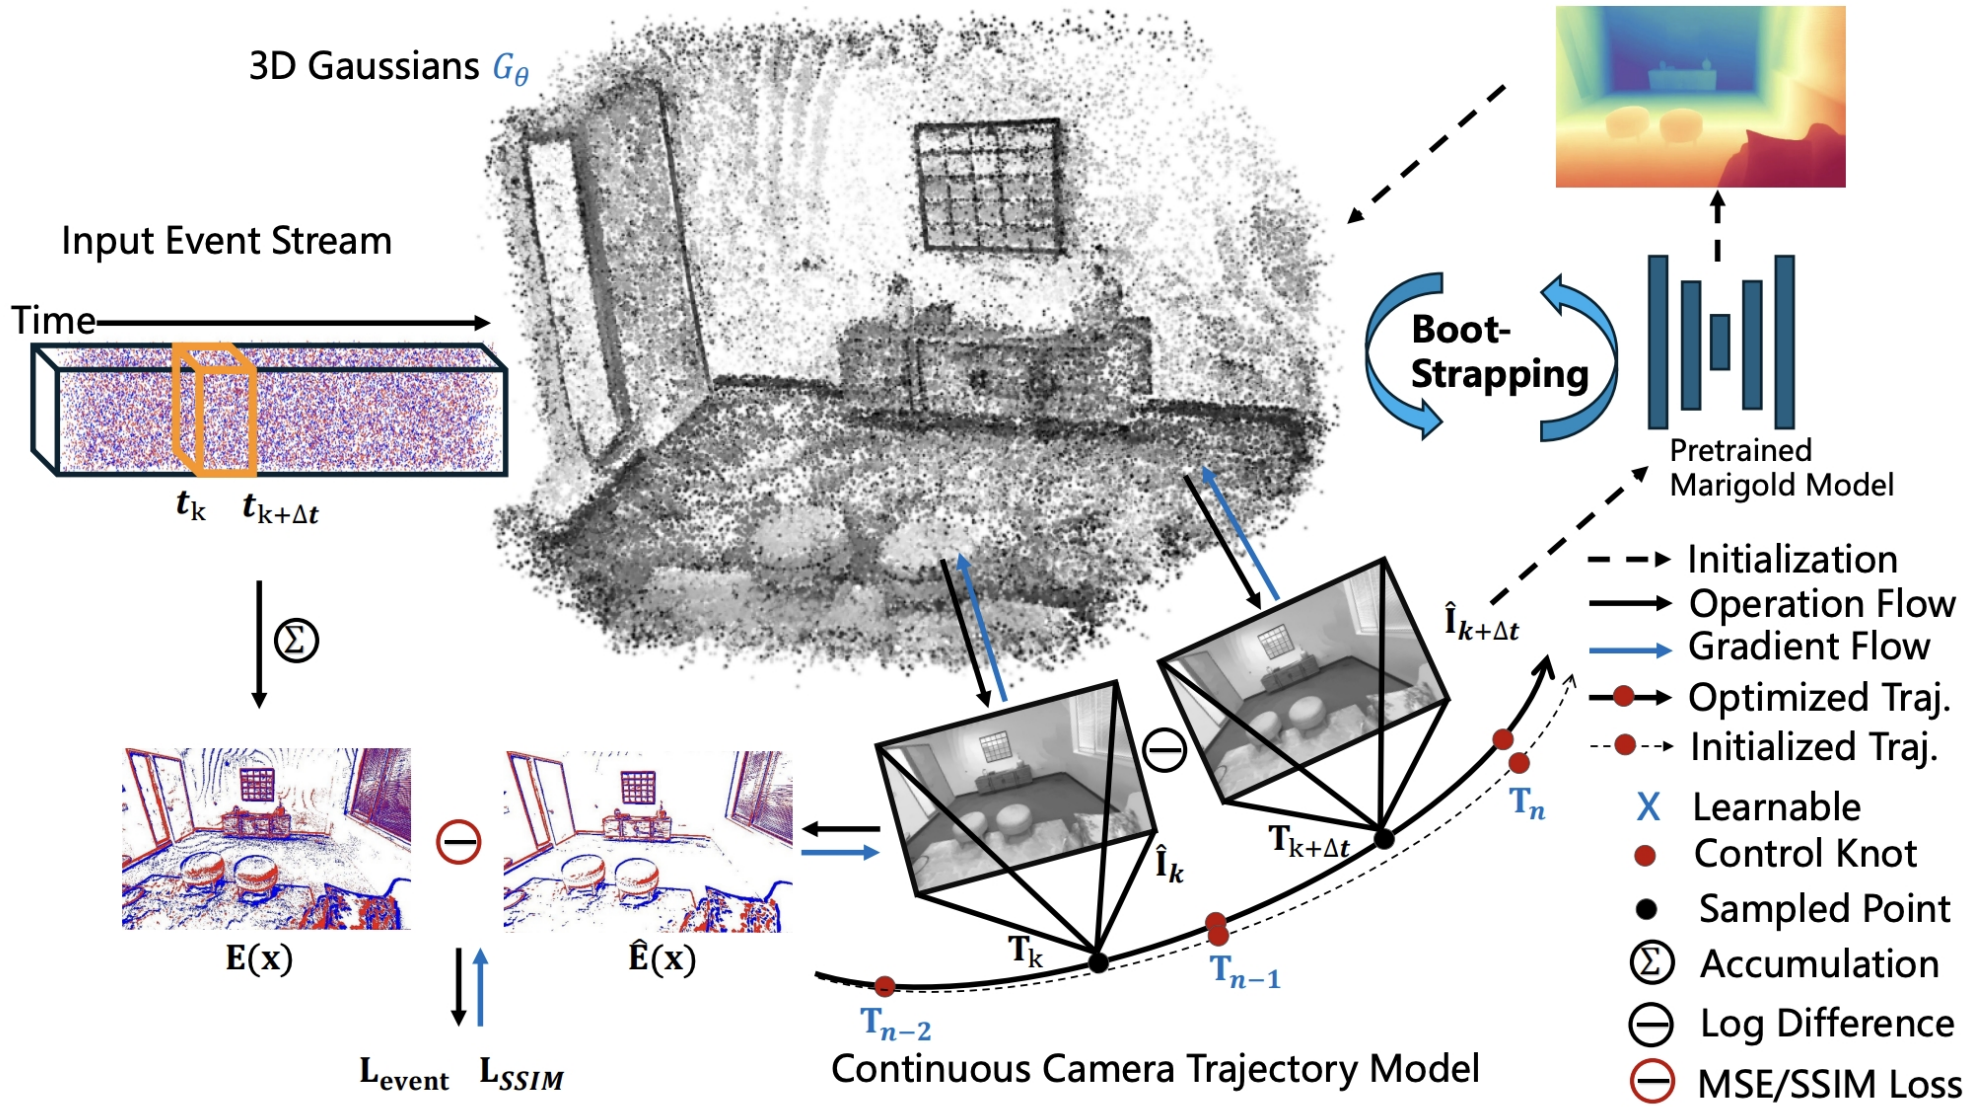
第 1 次训练：随机取 120–220ms
第 2 次训练：随机取 350–450ms
第 3 次训练：随机取 700–800ms

IncEventGS 使用的是一种基于事件数量约束的随机时间窗口采样方法。它不是按固定时间直接采样，也不是从所有事件里随机挑选单个事件，而是在一个事件片段内，先根据事件数量划分候选时间点，再随机选择一个结束时间和一个事件窗口长度，最后得到一段连续的事件时间窗口。

Setting	PSNR↑	SSIM↑	LPIPS↓	ATE
1k-10k	16.07	0.64	0.46	0.167
10k-50k	18.41	0.72	0.33	0.079
80k-200k	20.99	0.79	0.25	0.079
400k-500k	**21.74**	**0.82**	**0.23**	**0.046**
500k-600k	20.95	0.79	0.23	0.050
600k-700k	18.06	0.75	0.28	0.214

Table 4. Ablation Study on Event Slice Window Size (Hyperparameters n_{low} and n_{up}). The unit of ATE is cm.

Farmework


3D Gaussians G_θ
Input Event Stream
Time
t_k $t_{k+\Delta t}$
Σ
E(x)
Ê(x)
L_{event} L_{SSIM}
Boot-Strapping
Pretrained Marigold Model
$\hat{I}_{k+\Delta t}$
$\hat{I}_k$
T_k
$T_{k+\Delta t}$
T_{n-2}
T_{n-1}
T_n
Continuous Camera Trajectory Model
Initialization
Operation Flow
Gradient Flow
Optimized Traj.
Initialized Traj.
Learnable
Control Knot
Sampled Point
Accumulation
Log Difference
MSE/SSIM Loss

第一阶段： Initialization

一、完全随机初始化

3D Gaussian 初始化 → 在 bounding box 内随机采样
相机位姿初始化 → 前 m=3 个事件块的相机位姿初始化为接近单位矩阵

二、初始化（前3个事件块）

1. t_k到 $t_k+\Delta t$两个时间点之间的事件累积成真实事件流亮度变化:

①真实事件流累积的亮度变化:

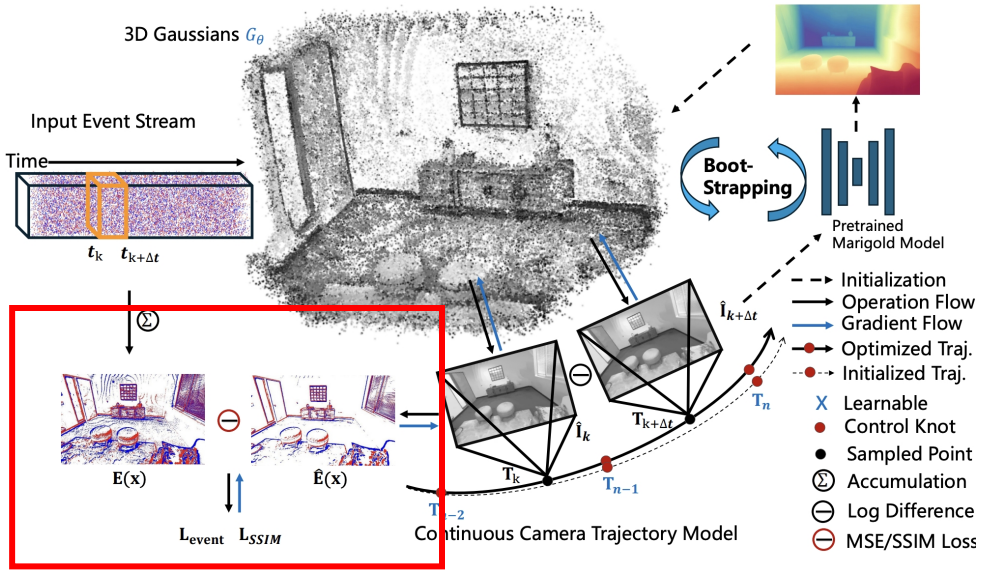
$$\mathbf{E}(\mathbf{x}) = C\{e_i(\mathbf{x}, t_i, p_i)\}_{t_k < t_i < t_k + \Delta t},$$

- $e_i(x, t_i, p_i)$ 表示 event camera 输出的单个事件;
- x 为像素位置;
- t_i 为事件时间戳;
- p_i 为 polarity;
- C 为 contrast threshold。

IncEvnet

第一阶段： Initialization

二、初始化（前3个事件块）



2. 利用连续相机轨迹模型对相机位姿进行建模：

$$\mathbf{T}_k = \mathbf{T}_{\text{start}} \cdot \exp\left(\frac{t_k - t_{start}}{t_{end} - t_{start}} \cdot \log(\mathbf{T}_{\text{start}}^{-1} \cdot \mathbf{T}_{\text{end}})\right)$$

（线性插值）

3. 得到对应位姿T_k和$T_{k+\Delta t}$后，从当前 3DGS场景中渲染两张亮度图像，随后就能够得到合成图片亮度变化，然后联合优化=3DGS和相机轨迹参数：

$$\hat{\mathbf{E}}(\mathbf{x}) = \log(\hat{\mathbf{I}}_{k+\Delta t}(\mathbf{x})) - \log(\hat{\mathbf{I}}_k(\mathbf{x})),$$

$$\mathbf{E}(\mathbf{x}) = C\{e_i(\mathbf{x}, t_i, p_i)\}_{t_k < t_i < t_k + \Delta t},$$

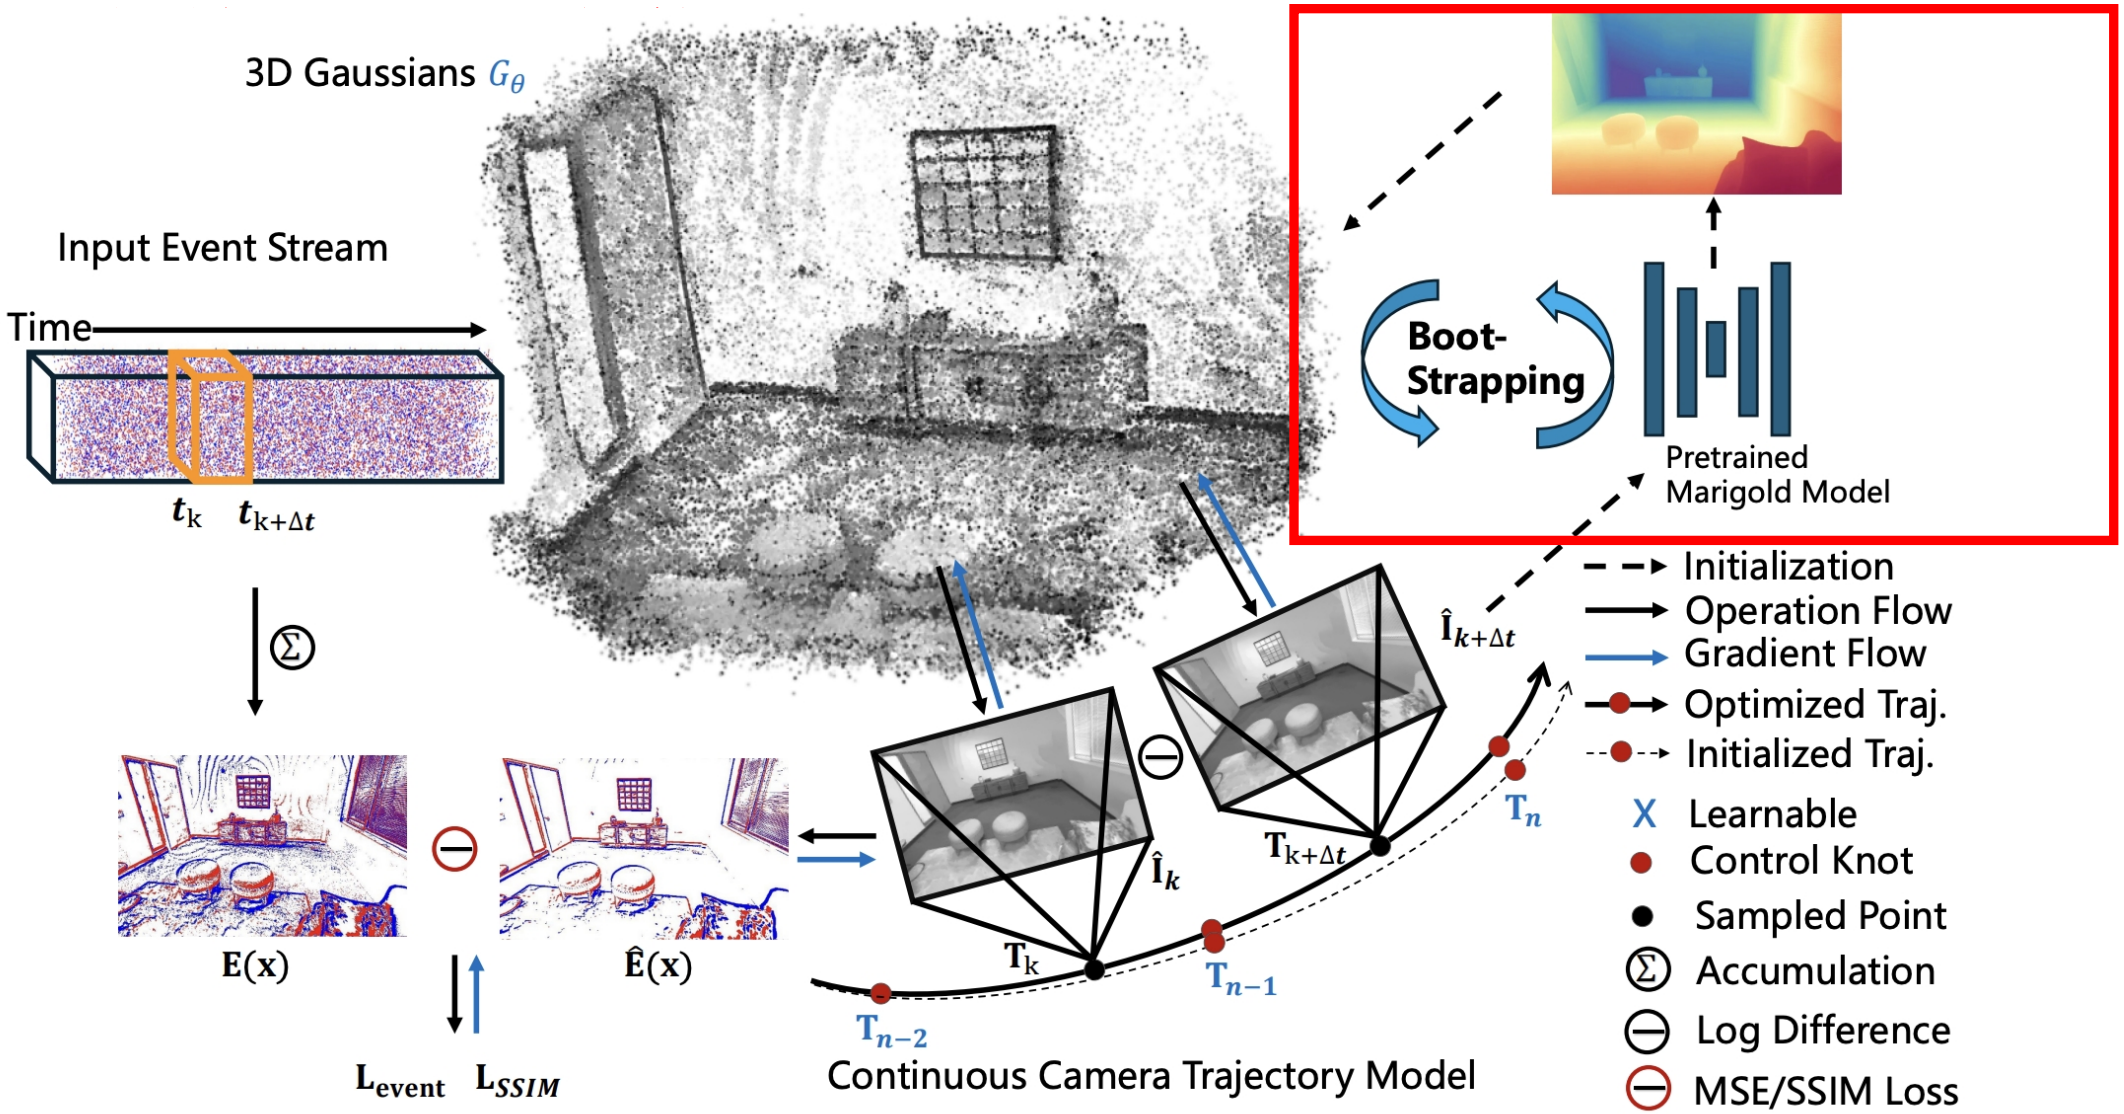
$$\mathcal{L} = (1-\lambda)\mathcal{L}_{event} + \lambda\mathcal{L}_{ssim},$$

$$\mathcal{L}_{event} = \left\|\mathbf{E}_i(\mathbf{x}) - \hat{\mathbf{E}}_i(\mathbf{x})\right\|_2,$$

$$\mathcal{L}_{ssim} = SSIM(\mathbf{E}_i(\mathbf{x}), \hat{\mathbf{E}}_i(\mathbf{x})),$$

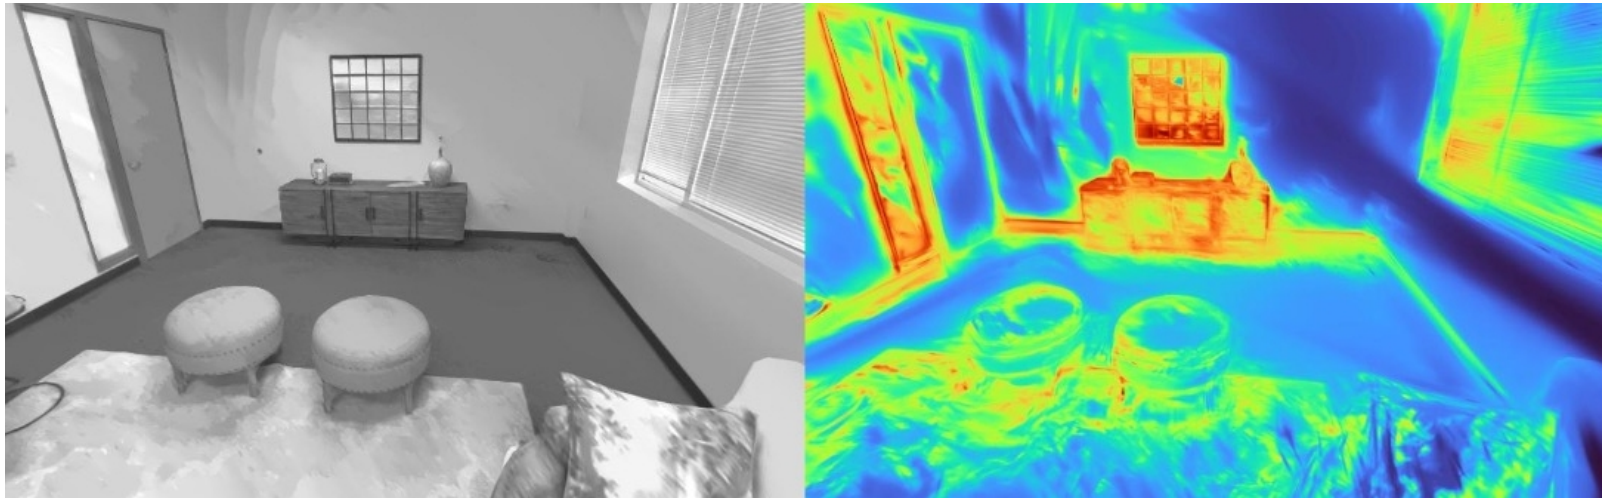
进行一轮（4500次迭代）后，已经能够大致恢复亮度变化

第一阶段： Initialization

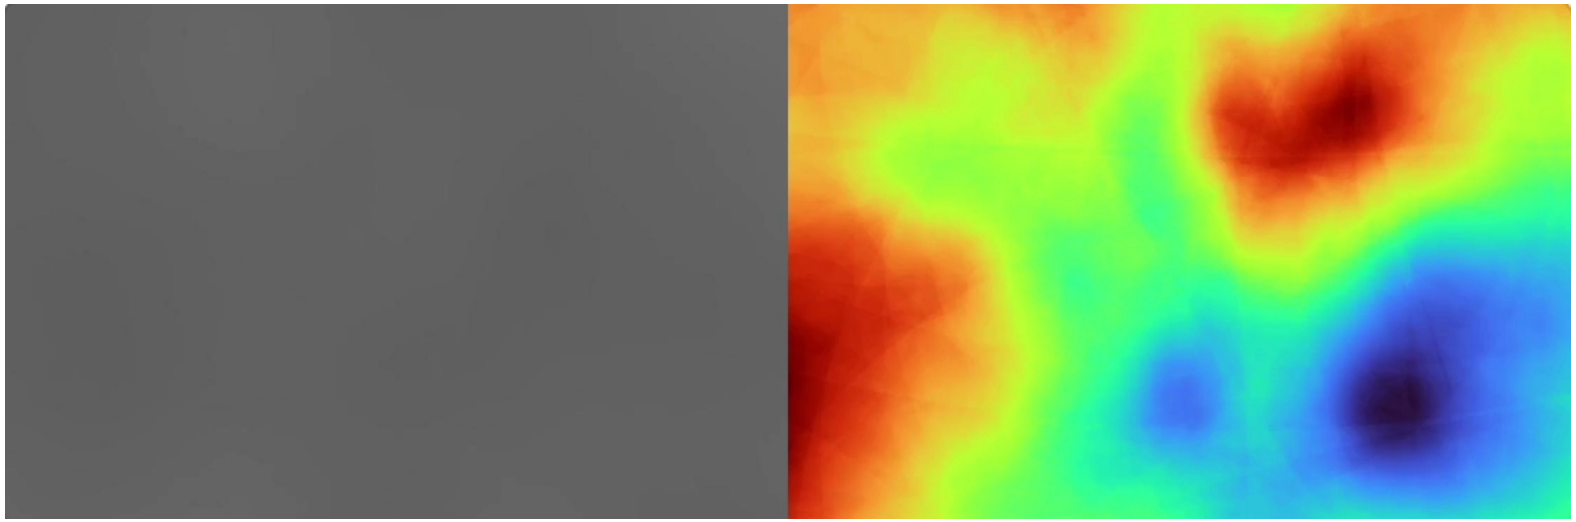


initialization 阶段图 （前面轮次 v.s 后面轮次）

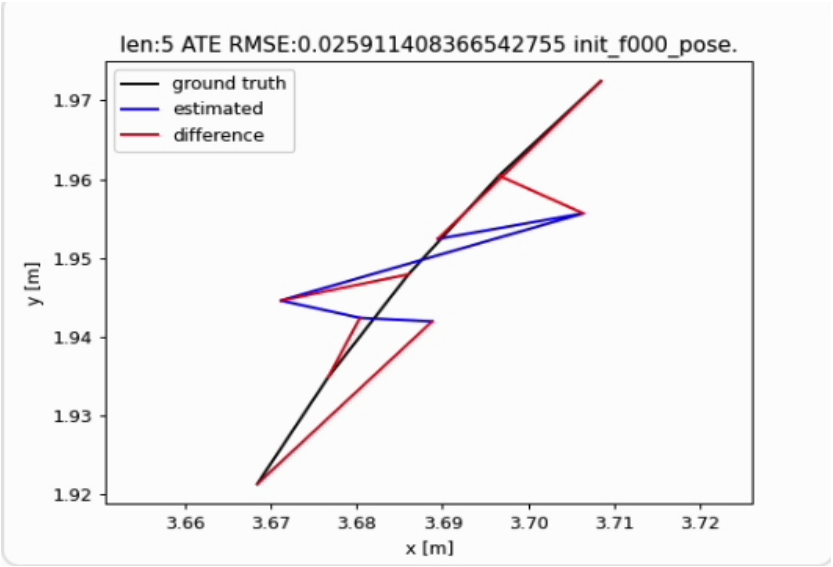
第一阶段： Initialization



4500轮后的**误差残次图**



整体图片残差图



相机轨迹预测偏差（ATE）曲线

第一阶段： Initialization

Setting	PSNR↑	SSIM↑	LPIPS↓	ATE
full	**21.74**	**0.82**	**0.23**	**0.046**
w/o	17.80	0.76	0.26	1.534

Table 3. Ablation Study about Depth Initialization. The unit of ATE is cm. The experimental results demonstrate the effectiveness of the initialization strategy. It not only improves the quality of rendered images, but also improves the accuracy of the camera motion estimation significantly.

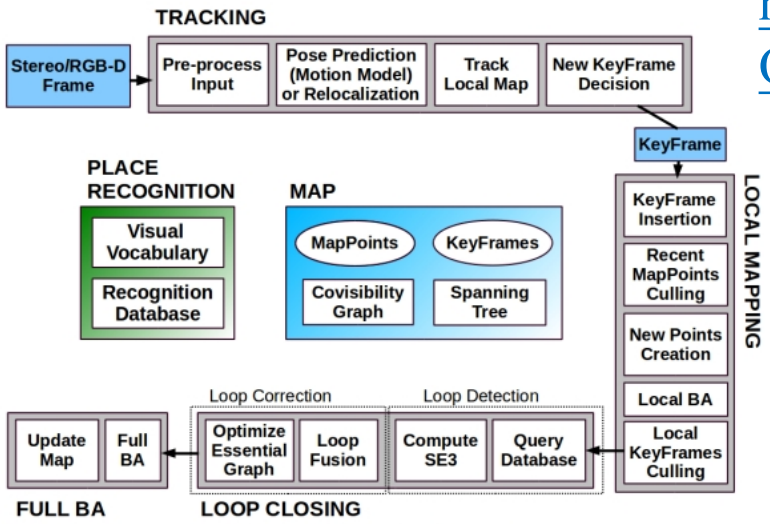
一个好的初始化能够为后续提供稳定且合理的初始几何结构，从而减少位姿漂移并提升整体 3D 重建质量。

第二阶段：增量式Tracking & Mapping

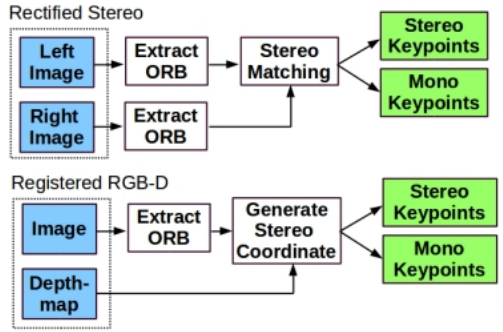
理论基础：SLAM（Simultaneous Localization and Mapping）

解决：让机器人或相机在一个未知环境中，**一边移动，一边估计自己的位置**，同时**构建周围环境地图**

https://github.com/raulmur/ORB_SLAM



(a) System Threads and Modules.



(b) Input pre-processing

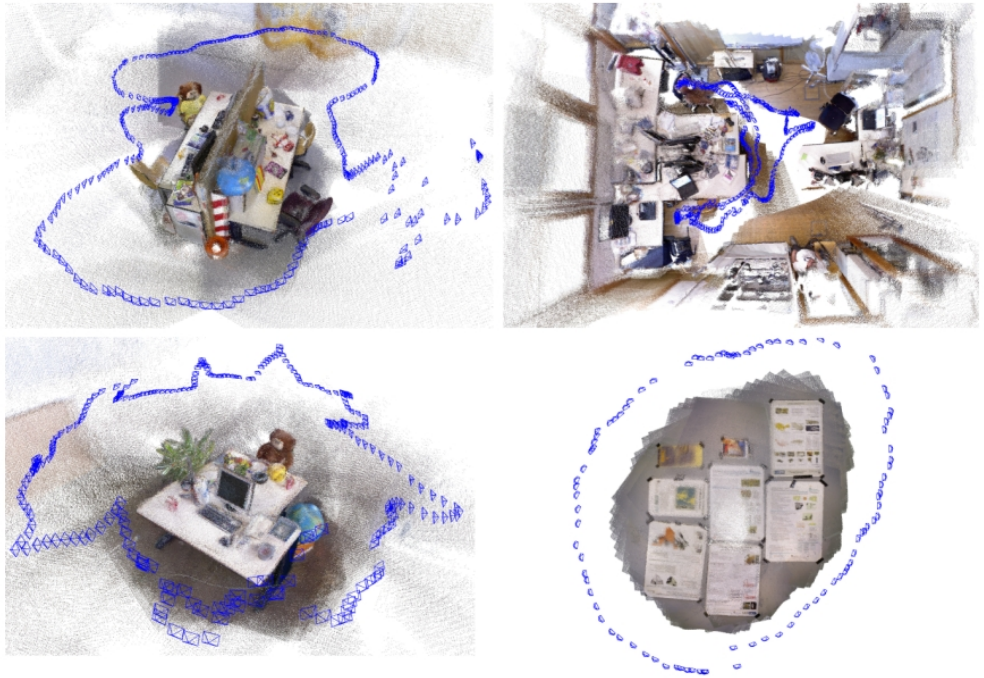


Fig. 7. Dense pointcloud reconstructions from estimated keyframe poses and sensor depth maps in TUM RGB-D *fr3_office*, *fr1_room*, *fr2_desk* and *fr3_nst*.

Image Input → Feature Extraction（角点 / 边缘）→ Feature Matching（寻找对应关系）→ Tracking（估计相机运动）→ Triangulation（三角化恢复3D点）→ Mapping（构建3D场景）→ Bundle Adjustment（联合优化 Pose & Map）→ Loop Closing（减少累计误差）

第二阶段：增量式Tracking & Mapping

SLAM：Tracking（估计相机位姿）
Mapping（优化地图结构）



IncEvent：Tracking（估计相机位姿）
Mapping（优化3DGS）

一、Tracking（估计相机位姿）

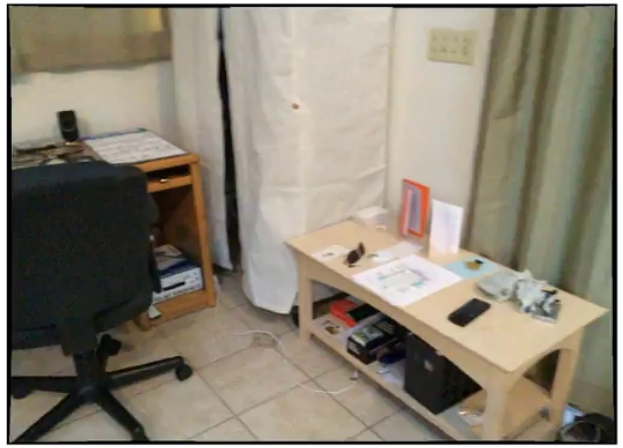
1. 每次加入一个新的事件块，利用当前已经重建出的 3D Gaussian，估计新到来的事件块的相机位姿。
2. 通过亮度变化误差来优化当前事件块的相机轨迹

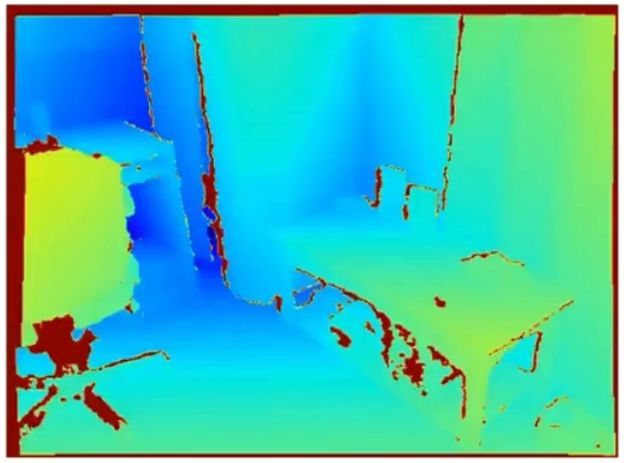
二、Mapping（优化3D高斯场景）

1. 完成Tracking的事件块进入Mapping
2. Bundle Adjustment：对滑动窗口内（从新加入事件块往前20个事件块）所有的3DGS属性和相机轨迹参数进行联合优化

第二阶段：增量式Tracking & Mapping

RGB-D sequence





Tracking & Mapping (12-17Hz)

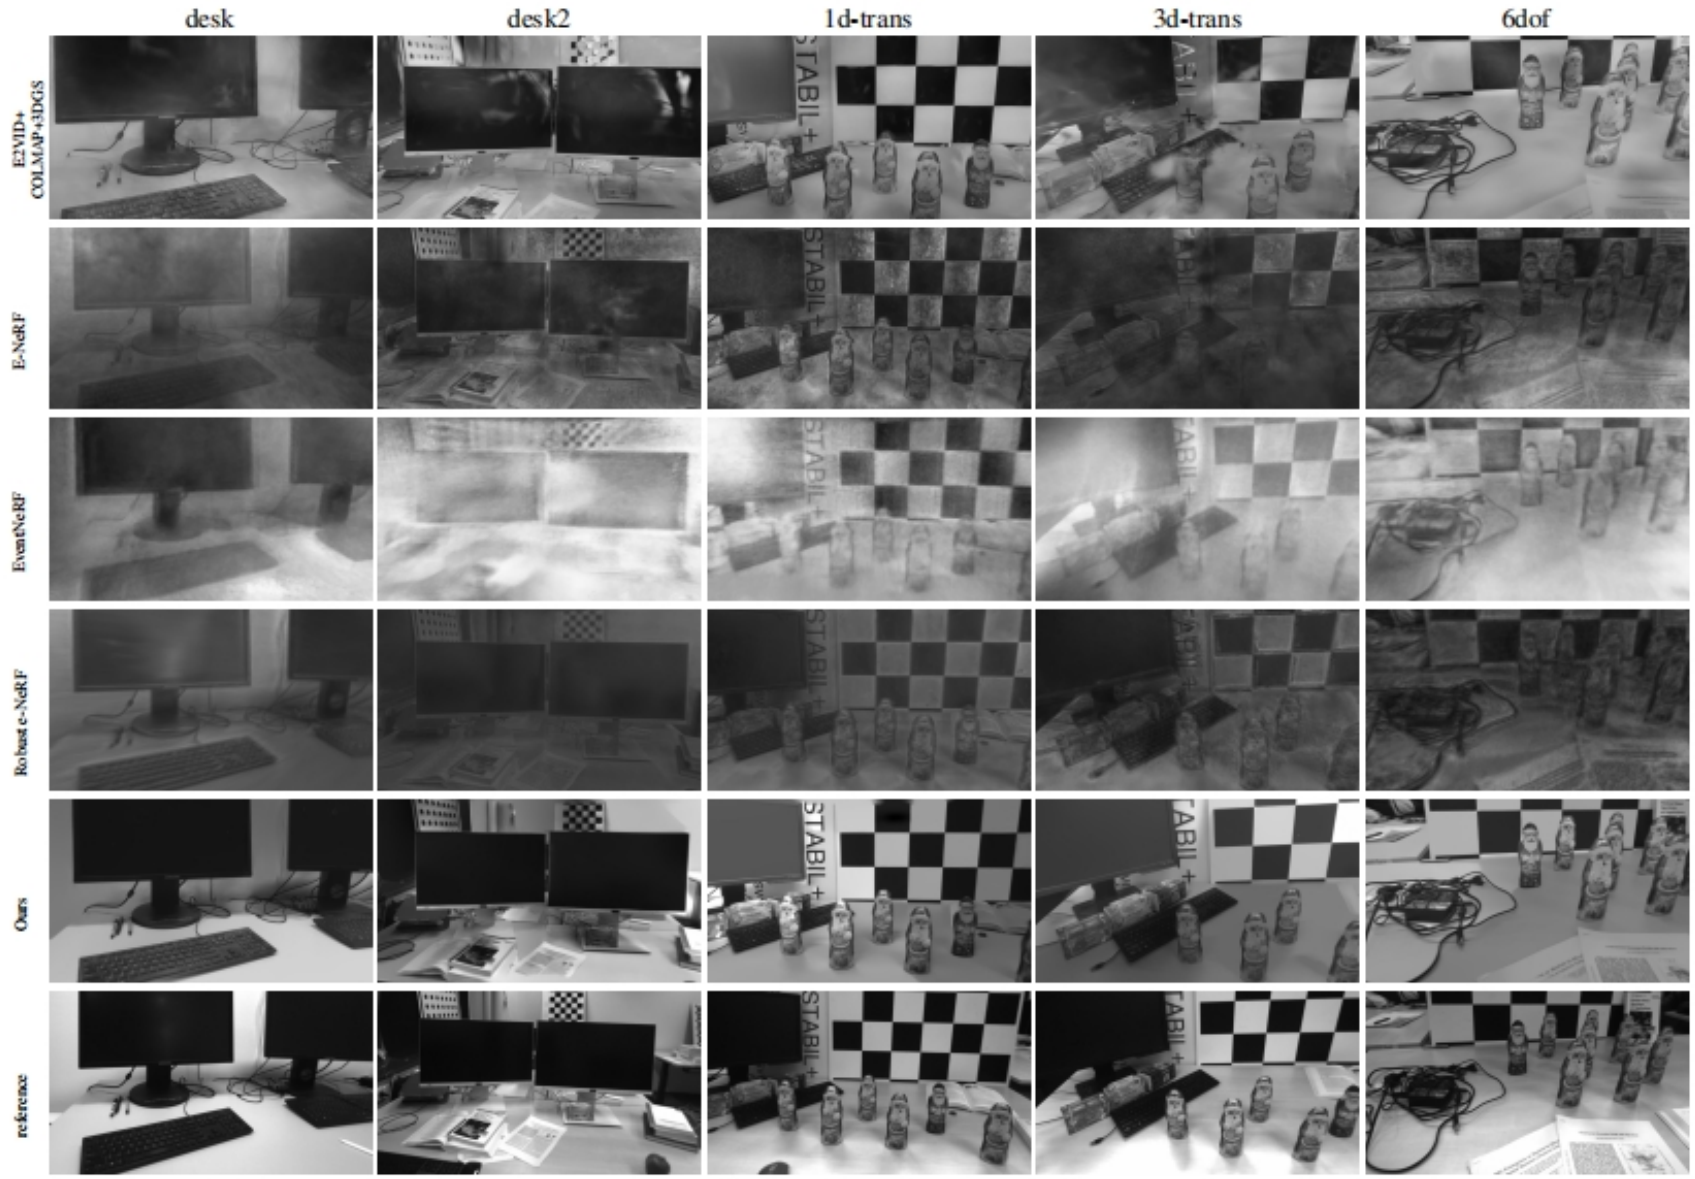


效果展示&评估指标



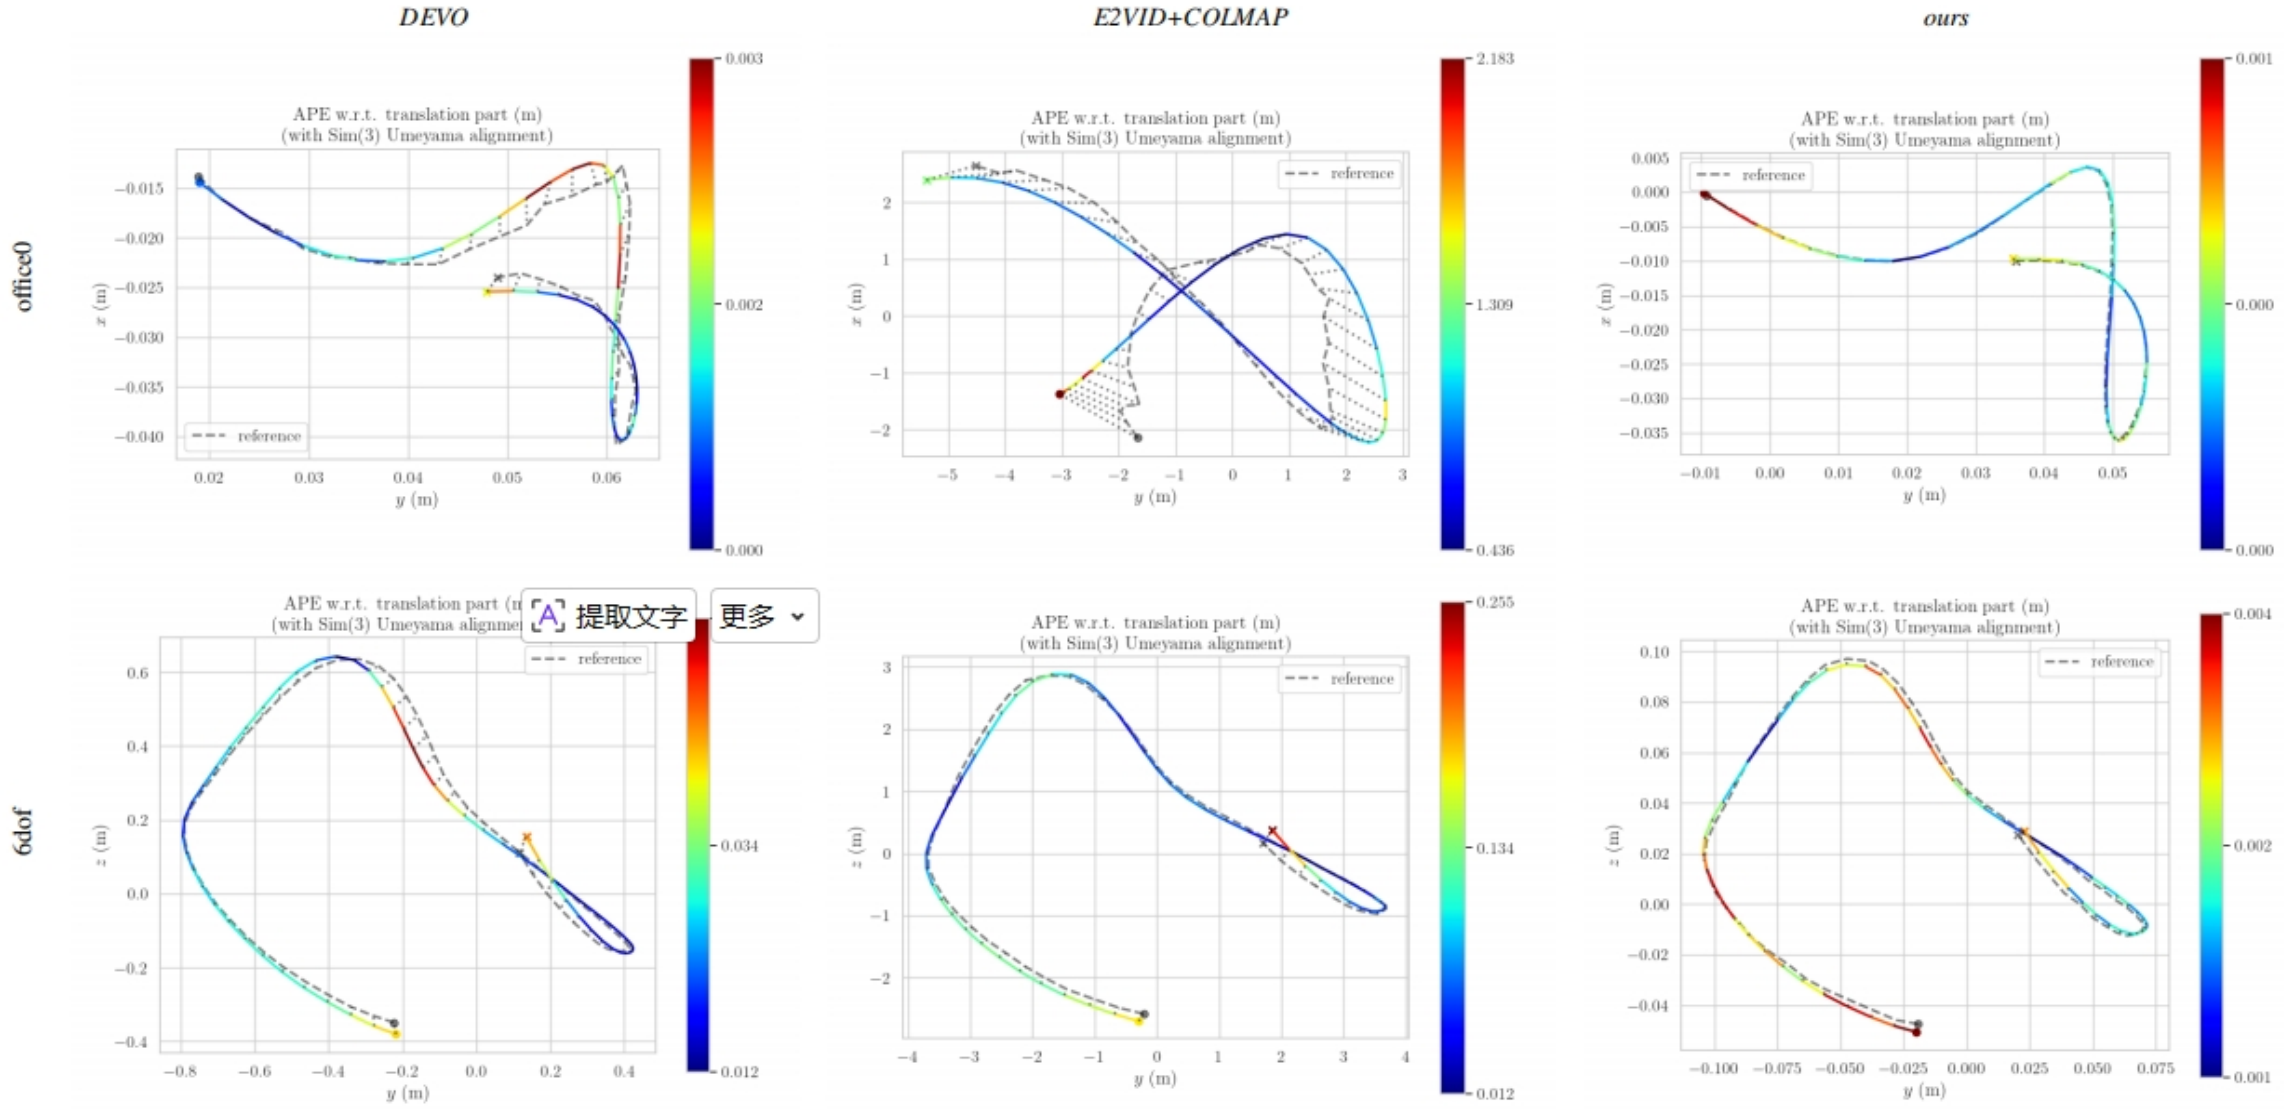
Replica dataset
场景数据集

效果展示&评估指标



自摄真实场景数据集

效果展示&评估指标


DEVO
E2VID+COLMAP
ours
office0
6dof
APE w.r.t. translation part (m)
(with Sim(3) Umeyama alignment)
reference
x (m)
y (m)
z (m)
0.003
0.002
0.000
2.183
1.309
0.436
0.001
0.000
0.255
0.134
0.012
0.004
0.002
0.001
提取文字
更多

效果展示&评估指标

	room0			*room2*			*office0*			*office2*			*office3*		
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
E-NeRF	13.99	0.58	0.51	15.56	0.47	0.58	18.91	0.51	0.57	13.05	0.65	0.44	14.01	0.62	0.48
EventNeRF	17.29	0.62	0.39	16.02	0.54	0.64	18.90	0.43	0.62	15.18	0.66	0.45	16.77	0.73	0.33
Robust e-NeRF	17.26	0.84	0.18	16.43	0.50	0.52	18.93	0.52	0.56	16.81	0.81	0.25	19.22	0.84	0.18
E2VID+ COLMAP+3DGS	14.45	0.44	0.52	15.74	0.51	0.55	18.91	0.31	0.68	14.03	0.57	0.48	13.25	0.47	0.53
Ours	**24.31**	**0.85**	**0.17**	**23.75**	**0.79**	**0.23**	**25.64**	**0.54**	**0.30**	**21.74**	**0.82**	**0.23**	**21.18**	**0.88**	**0.13**

PSNR↑, SSIM↑, LIPIS↓

	room0	room2	office0	office2	office3	1d	3d	6dof	desk	desk2
DEVO	0.289	0.266	0.138	0.281	0.156	0.147	0.303	2.93	0.732	0.201
E2VID+COLMAP	17.93	59.96	105.19	18.414	17.28	4.268	16.90	9.88	21.57	10.13
ESVO2	-	-	-	-	-	0.337	1.066	0.587	1.147	2.506
Ours	**0.046**	**0.067**	**0.045**	**0.046**	**0.054**	**0.115**	**0.298**	**0.251**	**0.231**	**0.129**

Table 2. Pose accuracy (ATE, cm) on Replica and TUM-VIE datasets. The results demonstrate that our method delivers better performance in terms of camera motion estimation. Since ESVO2 is a stereo event camera method, it cannot run on the Replica dataset.

相机轨迹偏差↓

IncEventGS 方法优点与局限

优点：

1. 无位姿重建，更接近真实事件相机应用

不需要预先给定相机位姿，而是同时估计相机轨迹和重建三维场景。相比依赖 COLMAP、同步定位与建图或真实位姿的方法，它更适合事件相机的真实应用场景。

2. 连续事件窗口采样，适合亮度变化建模

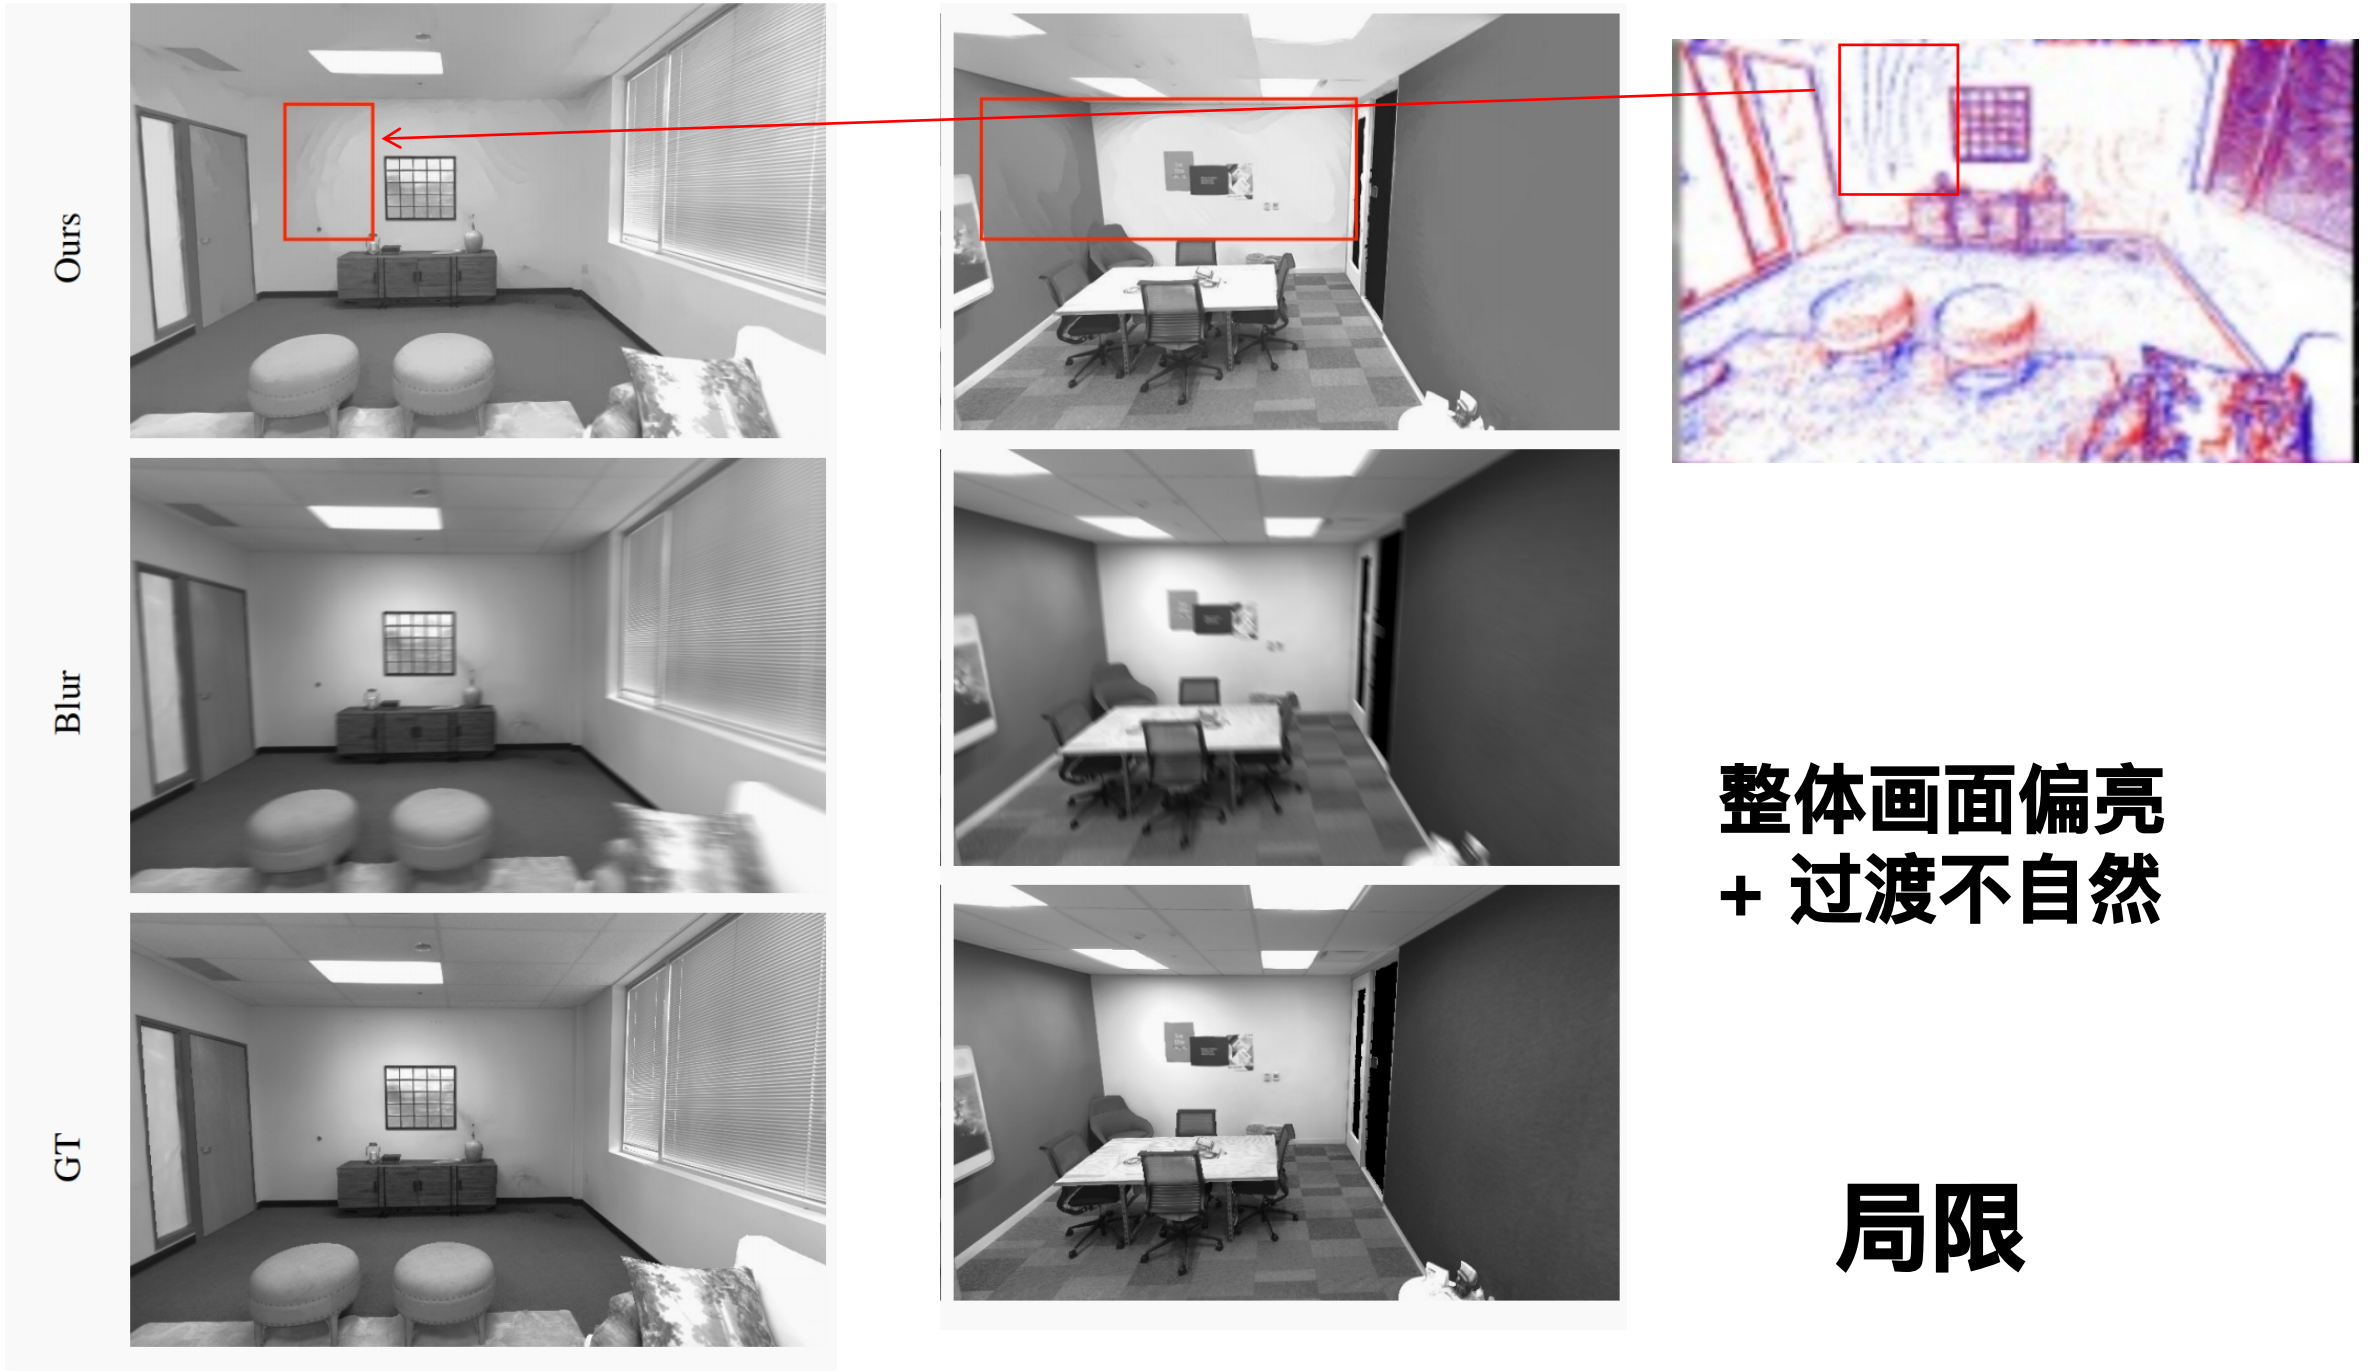
在事件块中截取连续事件片段。这样既能减少计算量，又能保留事件之间的时间连续性，便于计算真实亮度变化并与预测亮度变化对齐。

3. 基于深度先验的初始化，改善早期三维结构

由于事件相机不直接输出完整亮度图像，初始三维结构较难获得。IncEventGS 利用预训练单目深度模型提供深度先验，帮助重新初始化高斯点位置，使后续跟踪和建图更加稳定。

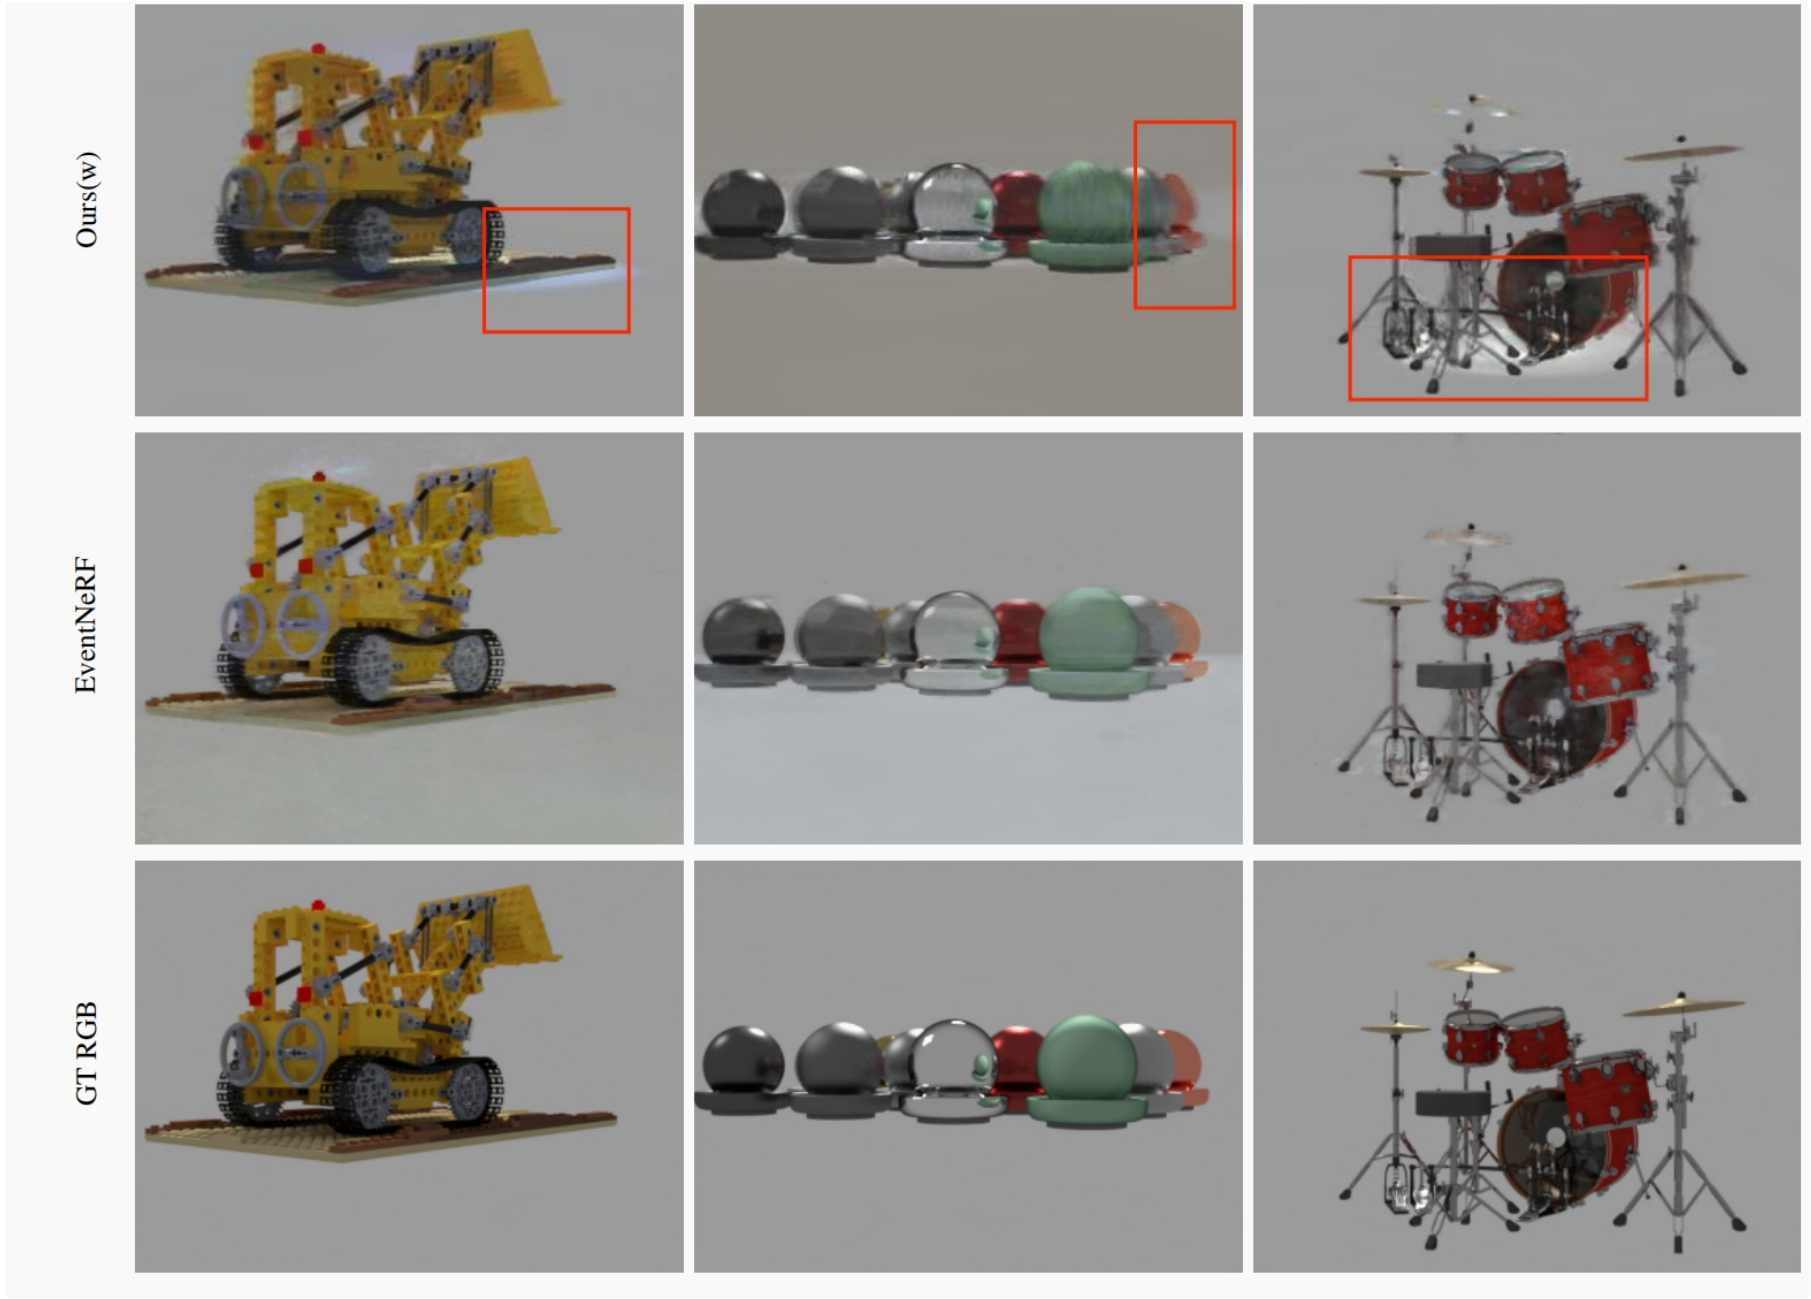
4. 引入“跟踪—建图”框架，支持增量式优化

方法将事件流切分为多个事件块，并采用类似同步定位与建图的流程：跟踪阶段估计当前事件块的相机运动，建图阶段联合优化相机轨迹和三维高斯表示，使系统可以随着事件流输入逐步更新。



整体画面偏亮
+ 过渡不自然

局限



小局部过曝

局限