2024 年第五届“大湾区杯”粤港澳
金融数学建模竞赛

题　目　**粤港澳大湾区经济增长因素分析与预测模型研究**

摘　要：

粤港澳大湾区包括香港特别行政区、澳门特别行政区和广东省珠三角九市，是我国开放程度最高、经济活力最强的区域之一。近年来粤港澳合作不断深化实化，经济实力、区域竞争力显著增强，已具备建成国际一流湾区和世界级城市群的基础条件。预测粤港澳大湾区未来经济发展既是服务国家战略的需要，也是优化区域发展的重要举措。本文通过数据分析与建模，量化各经济因素对经济发展的独立作用及联动效应的经济增值作用，并预测未来 5-10 年大湾区的经济走向，为区域政策优化与促进大湾区持续快速发展提供科学依据和策略建议。

针对问题一, 基于粤港澳大湾区 2017 年至 2023 年的经济指标数据，通过**多项式插值**和 **ARIMA 模型**估算缺失数据，对数据进行预处理；采用**随机森林模型**和**主成分分析模型**构建粤港澳经济因素评估模型，分别量化各因素的独立作用及联动效应对经济发展的影响程度，综合分析两种不同模型产生的结果，最终得出以下关键经济因素：人口，进出口货值，第二产业（产业结构），高等教育接受程度与科技。这些因素相互交织，共同推动区域经济的持续增长。

针对问题二, 根据问题一得出的关键经济因素，结合**卷积神经网络模型**提取局部特征与**长短期记忆网络模型**捕捉长期依赖的不同优势，创新构建出**粤港澳大湾区经济预测模型**。此外，考虑到未来的经济环境中存在诸如自然灾害、国际关系等不确定性因素，加入**随机噪声**提高其在不稳定环境下的鲁棒性。通过经济预测模型，粤港澳大湾区经济在未来将出现一定程度的波动，特别是在 2027 年至 2028 年可能面临较大压力。然而，从 2029 年开始，经济将逐步恢复并进入稳步增长期。接着结合粤港澳大湾区现况分析经济走势，并制定可行全面的策略方案。

针对问题三, 基于纽约湾区 2017-2023 的经济指标数据，利用问题一、二中构建的**粤港澳经济因素评估模型**和**粤港澳大湾区经济预测模型**，对粤港澳大湾区（GBA）与纽约湾区（NYBA）的经济增长驱动因素进行了比较和预测分析。结果表明，GBA 的经济增长主要依赖于工业、制造业以及国际贸易创收，而 NYBA 则得益于强大的科技产业和高等教育基础。而预测结果显示：在技术创新和产业转型的推动下，两个区域未来的经济增长路径将**逐渐趋同**，展现出全球经济复苏和增长的共性趋势。

针对问题四, 在粤港澳大湾区的经济预测数据建模和分析的基础上，简报包括以下

三个核心内容：一、明确建模依据，简要介绍所选用的经济指标及数据处理方法；二、揭示关键影响因素，展示基于建模结果的经济预测；三、提出政策建言并分析采取措施的影响，为经济持续健康发展提供决策参考。

关键字： ARIMA 模型　随机森林模型　卷积神经网络　长短期记忆网络　随机噪声

一、 问题重述

1.1 问题背景

粤港澳大湾区（Greater Bay Area, GBA）是中国开放发展战略中的重要区域，包含广东省的广州、深圳、珠海等九市及香港、澳门两个特别行政区。该区域聚集了金融、科技等资源，是我国对外开放的前沿窗口。本文聚焦于通过政策协同、资源共享等方式形成的经济网络，以提升整体经济效益和全球竞争力。

1.2 问题要求

问题一：因素分析：首先，针对粤港澳大湾区经济发展的众多影响因素（如人口、科技、物流等），根据历史数据进行分析，量化各因素对区域经济的影响程度。考虑到不同因素对应的的不同影响维度（例如人口年龄结构、教育水平等），通过建立数学模型对这些因素进行评估，提取对未来 5-10 年影响较大的关键因素，并对其进行分级分类。

问题二：经济预测模型：在识别出关键因素后，构建数学模型预测粤港澳大湾区未来 5-10 年的经济走势。基于模型预测结果，设计促进大湾区经济快速发展的策略，以增强区域的竞争力和创新驱动力。

问题三：湾区比较分析：在完成粤港澳大湾区的经济预测基础上，选择其他主要湾区（如旧金山、东京或纽约湾区），分析研究该湾区的经济发展特点，并运用同样的分析方法或模型对其未来经济进行预测。同时，量化分析不同湾区在发展特点上的异同点，为粤港澳大湾区的发展提供借鉴。

问题四：简报建议：基于前述分析和模型结果，本篇论文将撰写一份简报，向决策部门提供未来 5-10 年大湾区经济预测以及促进经济增长的策略建议。简报内容将包括建模依据、预测结果以及可行的政策建议。

二、 模型假设

本文提出以下合理假设：

- 假设一：本文假设本题 2017-2023 年的广泛数据能够大体反映粤港澳大湾区未来的发展趋势，未来经济形势的发展在一定的可控范围内。
- 假设二：假设在模型中，主要影响因素是独立或交互的，并不会受到未包含的外部因素强烈干扰，便于简化各因素的定量分析。
- 假设三：假设选定的关键影响因素在未来 5-10 年内对粤港澳大湾区经济仍然保持显著作用，不会发生重大变化或被新的影响因素取代。
- 假设四：假设对比分析的影响湾区经济的关键因素相同，其经济特征相对稳定，且经济发展规律和影响因素对比稳定，适用于与粤港澳大湾区进行对比。

三、 问题分析

3.1 问题一分析

针对问题一，要分析粤港澳大湾区经济发展的影响因素，首先需要收集粤港澳大湾区 2017-2023 年的各项历史数据（如 GDP、人口、科技、高等教育水平和多项产业指标等），明确主要经济指标（如 GDP、人口、进出口货物额等）的变化趋势。接着，利用多种数据处理和分析方法（如多项式插值、ARIMA 模型、随机森林和主成分分析）对历史数据进行数据预处理和对其中多项不同因素各自的重要性评估进行数学建模，建立粤港澳大湾区经济因素评估模型，以量化各因素的独立作用和联合作用。通过评估各因素的重要性，找出对未来经济走势具有显著影响的关键因素，并结合经济结构、科技创新、教育水平等方面进行深入分析，为形成系统性的经济发展预测框架和政策制定提供科学依据。

3.2 问题二分析

针对问题二，我们可以根据问题一中提取出的影响粤港澳大湾区经济发展的主要因素，创新结合卷积神经网络 (CNN) 和长短期记忆网络 (LSTM) 两种模型，并综合利用两者对于因素特征提取以及时间序列完整性等方面处理的优越性，同时综合考虑现实中随机噪声的影响因素，构建粤港澳大湾区经济预测数学模型。最后针对预测出的粤港澳大湾区的经济走势进行全面的分析，并设计策略制定方案以促进粤港澳大湾区的快速发展。

3.3 问题三分析

针对问题三，我们首先收集一个或者多个湾区的相关数据，与问题一、二类似，首先进行数据的预处理，随后通过粤港澳大湾区经济因素评估模型，评估出各经济因素对不同湾区的重要性程度，接着通过粤港澳大湾区经济预测数学模型，预测出其他湾

区未来 5-10 年的经济走势。量化分析不同湾区之间发展的异同.

3.4 问题四分析

针对问题三，结合问题一、二中的建模过程和数据结果，着眼于对粤港澳大湾区未来经济发展的简报编写，简报分析不仅要涵盖粤港澳大湾区未来 5 至 10 年的经济走势，还要结合区域政策环境，提出具体政策建议，并分析政策建议对应的可能产生的经济影响，以进一步支撑大湾区的高质量发展。

四、 符号说明

表 1　符号表

符号	说明
GDP	国内生产总值
$P(x_i)$	多项式插值函数在 x_i 处的值
x_i, y_i	插值数据点的横纵坐标
$Gini(p)$	基尼不纯度，衡量节点分裂后的纯度
$Gain$	基尼不纯度的减少量，衡量特征的重要性
ARIMA	自回归积分滑动平均模型
y_t	时间序列的当前值
c	常数项
ϕ_i	自回归系数
θ_i	移动平均系数
ϵ_t	白噪声项
N	总样本数
N_t	节点 t 的样本数
$\Delta Gini(X_j)$	特征 X_j 对基尼不纯度的贡献度

五、 问题一的模型建立与求解

5.1 数据预处理

粤港澳各地区历年数据较多，为了高效地利用海量数据以及考虑三个地区联动效应，即：考虑三个地区分别结合各自地域优势赋能于粤港澳大湾区的整体发展, 本论文

选取自从大湾区建立成熟并且建立深度合作的 2017 年至 2023 年以来统计的数据作为时间序列分析原数据。

本研究所运用的数据包含了从粤港澳地区从 2017 年到 2023 年的经济指标，包括 GDP、GDP 增长率、人口总量、进出口货值、科技研究机构数、技术合同成交额以及各产业的增长幅度等各种量化指标。每个指标的变化反映了经济的动态和趋势变化，从数据中可以发掘到各种指标对于经济发展的影响，了解到各个地区 GDP 的增长点，并因此因地制宜地制定相应的政策。

原时间序列的数据中，存在空值数据，因此需要进行数据预处理，为下一步数据分析以及建模过程奠定基础。由于不同属性的缺失数据的位置以及缺失比例的不同 (如表 1，表 2)，我们应该结合不同的差值方法与不同的技巧对缺失数据进行填充。

表 2　粤港澳大湾区人口总量时间序列数据的缺失情况

年份	2017	2018	2019	2020	2021	2022	2023
人口总量/万	8144.86	8360.97	8503.96	8634.52	8669.07	8643.97	NULL

对于地区人口总量数据的缺失情况 (表 1)，我们利用多项式插值拟合一个多项式函数来估算缺失值的方法，适用于数据变化较为复杂的情况。由于人口数据变化受到政策，整体经济形式和大环境的影响，所以数据变化受到多方面复杂的影响，因此适合用多项式插值算法拟合曲线来估算缺失值。

$$P(x_i) = y_i, \quad \text{for } i = 0, 1, \ldots, n$$

用拉格朗日插值公式表示为:

$$P(x) = \sum_{i=0}^{n} y_i \prod_{\substack{0 \le j \le n \\ j \ne i}} \frac{x - x_j}{x_i - x_j}$$

经过科学计算工具后，运用多项式插值来估算 2023 年的人口数据，选择合适的多项式阶数来适应人口数据整体的变化趋势，保证填充的数据与原数据有较好的平滑性连接，以适应非线性数据的特点。

表 3　粤港澳地区技术合同成交额时间序列数据的缺失情况

年份	2017	2018	2019	2020	2021	2022	2023
技术合同成交额/亿	NULL	NULL	NULL	3465.9205	4292.73	4525.42	NULL

对于地区技术合同成交额数据的缺失情况 (表 2)，我们将数据进行改良，以适应 ARIMA 模型的要求。首先进行 ARIMA 模型第一步 ADF 平稳性检验: p-value=6.68778e-

28 < 0.05, 可认为这个序列数据是平稳的。接下来，我们需要细化到一年中每一个月的合同成交额。将 2019、2020、2021 年三年数据中的每一个月合同成交额数据进行充分利用，即：总共有 12×3 个月的历史数据，确保可观测到历史数据趋势以及捕捉到时间序列的动态特征。需要进行短期预测的情况下 (如未来 1 年)。通过适当的差分和参数选择，ARIMA 能够有效捕捉时间序列的动态变化，为决策提供可靠的支持。

利用自回归 ϕ(AR), 差分 (I), 移动平均 (θMA) 三个部分构成表达式：

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \epsilon_t$$

利用多个月的历史数据来拟合 ARIMA 模型。通过拟合的模型进行未来 24 年技术合同成交额值的预测，从而预测科技对产生经济效益的价值。对数据中各个缺失的数据进行填充后，确保时间序列中没有缺失值。我们对填充后的各项数据指标都进行可视化，填充效果如下 (图 1)：

5.2 基于历史数据的粤港澳经济因素评级模型

本节将研究大湾区各因素对粤港澳大湾区经济发展的影响，并对各因素的影响程度进行量化分析。我们注意到，这些经济因素不仅仅是单独作用的，它们之间的相互关系和联合作用同样至关重要。因此，除了运用多个模型综合评估各个因素的独立影响外，我们还需探讨它们之间的交互作用，以揭示其综合效应对经济增长的推动作用。这种多维度的分析方法将帮助我们更全面地理解大湾区经济发展的动力机制，识别出哪些因素在不同情境下能够更有效地促进经济增长，从而为政策制定提供更有针对性的建议。通过结合定量分析与多元交互作用模型，我们期望能够揭示出大湾区经济发展的复杂性与动态性，为后续的经济预测与决策提供坚实的理论基础。

5.2.1 各经济因素的单独作用

5.2.1.1 运用随机森林模型评估经济因素

随机森林模型算法是一种基于集成学习的强大工具，其通过自助法（Bootstrap）从原始时间序列训练集中随机抽取多个样本子集，以构建多个决策树。这些子集为每棵决策树提供了独特的数据特征和规律的学习机会。在每棵决策树的节点分裂过程中，随机选择特征的子集，从中挑选出最佳特征进行分裂，这种特征选择机制增强了模型的多样性和鲁棒性。

为了量化各个因素对经济发展的影响，随机森林能够通过计算特征的重要性来评估其对预测结果的贡献。这一过程涉及比较在子树分裂节点时所用特征所带来的增益，进而评估各特征对模型决策的影响程度。高重要性的特征在模型决策中起着关键作用，而低重要性的特征则可能对结果的影响微弱或可忽略。因此，随机森林模型不仅适合

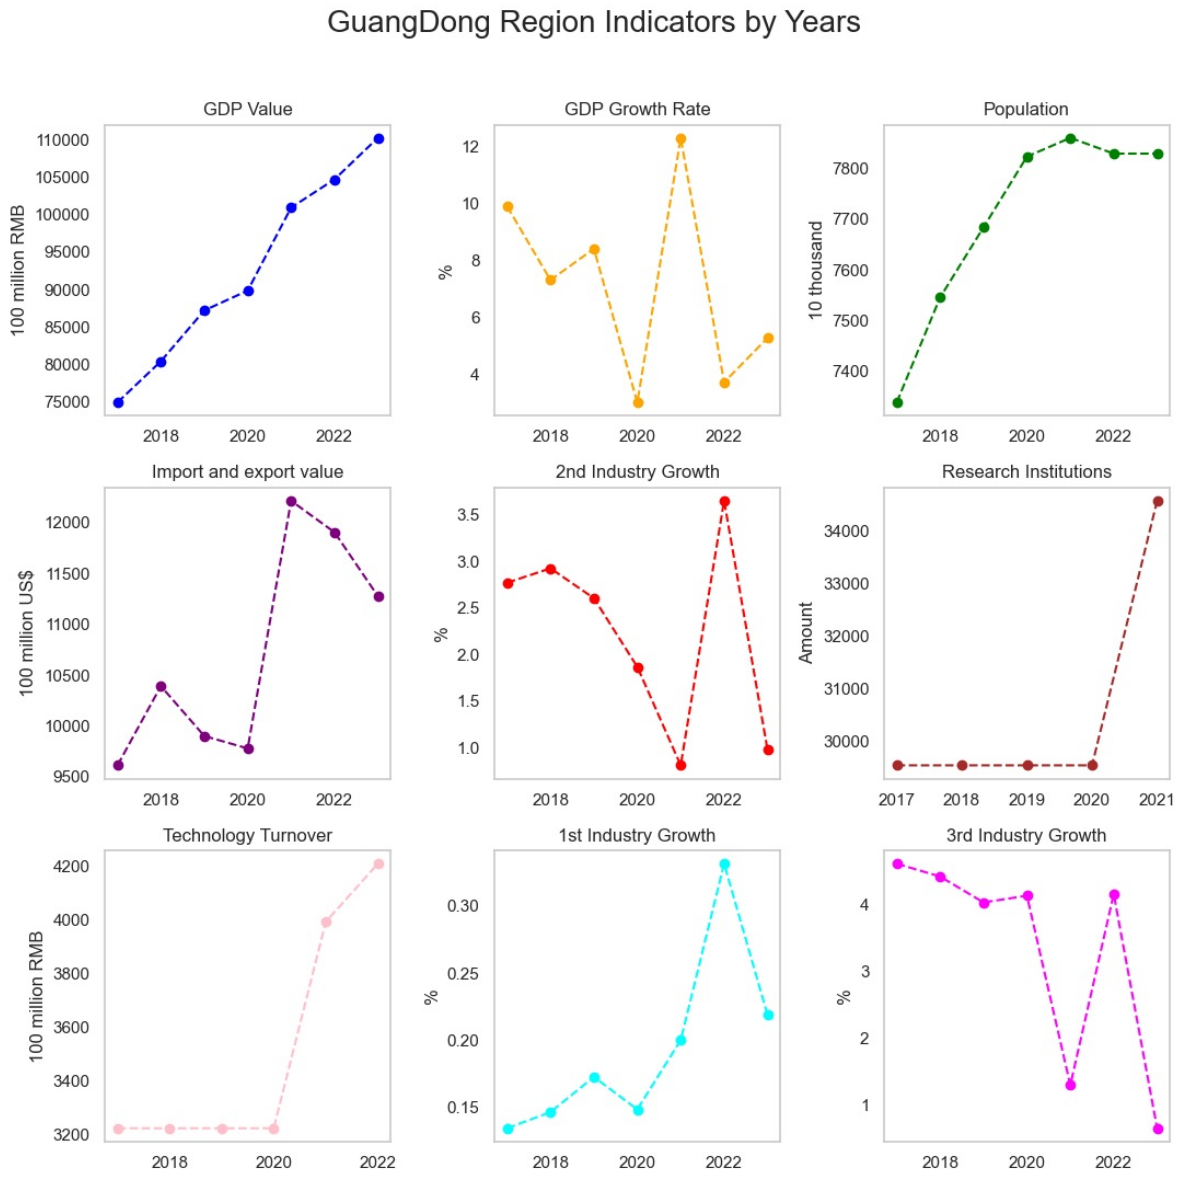


图 1　填充空值后各项指标的可视化

处理高维数据，还具有良好的抗噪声能力，能够有效识别和提炼出对经济发展具有显著影响的关键因素。

在应用随机森林模型进行经济因素量化评价时，其内部结构能够自动评估特征的重要性，通常依赖于决策树在节点分裂过程中对不纯度的影响。这种机制使得随机森林在量化各因素对经济发展的影响时，能够提供更为精准的决策支持，有助于构建具有实际指导意义的经济预测模型。

首先，我们定义 Gini 不纯度：

$$Gini(p) = 1 - \sum_{i=1}^{C} {p_i}^2$$

其中 p_i 是类别 i 的比例，C 是类别总数。Gini 不纯度越小，表示节点的纯度越高。

然后，计算每次节点分裂的 Gini 不纯度减少值：

$$Gain = Gini_{parent} - (\frac{N_{left}}{N} \cdot Gini_{left} + \frac{N_{right}}{N} \cdot Gini_{right})$$

其中，N_{left} 和 N_{right} 是左、右子节点的样本数量，N 是父节点的样本数量。

当某个特征 X_j 用于分裂节点 t 时，该特征的引入会导致 Gini 不纯度的减少，记作 $\Delta Gini_t(X_j)$。可以用以下公式表示特征 X_j 的重要性：

$$Importance(X_j) = \sum_{t \in T} \frac{N_t}{N} \Delta Gini_t(X_j)$$

- T：模型中所有的树。
- N_t：节点 t 的样本数。
- N：总样本数。
- $\Delta Gini_t(X_j)$：节点 t 因特征 X_j 分裂导致的 Gini 不纯度的减少。

结合上面对于 Gini 不纯度的定义，每棵决策树的构建过程中，随机森林会记录每个特征在节点分裂时的 Gini 不纯度的变化。每次分裂节点时，选择一个特征和相应的阈值，计算分裂前后 Gini 不纯度的差值（$\Delta Gini(X_j)$）. 接下来遍历所有树和节点时，将每次分裂的 Gini 不纯度减少情况进行累积, 再进一步计算出各个因素的重要性，得到重要性的量化指标。经济因子的重要性反映出了各个因素对于粤港澳地区经济增长的作用。

表 4　经济因子的重要性排序

因素	进出口	人口总量	第二产业	第一产业	GDP 增幅	第三产业	高等教育	科研机构	技术创收
量化指标	0.1698	0.1507	0.1505	0.1451	0.1260	0.1105	0.0813	0.0435	0.0226

根据以上结果可以得出，粤港澳大湾区的第二产业发展、进出口物流货运和总人口数量是推动该地区经济增长的主要驱动力。进出口总额量化评估指标（0.1698）作为外贸的重要指标，反映了粤港澳地区在全球经济链中的重要地位，其高贡献度表明外贸活动对区域经济的拉动作用不可忽视。总人口量化评估指标（0.1507）是经济活动的基础，人口的增加不仅提升了消费需求，也促进了劳动力市场的活跃，为经济增长提供了动力。各产业的量化评估指标如第二产业（0.1505）和第一产业（0.1451）的增长率显示出粤港澳在产业结构调整中，传统行业仍然发挥着稳定的作用，尤其是第二产业的贡献，反映出制造业及相关服务业在经济转型中的重要性。GDP 增长率量化指标（0.1260）作为宏观经济健康的重要指标，与其他因素的互动关系进一步加强了经济发展的连贯性。

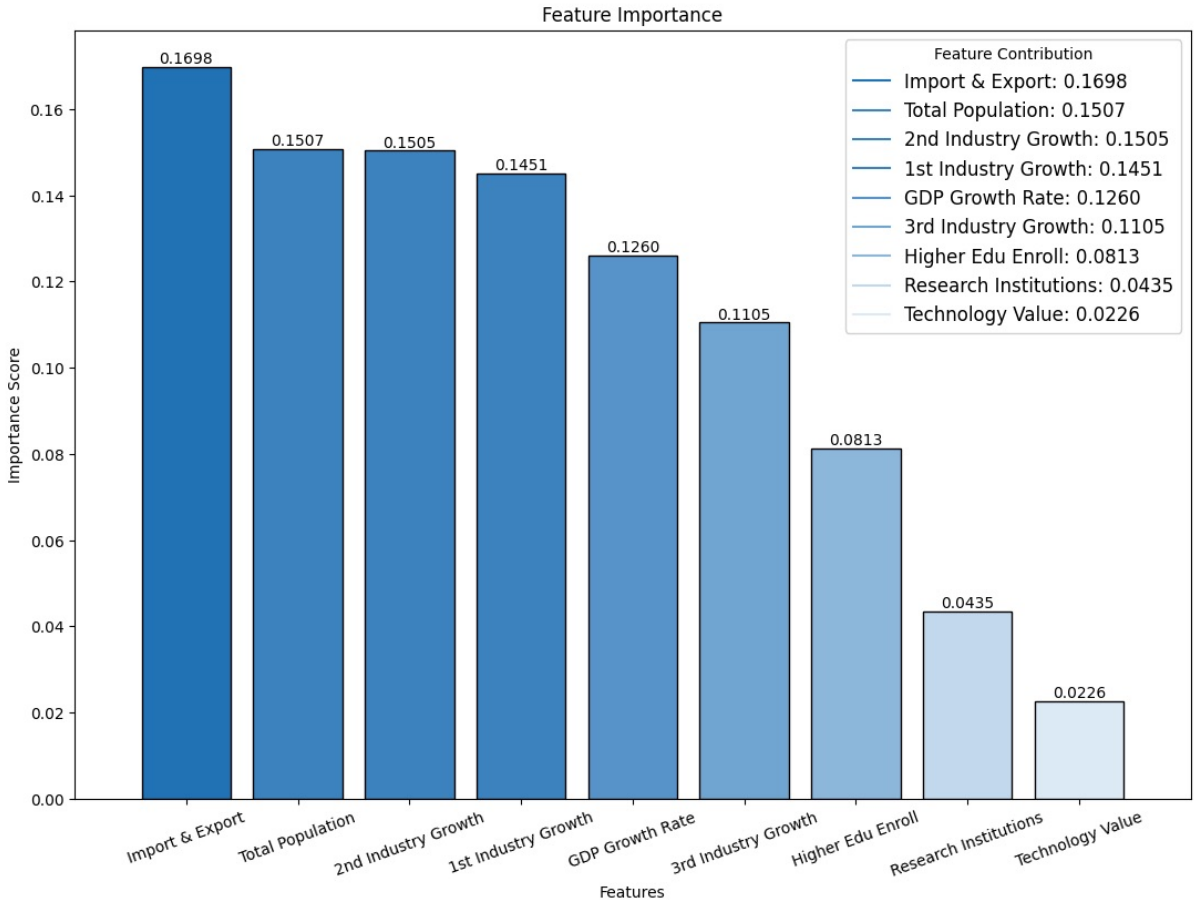


图 2　经济因子的重要性排序

此外，高等教育入学率量化指标（0.0813）与研究机构数量量化指标（0.0435）对经济发展的贡献表明，科技创新和人力资本的积累正在成为推动经济转型和提升竞争力的关键因素。科技价值量化指标（0.0226）的贡献相对较小，但在未来的经济发展中，随着科技进步的加速，其潜在影响力不可小觑。

5.2.1.2 运用改良主成分分析法评估经济因素

主成分分析法（PCA）是一种常用于降维的算法技术，可用于特征提取。通过线性变换方法，将原始特征转化为新的主成分特征，并且按照其解释方差顺序排列，然后保持主成分通常能够解释数据中大部分的变异性。由于 PCA 的方法可以处理像粤港澳大湾区多种信息融合的高维度数据，但同时也导致 PCA 方法对于特征尺度非常敏感，需要进行标准化并且计算出协方差矩阵，得出各特征之间的关系。对协方差矩阵进行特征值分解，得到特征值和特征向量。特征值表示各主成分方差，反映了每个主成分对数据变异性的解释能力。

结合上述得到的特征值与特征向量，可完成每个主成分 (PC) 的贡献率可以通过其

特征值与所有特征值之和的比例计算：

$$ContributionRate_i = \frac{\lambda_i}{\sum \lambda_j}$$

其中，λ_i 是第 i 个主成分的特征值，λ_j 是所有主成分的特征值。

进一步计算评估原始因素特征的重要性，可以运用每个主成分的特征向量元素，以表示原始特征对主成分的贡献。

引入负荷的计算因子 $loading_{ij}$ 与负荷矩阵 Loadings：

$loading_{ij}$ 代表了每个原始因素特征在主成分中的权重，反映了该因素特征对于主成分划分的作出贡献程度。

对于 p 个原始特征和 k 个主成分，主成分载荷通常被表示为一个 $p \times k$ 的载荷矩阵：

$$\text{Loadings} = \begin{bmatrix} \text{Loading}_{11} & \text{Loading}_{12} & \dots & \text{Loading}_{1k} \\ \text{Loading}_{21} & \text{Loading}_{22} & \dots & \text{Loading}_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \text{Loading}_{p1} & \text{Loading}_{p2} & \dots & \text{Loading}_{pk} \end{bmatrix}$$

结合上述的计算因子 $loading_{ij}$ 与负荷矩阵 Loadings，计算每个特征在前几个主成分中的载荷平方和，来评估其在这些主成分中的重要性：

$$FeatureImportance = \sum_{k=1}^{K} (loading_{ij})^2$$

其中，$loading_{ij}$ 是第 j 个特征在第 i 个主成分中的载荷，K 是选定的主成分数量。

通过 PCA 量化计算出各个经济因素对于粤港澳大湾区经济发展的影响程度，得到以下可视化效果（如图 3 所示）：

表 5　运用 PCA 方法量化计算各个单因素对经济的影响程度数据指标（上）

因素	人口总量	进出口货值	高等教育
量化影响数据指标	4.94803242e-01	3.00331671e-01	1.55747952e-01

表 6　运用 PCA 方法量化计算各个单因素对经济的影响程度数据指标（下）

科研机构	技术创收	第一产业	第二产业
4.01070608e-02	7.29352587e-03	1.71654878e-03	1.87825872e-33

结果显示，总人口对经济发展贡献最大，其重要性量化评估指标达到了 0.4948，大规模人口丰富劳动力市场，并且为粤港澳大湾区的消费市场提供活力。表明人口规模是

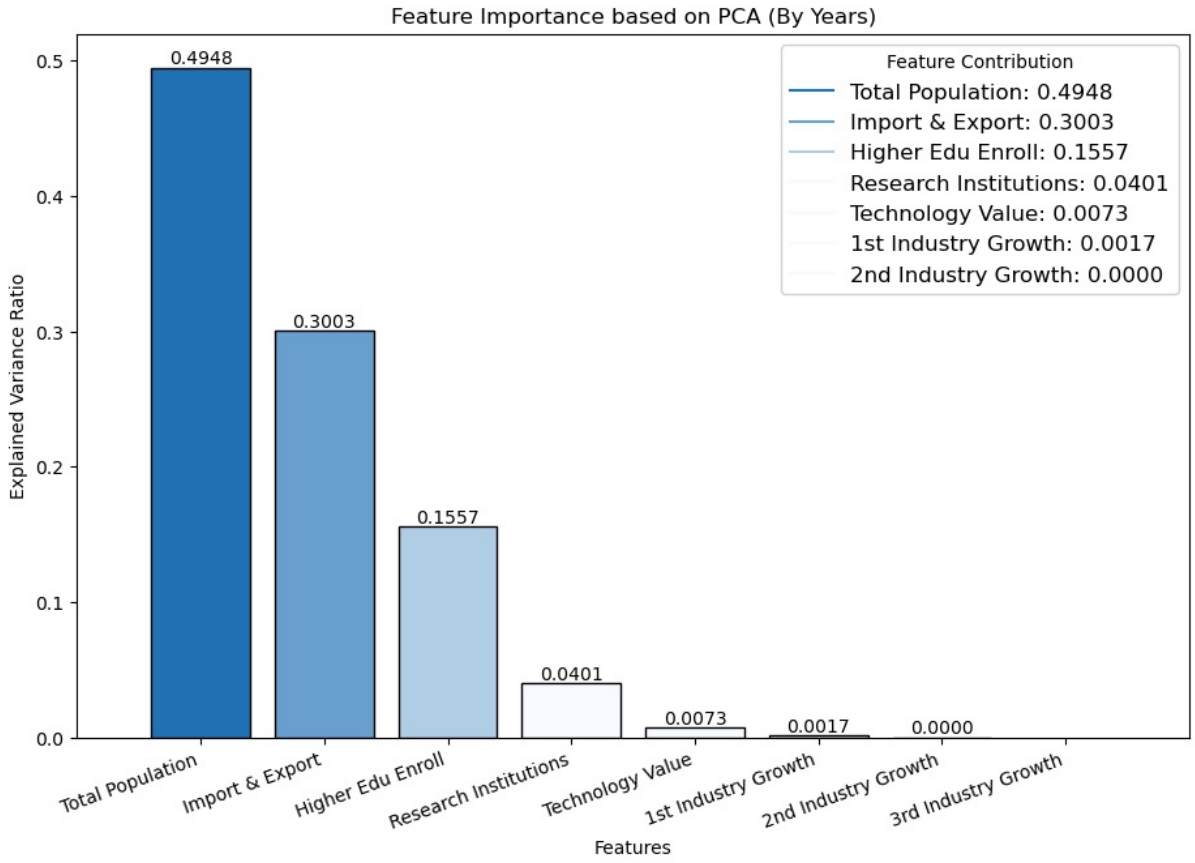


图 3　运用 PCA 方法量化计算各个单因素对经济的影响程度数据指标

驱动经济增长的关键因素。其次，进出口物流货运的重要性量化评估指标达到 0.3003，反映出外贸活动在区域经济中的重要性。其中高等教育入学水平的重要性量化评估指标达到 0.1557，提示教育资源对经济发展的支持作用。研究机构和技术价值的重要性贡献相对较小，分别为 4.01% 和 0.73%，这可能表明当前科技创新对经济发展的推动力尚未充分发挥。整体而言，人口和外贸是推动区域经济增长的主要因素，而教育和科技创新则需要进一步加强。

5.2.1.3 双重验证各因素对经济的影响

考虑到随机性，结合两个不同建模模型得出的结论与实际情况，我们可以双重验证各因素对经济的影响。

首先，外贸对于经济发展的影响较大：粤港澳大湾区地处中国南部，毗邻东南亚，拥有得天独厚的地理位置，使其成为国际贸易的重要枢纽。香港作为全球金融中心，外汇流入丰富，极大促进了进出口总额的增长。这种外贸活跃不仅带来了资金流动，还增强了区域内企业的国际竞争力，推动了经济的快速发展。

其次，粤港澳大湾区总人口庞大，青壮年劳动力比例高，使得劳动力市场潜力巨大。这一优势为经济增长提供了强劲的内需支持，特别是在服务业和消费品市场上，能

够有效促进经济活力。

产业结构对于 GDP 的影响也需要被重视，直至 2022 年，粤港澳大湾区第一、二、三产业占 GDP 比重分别为 1.32%、30.87%、67.81%。香港、澳门以第三产业为主，第三产业占比均在 90% 以上，产业结构仍然极其不平衡。同时我们注意到，尽管高等教育入学率在粤港澳大湾区并不算高，但教育资源的分布与科技创新能力正在逐步提升。高等教育对人力资本的培养及科技创新的推动是未来经济发展的关键。

5.2.2 多因素联合作用

经济发展的因素通常是相互作用的，形成复杂的动态系统。例如，第二产业的增长依赖于高效的物流系统来降低成本并提升竞争力，而科技创新又需要教育系统提供高素质人才支持。此外，人口数量的增加直接推动市场需求，进一步促进产业发展。同时，物流行业的科技创新（如自动化和数据分析）能够提高运输效率，增强进出口业务。这样的相互作用形成了复杂的动态系统，使得经济发展呈现出非线性特征，因此在经济预测和政策制定时需综合考虑这些关系。

接下来，运用 RF 模型对多因素联合作用的影响进行量化分析：通过因素特征的笛卡尔积组合（$x_1 \times x_2$），可以捕捉到两个因素特征之间的交互作用以及联合的作用。随机森林通过构建多个决策树并对每个树的预测结果进行平均来减少过拟合。

通过多种因素特征组合和随机森林模型的评估，探索了特征对 GDP 预测的影响。以下列出部分组合的笛卡尔积组合：

$$
\begin{aligned}
\text{第一组:} &\quad (\text{高等教育} \times \text{人口总量}) \\
\text{第二组:} &\quad (\text{进出口货值} \times \text{高等教育}) \\
\text{第三组:} &\quad (\text{科研机构数} \times \text{人口总量}) \\
&\quad \vdots \\
\text{第 N 组:} &\quad (\text{A 因素} \times \text{B 因素})
\end{aligned}
$$

通过 RF 模型对于子节点树的分析计算，得到了各种可能的因素特征组合对粤港澳地区经济发展的作用影响。

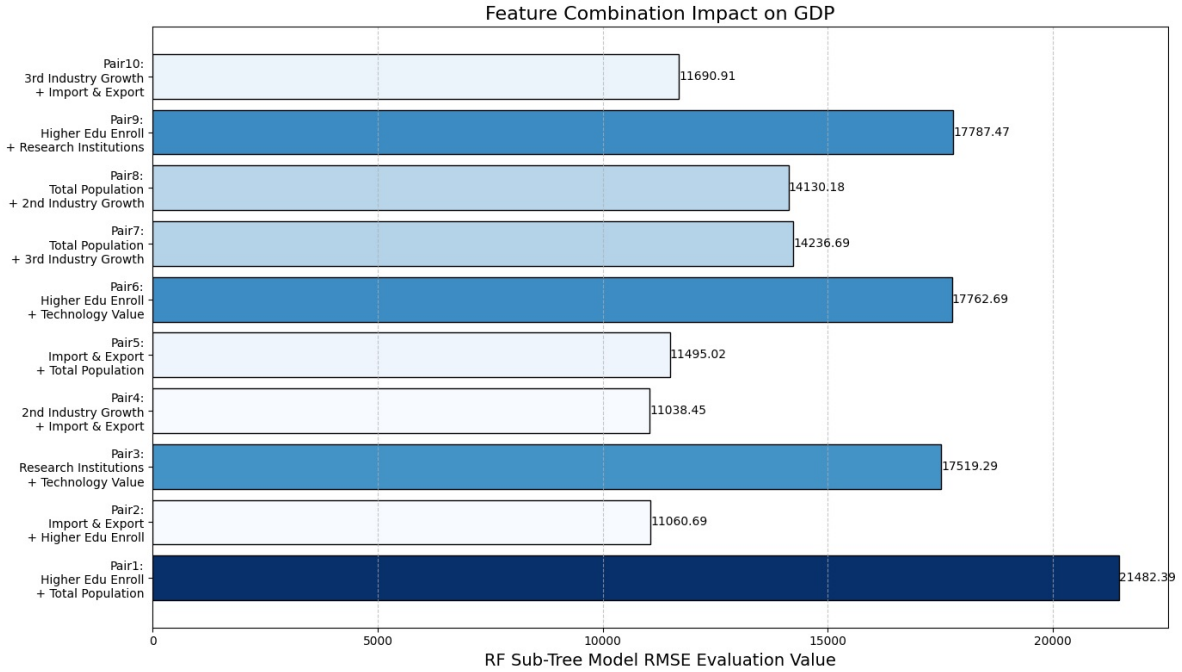


图 4　特征组合对经济影响程度较高的前 10 种结果

表 7　特征组合对经济影响程度

因素	人口总量	进出口货值	高等教育	科研机构	技术创收	第一产业	第二产业	第三产业
人口总量	NULL	11495.02	21482.39	NULL	NULL	14130.18	NULL	14236.69
进出口货值	11495.02	NULL	11060.69	NULL	NULL	NULL	11038.45	11690.91
高等教育	21482.39	11060.69	NULL	17787.47	17762.69	NULL	NULL	NULL
科研机构数	NULL	NULL	17787.47	NULL	17519.29	NULL	NULL	NULL
技合额	NULL	NULL	17762.69	17519.29	NULL	NULL	NULL	NULL
第一产业	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL
第二产业	14130.18	11038.45	NULL	NULL	NULL	NULL	NULL	NULL
第三产业	14236.69	11690.91	NULL	NULL	NULL	NULL	NULL	NULL

注：NULL 单元格表示这种因素特征组合对经济影响程度不高，仅展示前 10 种较高影响程度的结果。

图 4 通过横向柱状图的形式展示了不同特征组合对粤港澳大湾区 GDP 的影响，使用随机森林（RF）子树模型的均方根误差（RMSE）值作为评估标准，反映出特征组合在预测 GDP 方面的有效性。横轴上的 RMSE 值越小，说明该组合对 GDP 的预测精度越高，因此可以清晰地看出哪些特征组合具有较强的预测能力。

在特征组合及排序方面，图表从上到下列出了各组合的 RMSE 值，突显出某些组

合在 GDP 预测上的优势。例如，“第三产业增长 + 进出口总值”组合运用指标 RMSE 评估值为 11690.91，成为所有组合中最小的，这一结果表明，这两个因素的结合能够较好地反映出大湾区经济的实际增长情况，强调了这两者在推动经济发展中的重要性。进一步分析特征重要性，可以发现“第三产业增长”、“高等教育入学率”、“技术合同成交额”等特征对 GDP 的预测效果显著。特别是以“第三产业增长”为核心的组合，其普遍展现出较低的 RMSE 值，进一步证明了第三产业在粤港澳大湾区经济发展中的主导地位。这一发现不仅与大湾区的经济结构相吻合，也突显了服务业、金融和科技等行业在促进 GDP 增长中的关键作用。

在特征关联性方面，不同组合的 RMSE 值差异显示了特征之间的相互关系。例如，“高等教育入学率 + 科研机构数量”组合的 RMSE 为 17787.47，相较其他组合并不算低，暗示出单纯依赖教育和科研因素来预测 GDP 的效果并不理想。这表明在进行经济预测时，仅依靠教育和科研指标可能无法全面反映经济发展状况，而是需要与其他经济指标结合，形成更为综合的分析框架。

从现实合理性来看，粤港澳大湾区的经济结构以第三产业为主，这一点与图表中得出的结论高度一致，特别是在香港和深圳等城市，金融、科技和服务业的发达使得第三产业的增长成为推动经济发展的重要力量。此外，大湾区作为中国对外开放和国际贸易的重心，进出口总值的影响同样不可忽视。最后，粤港澳地区众多的高等教育和科研机构为区域的创新和经济增长提供了有力支持，进一步强调了教育和科研在推动经济发展中的重要性。

5.3 选择影响经济走势的重要因素

经过上面分别运用 RF 模型和 PCA 方法模型对各种单独因素的作用以及 RF 模型对于多因素共同联合作用的影响进行分析后，得到了各种因素对于大湾区经济发展的影响程度的量化指标。其中有一些因素单独作用于经济发展效果很好，也有另外一些因素结合其他元素的共同组合对粤港澳大湾区经济发展有强力的推进作用。

根据上面的可视化分析和量化数据的分析，得出了几项较为重要的影响因素：**人口总量，进出口货值，第二产业（产业结构），高等教育接受程度，科技**。其中评估的量化指标如下：

表 8　重要因素量化指标

因素	进出口货值	人口总量	第二产业	高等教育	科研机构数	技术合同成交额
量化指标	0.1698	0.1507	0.1505	0.0813	0.0435	0.0226

粤港澳大湾区吸引了大量劳动力和人才，形成了丰富的人力资源。这一人口红利不

仅增强了消费需求，促进了市场的活跃度，也为各行业提供了所需的劳动力，推动了经济的多元化发展。同时，年轻人口的涌入还带来了创新精神和创业机会，为经济转型注入了新的活力。其次，进出口货值反映了区域的贸易活跃程度。作为中国重要的国际贸易枢纽，粤港澳大湾区凭借其优越的地理位置和完善的物流网络，促进了与全球市场的联系。进出口的增长不仅提升了地方财政收入，还带动了相关产业的发展，推动了经济的持续扩张。

大湾区的总体产业结构以第三产业为主，金融、科技和服务业的快速发展为区域经济提供了新的增长动力。同时，虽然珠三角地区的制造业基础雄厚，以高科技和传统产业并存的特色，成为区域经济的重要支柱之一，第二产业的转型升级也需要进一步加强，为经济的可持续发展奠定了基础。

高等教育的接受程度直接关系到人才的培养和经济的可持续发展。粤港澳大湾区内有多所知名高等院校，培养了大量专业技术人才和管理人才。这些高素质的人力资源为区域内的科技创新和产业升级提供了强有力的支撑，推动了经济结构的优化。科技作为经济发展的核心驱动力，在粤港澳大湾区的创新和发展中起到了重要作用。区域内对科技研发的重视和投资不断加大，推动了科技成果的转化与应用。这不仅提升了企业的竞争力，还催生了如人工智能、生物科技等新兴产业，为经济发展注入了新的活力。

六、 问题二的模型建立与求解

6.1 CNN 与 LSTM 模型结合构建经济预测模型

由于任务一选取了**人口，进出口货值，第二产业（产业结构），高等教育接受程度，科技**作为影响粤港澳大湾区经济发展重要的特征，根据提取的主要因素，建立经济预测的数学模型，预测未来 5-10 年的粤港澳大湾区的经济走势。本文建模的思路将结合卷积神经网络 (CNN) 和长短期记忆网络 (LSTM) 两种模型各自的优势，完成对粤港澳大湾区经济预测的模型设计。

6.1.1 卷积神经网络架构

卷积神经网络可从数据中提取局部特征以及数据中隐藏的局部规律，在处理序列类型的数据时表现优异，适合用于回归预测的任务处理。在时间序列中，CNN 可以有效识别数据中的局部模式和特征。由于粤港澳地区的历年数据属于时间序列数据类型，因此也可运用于卷积神经网络的模型中。

卷积神经网络的主要部件为卷积层，卷积层用于提取时间序列数据中的特性以及模式。例如发掘在科技因素方面，科研机构以及高等教育提供的人才储备对于粤港澳地区经济发展的潜在影响。然后通过提起到的特征信息进一步传递到下一层卷积层中进一步提取更加深层的特征与影响。使用一维卷积层（Cov1d）对每个时间窗口进行卷

积操作，提取局部特征。这些卷积层可以与激活函数（ReLU）和池化层 (maxpool1d) 组合，减少了维度并提高特征的抽象能力。通过卷积和池化操作，生成特征图，代表了输入时间序列中重要的局部模式。

表 9　CNN 结构参数表

参数名称	维度
conv1.weight	torch.Size([512, 8, 1])
conv1.bias	torch.Size([512])
bn1.weight	torch.Size([512])
bn1.bias	torch.Size([512])
conv2.weight	torch.Size([1024, 512, 1])
conv2.bias	torch.Size([1024])
bn2.weight	torch.Size([1024])
bn2.bias	torch.Size([1024])
conv3.weight	torch.Size([2048, 1024, 1])
conv3.bias	torch.Size([2048])
bn3.weight	torch.Size([2048])
bn3.bias	torch.Size([2048])
conv4.weight	torch.Size([4056, 2048, 1])
conv4.bias	torch.Size([4056])
bn4.weight	torch.Size([4056])
bn4.bias	torch.Size([4056])
fc1.weight	torch.Size([100, 8112])
fc1.bias	torch.Size([100])
fc2.weight	torch.Size([1, 100])
fc2.bias	torch.Size([1])

卷积神经网络模型的参数架构，通过多个卷积层的堆叠构建出提取复杂特征的模型工具。

通过上述卷积神经网络模型的构建，可以提取到时间序列数据中的特征作为 LSTM 的输入。从原数据中提取到的中级特征将作为下一层 LSTM 模型部分的输入。

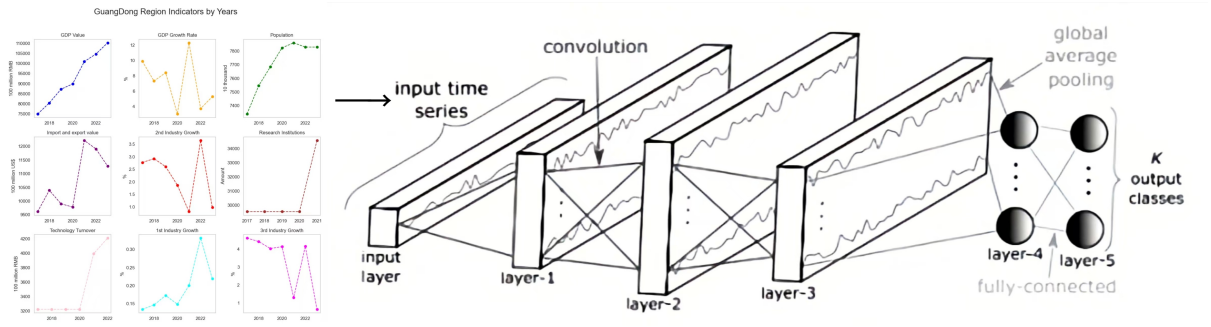


图 5　基于卷积神经网络的粤港澳大湾区经济指标时间序列分析

6.1.2 长短期记忆网络

通过构建卷积神经网络（CNN）模型，我们能够有效提取粤港澳大湾区经济时序数据中的复杂特征。CNN 的多层卷积结构利用局部感受野和权重共享机制，自动识别输入数据的特征，从而捕捉到细致的特征表示。这些提取的特征可以作为长短期记忆网络（LSTM）的输入，LSTM 通过其特有的门控机制，能够处理和记忆长期依赖的信息。

将 CNN 提取的特征输入到 LSTM 中，模型不仅具备对当前经济状况的理解能力，还能利用历史经济数据来增强对未来经济趋势预测的准确性。这种特征融合的方法结合了 CNN 在特征提取方面的优势和 LSTM 在处理时间序列数据中的长期依赖性能力，使整体模型能够更好地捕捉粤港澳大湾区经济动态变化和潜在模式，从而在经济预测任务中展现出良好的性能。

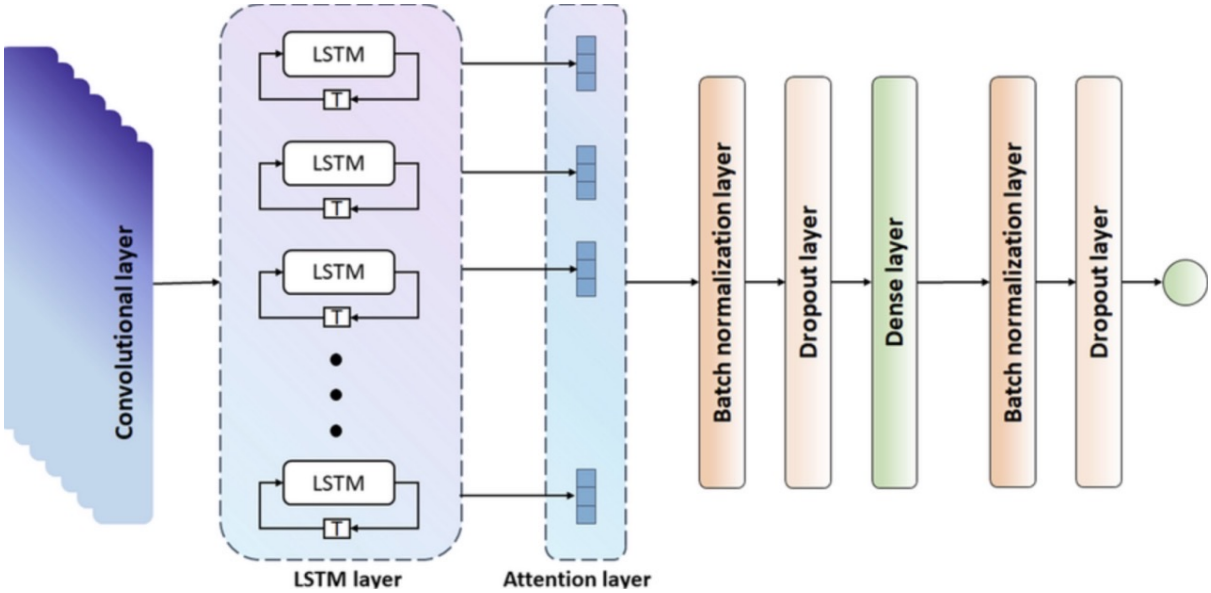


图 6　结构图

表 10　LSTM 层与全连接层参数维度

参数名称	维度
lstm.weight_ih_l0	torch.Size([400, 9])
lstm.weight_hh_l0	torch.Size([400, 100])
lstm.bias_ih_l0	torch.Size([400])
lstm.bias_hh_l0	torch.Size([400])
fc.weight	torch.Size([1, 100])
fc.bias	torch.Size([1])

6.1.3 现实中随机噪音的影响因素

由于现实中存在不稳定性因素，如自然灾害（如台风、洪水）、政策变化（如税收政策调整）、经济波动（如国际市场危机）、社会动荡（如抗议活动）以及疫情爆发等情况，会对影响粤港澳大湾区经济发展的各种因素产生一定的不确定性影响。这些因素可能导致市场信心下降、投资减少以及供应链中断，从而影响整体经济表现。因此我们需要在预测模型中添加一定的随机噪声，以增强模型在不确定性环境下的表达能力和适应性。

最终，通过卷积神经网络 CNN 与长短期记忆网络 LSTM 模型的创新结合，成功地利用了粤港澳大湾区建立以来历年的统计数据，结合任务一中选取出来的重要因素，并且在上面第三部分考虑了现实中随机噪声的影响因素，最终完成了对经济预测模型的构建。

本研究采用结合卷积神经网络（CNN）和长短期记忆网络（LSTM）的方法进行时间序列分析。我们首先对数据进行标准化和窗口划分，然后使用一维卷积层提取局部特征，接着将特征输入到 LSTM 层以捕捉时间依赖性。实验结果表明，该方法在预测精度上显著优于单独使用 CNN 或 LSTM 的模型，并且添加了随机噪声，增强模型在不确定性环境下的表达能力和适应性。

运用上面经济预测模型，预测出粤港澳大湾区在未来 10 年内的 GDP 增长幅度数值如下：

表 11　粤港澳大湾区未来 10 年内的 GDP 增长幅度数值预测

年份	2024	2025	2026	2027	2028	2029	2030	2031	2032	2033
GDP 增长率	-0.8362	1.9082	3.3855	-3.0000	-3.0000	0.4566	3.6987	4.2741	2.1761	3.2111

6.2 经济走势分析与经济计划制定

6.2.1 经济走势分析

粤港澳大湾区的经济走势在未来几年的预测中显示出明显的波动性，这一现象可以归因于多个复杂的内外部因素。

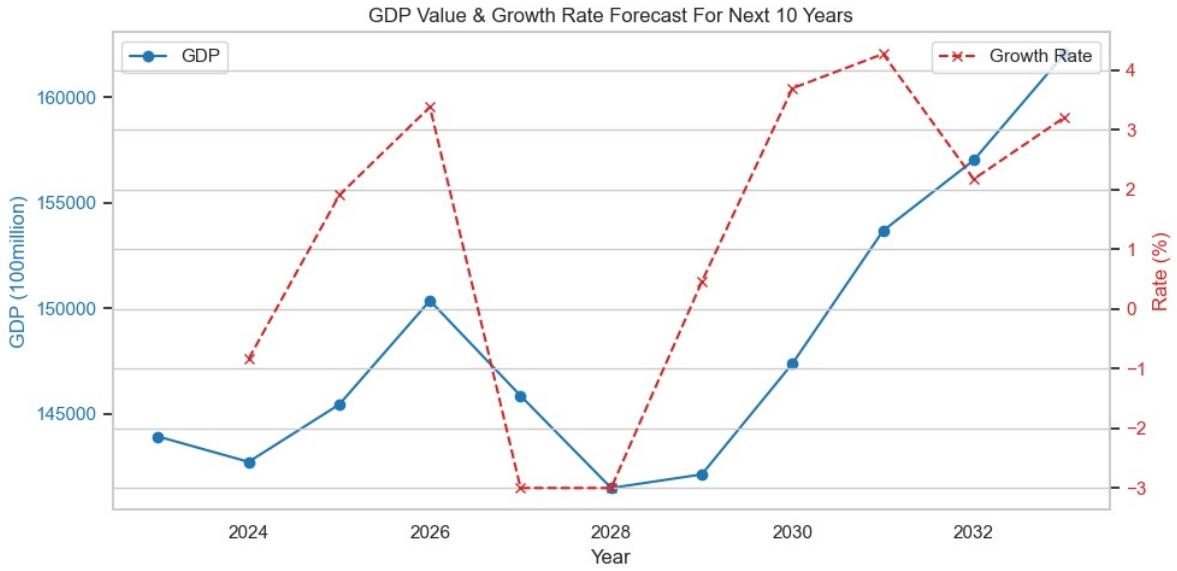


图 7　粤港澳大湾区未来 10 年的经济发展走势可视化

经济下行调整阶段：根据图 7，2024 年经济预计将出现轻微的负增长（-0.8362%），这可能是由于国内外经济环境的不确定性以及周期性调整的影响，可能会受到全球经济放缓、贸易摩擦或内部结构性问题的挑战。然而，进入 2025 年，湾区经济有望逐步恢复，预计增长率为 1.9082%，表明在政策支持、经济复苏以及技术创新推动下，经济增速开始回升。

经济稳步增长阶段：到 2026 年，经济增长率预计达到 3.3855%，进一步表明湾区经济正在步入正轨，尤其是高技术产业、金融科技和国际贸易等领域的复苏可能会成为经济增长的重要驱动力。

经济下行阶段：然而，2027 年和 2028 年预计会出现较大压力，经济增长率为-3.0000%，这可能是由于全球经济形势不利、市场需求疲软、以及区域内经济转型过程中的阵痛，导致经济暂时出现下行。

经济持续增长阶段：从 2029 年开始，经济开始恢复增长，预计增长率为 0.4566%，虽然回升幅度较为缓慢，但这反映出湾区经济开始逐步适应市场变化，并展现出一定的复苏迹象。到 2030 年，经济增长率将显著回升至 3.6987%，预计将进入一个较为强劲的增长周期，这可能得益于技术创新、国际市场回暖以及政策引导等因素。

经济平稳发展阶段：2031 年，经济继续稳步增长，预计增长率为 4.2741%，此时湾

区经济将可能处于一个更加健康和稳定的增长阶段，企业创新、区域协同及资本市场的成熟可能成为推动增长的主要动力。而到 2032 年，增长率将趋于平稳，预计为 2.1761%，这表明经济进入相对成熟期，增速放缓，但仍然保持稳定。

到 2033 年，经济增长率预计为 3.2111%，湾区经济将继续维持稳定增长，虽然增速较为平稳，但表明经济在经历了多年的调整和转型后，已进入一个更加可持续、稳定的增长阶段。

在此期间，全球经济环境的不确定性，特别是俄乌战争所引发的地缘政治紧张局势，对能源和原材料市场造成了深远影响。能源价格的急剧上涨不仅增加了企业的生产成本，也抑制了消费者的支出能力，从而对整体经济增长产生了负面影响。此外，西方国家对中国实施的多项政策制裁与贸易壁垒，尤其是在高科技领域，进一步限制了外资的流入与技术转移，减缓了大湾区的创新步伐和经济活力。关税争端也加剧了大湾区经济发展的不确定性。高关税政策导致进口成本上升，影响了企业的利润空间，并削弱了出口竞争力。这种情况使得依赖外贸的行业面临挑战，进而影响到整体经济增长。再者，尽管新冠疫情的影响逐渐减弱，但经济恢复的过程中，消费和投资信心仍然受到制约。旅游和服务行业的复苏进程缓慢，导致这些领域的经济活动未能完全恢复至疫情前的水平。

同时，政府在应对经济下行压力时可能采取的刺激政策或财政调整也会对经济走势产生影响。这些短期措施虽然可以在一定程度上缓解经济困境，但若未能实现可持续增长，长远来看可能会引发更大的财政压力。同时，随着大湾区经济结构的转型，内需的增长潜力逐渐显现，创新驱动、产业结构调整和区域协同合作将成为推动湾区经济长远发展的关键因素。然而，如果消费信心不足，消费需求无法有效释放，也将拖累经济的进一步发展。

6.2.2 制定政策计划

针对未来 5-10 年可能出现的情况，为了促进粤港澳大湾区的快速发展，制定以下的相关策略：

一、 城市分工互补联动，推进区域协调发展。坚持极点带动、轴带支撑、辐射周边，推动大中小城市合理分工、功能互补，进一步提高区域发展协调性，促进城乡融合发展，构建结构科学、集约高效的大湾区发展格局。

二、 深化供给侧改革，培育新兴产业，升级传统行业。深化供给侧结构性改革，着力培育发展新产业、新业态、新模式，支持传统产业改造升级，加快发展先进制造业和现代服务业，改善产业结构比例，促进产业优势互补、紧密协作、联动发展，培育若干世界级产业集群。

三、 强化科技创新，推动技术攻关与成果转化。加大科技发展支持力度，坚持科技创新的战略定位，推动关键核心技术攻关，鼓励科研机构、高校与企业协同创新，构建

开放、共享的科技创新体系。通过政策引导和资金支持，加快成果转化应用，推动科技成果向现实生产力转化，提高区域科技创新能力和经济发展的质量。

四、 优化营商环境，推动对外贸易多元化。在全球竞争加剧、市场不稳定因素增加的背景下，粤港澳大湾区需通过降低企业税负、简化行政流程、优化跨境金融服务，吸引外资和国际人才。同时，拓宽对外贸易市场，深化与“一带一路”沿线国家的合作，减少对单一市场的依赖。通过自贸区和特殊经济区的制度创新，推动金融市场开放，支持企业通过展会、品牌推广等方式进入海外市场，增强外贸抗风险能力与国际吸引力。

五、 提升绿色与低碳经济发展。在“双碳”目标的指引下，大湾区应加快推动绿色发展，发展低碳、高效的现代能源体系，减少对传统能源的依赖。同时，鼓励绿色技术的研发和应用，促进传统制造业的绿色转型。设立绿色基金，支持清洁能源和可持续基础设施项目，为经济的长远发展奠定基础。

六、 加快跨境基础设施建设与一体化发展。为提升大湾区内地与港澳的互联互通，需加快跨境基础设施的建设，尤其是交通、物流、信息网络等方面的投资。推动“一小时生活圈”建设，减少湾区内城市之间的通勤时间，提升区域内部的资源流通和经济活力。同时，加强税务和金融制度的一体化，进一步便利资金、人员和信息的自由流动。

七、 问题三的模型建立与求解

7.1 纽约湾区经济因素评估

纽约湾区作为全球重要的经济枢纽，展现出其多元化和高度国际化的经济结构。该地区的经济支柱涵盖了科技、金融、文化教育、制造业和零售等多个领域。作为全球金融中心之一，纽约湾区在全球资本市场中占据着举足轻重的地位，推动了跨国资本流动和金融创新。此外，纽约湾区凭借其卓越的科技创新生态系统，吸引了众多国际领先的科技公司、初创企业以及风险投资者，成为全球科技创新的核心区域之一，持续为区域 GDP 的增长注入活力。

同时，纽约湾区是全球顶尖大学和科研机构的集聚地，汇聚了诸多世界一流的教育和研究资源。这些高等院校和研究中心在各学科领域尤其是科技、工程、医学等方面，培养了大量创新型人才，为区域科技进步提供了源源不断的智力支持。该地区还拥有众多领先的创新实验室和科技研发中心，成为全球创新和技术发展的重要源泉。

7.1.1 经济因素的独立影响

我们需要对纽约湾区进行分析，分析挖掘出该湾区独特的经济发展特点，探索其中多种因素对于经济发展的影响，并且运用前面用于分析粤港澳大湾区的两种子模型

CNN 与 LSTM 结合的创新模型——CNNLSTM，利用 CNN 多核卷积层堆叠，学习多元原始数据的变量间水平关系，提取到各种影响因素的特征，再利用 LSTM 提取对于时间的关系，完善时间序列数据的分析预测结果。

首先量化以及可视化分析纽约湾区的经济发展特点，即发掘该地区的各种经济影响因子对纽约湾区经济发展的影响效果与重要程度。通过拉格朗日插值的数学方法对纽约湾区数据中缺失值进行填充后，运用随机森林模型以及改良主成分分析法评估各因素对经济的影响，并且再运用随机森林模型对多因素组合的共同作用对纽约湾区经济影响程度。

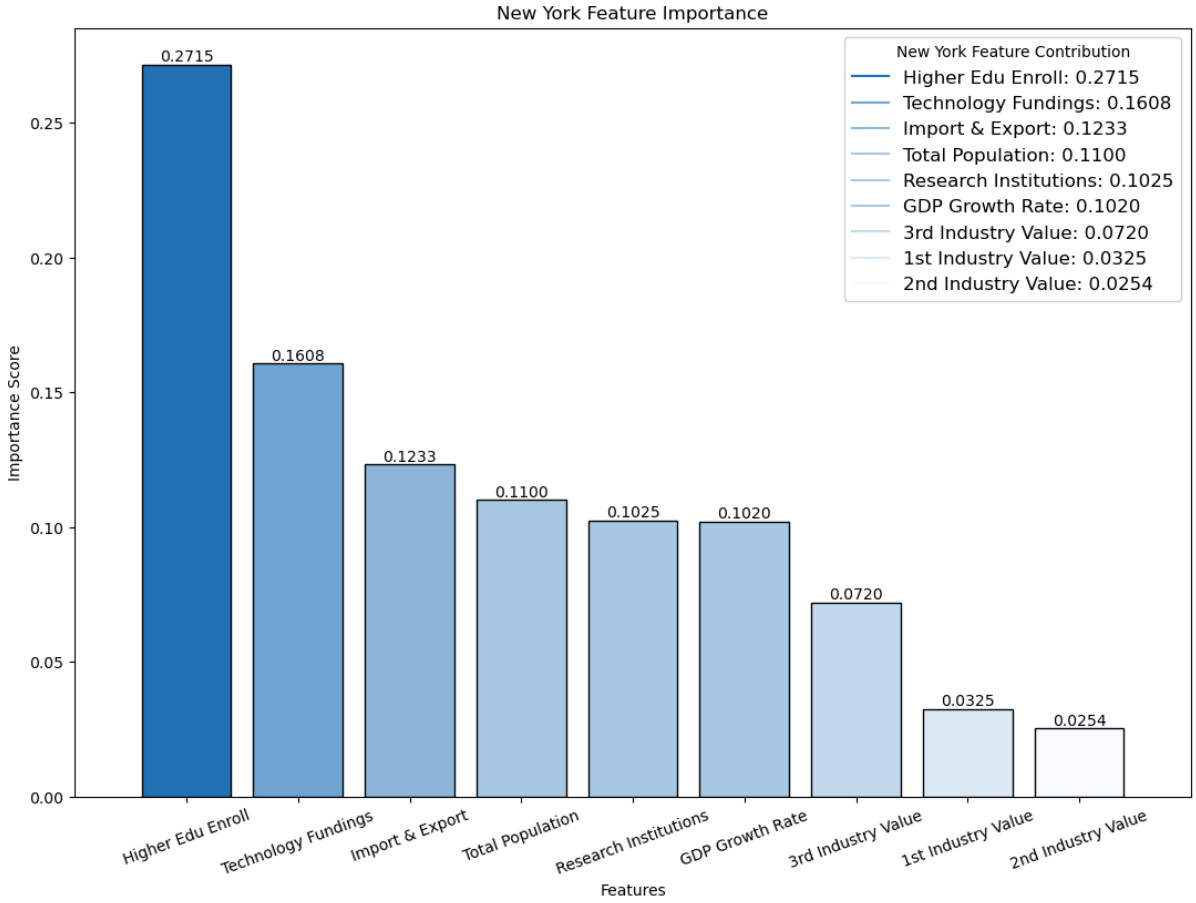


图 8　纽约湾区各个单因素对经济的影响程度

根据图 8，纽约湾区的经济增长受多个因素的推动，尤其是高等教育和科技领域。高等教育的贡献最大，达到 27.15%，这表明纽约湾区的教育体系对人才的培养和技术创新具有重要作用。哥伦比亚大学、纽约大学等世界一流学府培养了大量的科技、金融和文化领域的专业人才，推动了各行业的发展。紧随其后的是科技资金的投入，占比 16.08%，科技行业的发展，特别是在人工智能、金融科技和生物医药等领域的投资，已成为纽约湾区经济增长的关键驱动力。湾区作为全球科技创新中心，吸引了大量的企业和初创公司，推动了技术的快速发展和产业的升级。

此外，进出口贸易对湾区经济的影响也不可忽视，贡献为 12.33%。纽约港和新泽西港是美国最繁忙的港口之一，这为纽约湾区提供了重要的国际贸易和物流通道。与此同时，研究机构和总人口对经济的推动作用分别为 10.25% 和 11%，表明了创新生态系统和劳动力资源对经济增长的支持。虽然第二产业和第一产业对经济的贡献相对较小，分别为 2.54% 和 3.25%，但整体来看，纽约湾区的经济结构已经转向以服务业和科技创新为主，这使得其经济增速保持了较强的竞争力和活力。

由各个单因素对纽约湾区经济的影响程度可知，每一个因素都在其所在的特定领域发挥着至关重要的作用，且彼此之间相互促进、相互依存，共同推动纽约湾区经济的多元化和持续增长。

7.1.2 经济因素的协同影响

经济系统是高度复杂且相互依存的，多个因素往往共同作用并产生叠加效应。例如，科技创新与金融市场的互动、教育与人才流动、制造业与出口贸易的联动，都在推动区域经济增长的同时，可能会相互促进或制约。因此，单一因素的分析可能无法全面揭示其对经济的真实影响。接下来需要分析这些多种经济影响因素的共同作用。

通过多种因素特征组合和随机森林模型的评估，探索了特征对 GDP 预测的作用，得到各种可能的因素特征组合对纽约湾区经济发展的作用影响如下：

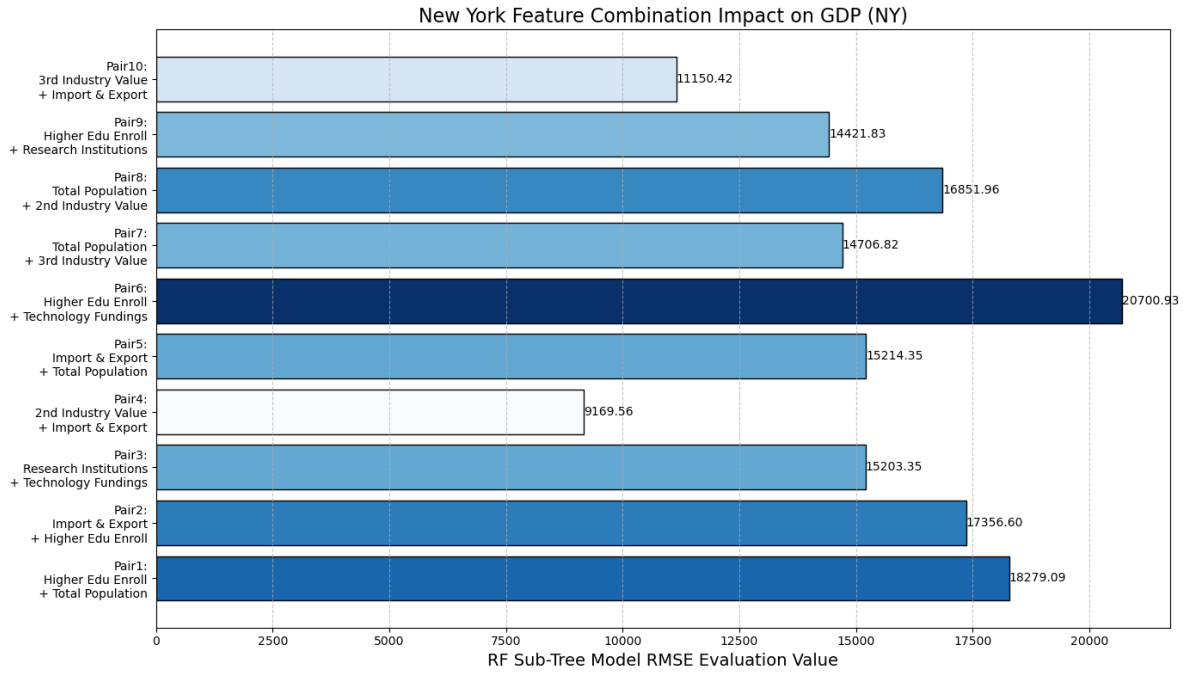


图 9　纽约湾区不同特征组合的联合作用对经济发展的影响程度

纽约湾区的经济发展受到了多个因素的相互作用，其中高等教育入学率与技术资助的联合作用尤为突出。纽约湾区拥有世界一流的高等教育机构，如斯坦福大学和加

州大学伯克利分校，这些学校培养了大量科技、工程、金融等领域的高端人才。而技术资助（如硅谷的风险投资和政府的科研资金）为这些创新人才提供了资金支持，推动了从学术研究到商业化应用的转化过程，促进了高科技产业（如信息技术、人工智能、生命科学等）的迅猛发展。这种教育和技术资金的结合形成了一个强大的创新生态系统，支撑了湾区的经济繁荣。

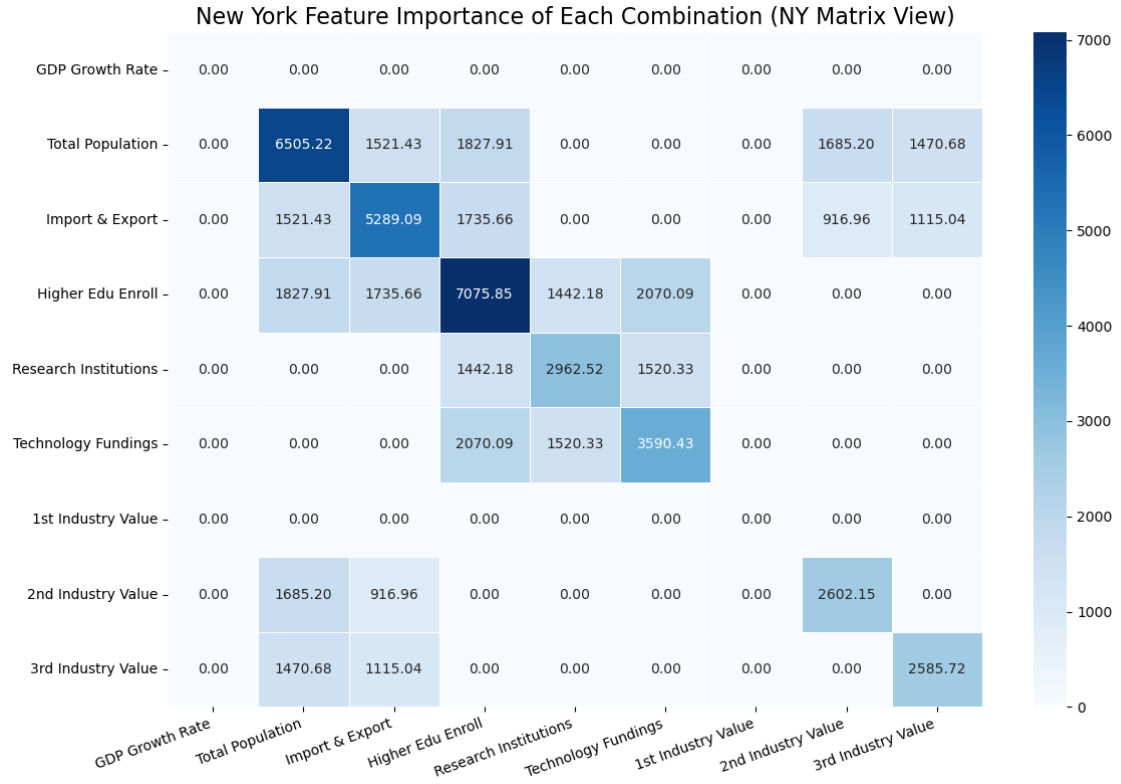


图 10　热力图可视化各因素间联合作用对经济发展的影响程度

此外，进出口与高等教育入学率的联合作用也在推动区域经济全球化方面发挥了重要作用。纽约湾区作为全球科技中心，不仅通过科技产品和服务参与国际贸易，还吸引了大量跨国企业和外资。高等教育为进出口活动提供了专业技能和国际视野的人才，提升了湾区在全球市场中的竞争力。高等教育入学率与总人口的联合作用则确保了区域内有足够数量且高素质的劳动力，为高科技企业和金融服务提供了所需的人才基础，进一步推动了湾区经济的持续增长和产业升级。

7.2 纽约湾区经济预测

本题继续利用题目二中提及的 CNN 与 LSTM 两种模型的创新结合体来对纽约湾区的未来 10 年经济发展形势进行量化分析。通过创新性地结合卷积神经网络（CNN）与长短期记忆网络（LSTM）模型，利用纽约区自成立以来的历年统计数据，并结合上面 1.“分析纽约湾区的经济发展特点”内容中筛选出的关键因素。在选择了关键影响因

子的基础上，本模型还充分考虑现实中随机噪声的影响因素，从而实现了更为精准和鲁棒的预测。

运用上面 CNN 与 LSTM 结合的经济预测模型，预测出纽约湾区在未来 10 年内的 GDP 增长幅度数值如下：

表 12　纽约湾区未来 10 年内的 GDP 增长幅度数值预测

年份	2024	2025	2026	2027	2028	2029	2030	2031	2032	2033
GDP 增长率	-0.9337	2.0758	3.3227	-3.0000	-3.0000	0.0892	3.7880	4.3120	2.0971	3.0653

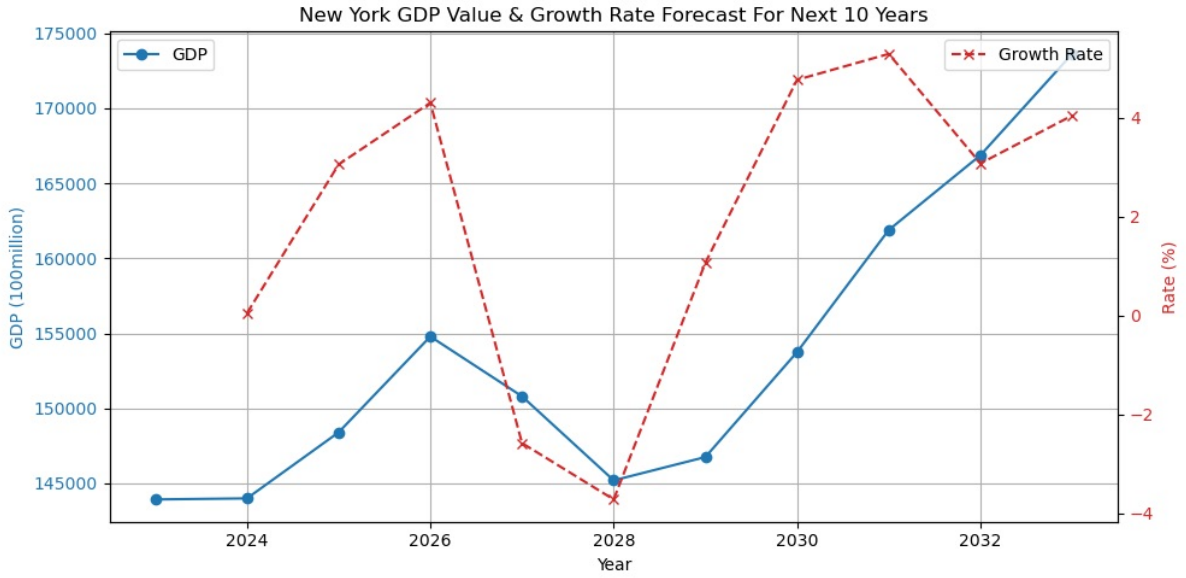


图 11　纽约湾区未来 10 年内的 GDP 增长幅度数值预测

纽约湾区未来十年经济增长率变化的趋势大致呈现出三个阶段：2024-2026 年上升阶段、2027-2029 年下降阶段、以及 2030-2035 年快速增长阶段。

在 2024-2026 年上升阶段，科技创新特别是人工智能、区块链和绿色能源等新兴行业的快速发展，将成为推动经济增长的主要动力。作为全球科技创新中心，湾区拥有强大的技术研发基础和创新能力，尤其在金融科技和高端技术领域。高等教育、科研机构的持续发展以及科技资金的注入将进一步激发新技术的突破和商业化应用，推动经济增长。在这一阶段，科技和金融创新成为湾区经济发展的主要引擎，带动了就业增长和产业转型，表现为经济的积极波动。

进入 2027-2029 年下降阶段，湾区经济可能会受到全球经济周期和外部冲击的影响，表现出一定的下行压力。传统金融行业的衰退、全球贸易环境的变化以及政策调整等因素，可能导致一些传统产业面临结构性调整。例如，金融危机后的历史经验表明，

传统金融业务可能会经历裁员、重组和自动化过程，这不仅影响经济增长，还可能导致低技能劳动力的失业和岗位流失。此外，全球经济放缓也可能影响湾区的出口和国际投资。整体来看，经济增长放缓，部分行业和劳动力市场受到冲击，可能经历一定的衰退。

在 2030-2035 年快速增长阶段，随着前期的经济结构调整和行业转型完成，湾区的经济将迎来新的增长周期。科技和创新型产业的成熟，尤其是在金融科技、人工智能等领域，将再次推动经济的快速增长。此时，劳动力市场经过再培训和产业优化后，将更加符合新经济的需求。高技能劳动力和创新型企业的需求增加，推动了就业市场的复苏。湾区将通过产业升级和创新驱动，克服了前期的经济下行压力，迎来了强劲的增长，成为全球经济的重要引擎之一。

7.3 纽约湾区经济预测

7.3.1 差异性分析

两个不同湾区支持经济增长的影响因素不同。从量化数据来看，将各种单独因素对预测结果的重要性进行量化打分，以下挑选了一些差异性较为明显的量化数据比较，并且经过进行一定数据处理后更加科学反映出两个湾区之间的量化差异性：

表 13　两个湾区的各因素评分与差值

影响因素重要性打分	第一产业	第三产业	科技产业与政府及企业资金支持	高等教育水平
粤港澳大湾区	0.1451	0.1105	0.1291	0.0813
纽约湾区	0.0325	0.1920	0.2208	0.2715
湾区影响因素的量化打分差值	-0.1126	0.0815	0.0971	0.1902

根据量化数据对粤港澳大湾区和纽约湾区的影响因素进行比较，可以看出两者的经济增长支持因素存在显著差异。粤港澳大湾区的主要经济驱动力体现在第二产业（如制造业、出口贸易）和劳动力市场，而在科技产业和高等教育方面的影响力相对较弱。具体来说，粤港澳大湾区的高等教育水平得分较低，仅为 0.0813，这表明该地区的科技创新和人才培养对经济的推动作用尚处于起步阶段，更多依赖传统产业、外贸以及国际贸易的创收。

该地区的制造业特别依赖外贸市场，且其外向型经济特征明显，国际贸易为经济发展提供了重要的支持。这一结构使得粤港澳大湾区能够在全球供应链中占据重要地位，尤其是在电子信息、家电、机械设备等领域的出口贸易上表现突出。然而，随着全球市场的变化以及技术进步的加速，粤港澳大湾区面临着产业升级的压力。尤其是高技术产业的创新能力和本土人才的培养尚未达到与全球竞争力相匹配的水平，这使得该地

区的科技创新能力相较于一些发达经济体有所欠缺。此外，粤港澳大湾区的劳动力市场虽然庞大且相对灵活，但受限于产业结构的单一性，劳动力的流动性和技术提升的空间也受到一定限制。

与此不同，纽约湾区的经济增长则深受科技产业和高等教育的强力支持。纽约湾区的高等教育得分为 0.2715，科技产业得分为 0.2208，远高于粤港澳大湾区。这反映出纽约湾区拥有强大的科技创新能力和高水平的教育体系，推动了高科技产业的蓬勃发展，尤其是在人工智能、金融科技等领域。纽约湾区的多所世界顶级大学和研究机构为其提供了丰厚的人才资源和创新支持，吸引了全球一流的科研团队和企业，这使得该地区成为全球科技创新的中心之一。

高科技产业的快速发展不仅促进了信息技术、人工智能、生命科学等领域的技术进步，也推动了金融科技、绿色能源等新兴产业的崛起。这些新兴行业对经济的贡献逐渐超过了传统产业，成为纽约湾区增长的主要驱动力。特别是在人工智能和大数据领域，纽约湾区的创新能力和技术领先性使其在全球市场中占据了重要位置，吸引了大量的投资和创业公司，进一步推动了经济的快速增长。同时，纽约湾区的第一产业（如农业和采矿业）和传统第三产业（如传统金融业）影响力逐渐减少。传统金融业曾是纽约湾区经济的重要支柱，但随着科技产业的发展，尤其是金融科技的崛起，传统银行和投资机构的市场份额受到了挑战。高科技公司和金融科技平台的创新技术为金融服务行业注入了新的活力，使得金融服务更加高效、透明，逐渐替代了传统金融模式。这一转型趋势不仅改变了纽约湾区的经济结构，也提升了该地区的全球竞争力。

这种差异表明，粤港澳大湾区目前更依赖于传统产业和出口，而纽约湾区则主要依靠科技和教育的强大驱动力，推动经济向更加创新和高附加值的方向发展。

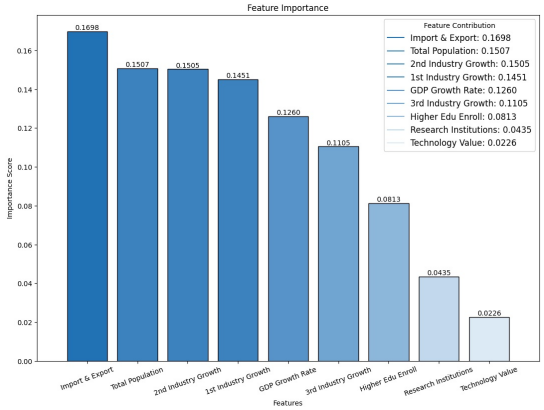


图 12　粤港澳大湾区

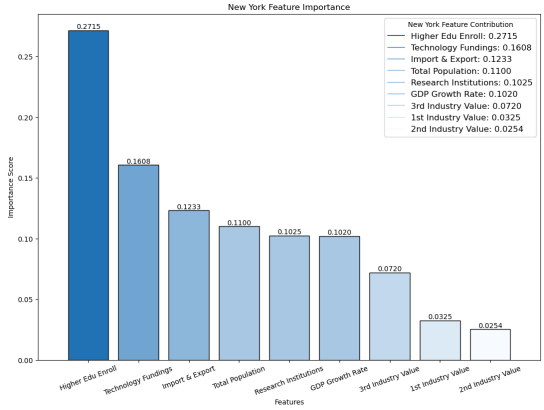


图 13　纽约湾区

7.3.2 相似性分析

从**经济发展影响因子相似性**的角度分析，尽管粤港澳大湾区和纽约湾区在经济增长的关键因素上存在明显差异，但两者也有一些相似之处，特别是在进出口和人口数

据方面。

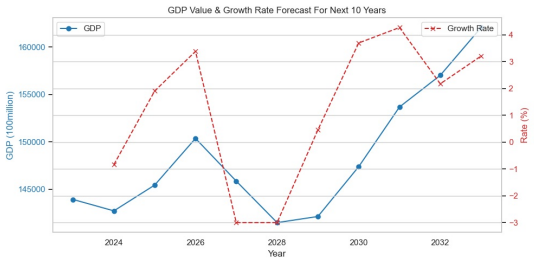
得益于两地的地理优势以及开放市场的政策，进出口在两大湾区的经济发展中都占据着至关重要的地位。粤港澳大湾区作为全球重要的贸易和物流中心，进出口贸易推动了区域经济的快速发展；同样，纽约湾区作为美国与全球经济联系的重要纽带，进出口贸易也是其经济增长的一个关键因素。

人口数据在两地的经济发展中也扮演着重要角色。两大湾区拥有庞大且不断增长的人口，这不仅促进了市场需求和消费潜力的释放，还直接影响劳动力市场的活力、社会结构的变化以及基础设施建设的需求。人口的增长为创新型产业的崛起提供了源源不断的劳动力，并通过推动技术进步和资源配置优化，进一步促进了两地经济的繁荣。因此，尽管经济驱动力有所不同，但在进出口和人口数据的影响下，粤港澳大湾区与纽约湾区在多个方面都展现出了相似的发展趋势。

从**经济发展趋势相似性**的角度分析，纽约湾区和粤港澳大湾区的经济数据展现出明显的相似性，尤其是在经济增长的波动性、科技创新驱动以及产业转型过程中。

从图 14 中可以得出，两地在未来的经济增长率呈现出一定的波动性，在全球经济环境、政策调整及市场需求变化的影响下，短期内可能出现负增长，如 2024 年粤港澳大湾区的轻微负增长和纽约湾区的上升阶段。随着科技创新的推动，尤其是在人工智能、金融科技和绿色能源领域的快速发展，两个地区在 2025 至 2026 年都表现出增长的回升，经济逐渐恢复。这一趋势反映了技术和创新对两地经济的强大驱动力。第二，进入 2027 至 2029 年，经济增速的下行是两地经济数据中的共同特征，反映了产业结构调整和外部经济压力的影响，传统产业面临转型和衰退。尽管如此，两个地区的数据也表明，在经过经济调整和产业优化后，至 2030 年，经济将重新迎来增长周期。纽约湾区和粤港澳大湾区都显示出在经济恢复过程中，科技创新和新兴产业的成熟以及劳动力市场的再培训推动了经济的强劲复苏，进入快速增长阶段。

因此，两个地区的经济走势和数据表明，它们在周期性波动、创新驱动及转型期的挑战中展现出类似的发展轨迹。这也在一定程度上反映了全球经济的这也在一定程度上反映了全球经济的相似动态，尤其是大湾区和湾区作为全球经济的重要组成部分，它们的发展不仅受自身产业结构调整的影响，也受到全球经济周期、技术变革和国际市场波动的共同作用。随着科技创新的加速，全球经济的转型也逐步影响到这些区域的经济表现，推动了新兴产业的发展并加速传统行业的重组。两地的经济模式表明，全球化背景下的经济互动性使得湾区区域经济走势趋于同步，反映出全球经济复苏与增长的新趋势。



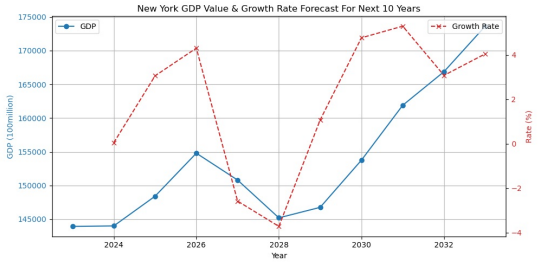


图 14　不同湾区间经济发展形势预测：左图表示粤港澳大湾区，右图表示纽约湾区。

八、 问题四经济预测简报

粤港澳大湾区经济预测简报

一、建模依据

本次建模分析基于 2017 年至 2023 年的历史数据，涵盖了包括 GDP、GDP 增长率、人口总量、进出口货值、科技研究机构数量等经济指标。为了全面评估湾区未来 5 至 10 年的经济走势，我们使用了随机森林模型和主成分分析来确定各经济因素的相对重要性，并结合卷积神经网络和长短期记忆网络模型，构建出精准的经济预测模型。

二、预测结果

预测结果显示，粤港澳大湾区经济在未来将面临一定波动，特别是 2027 年、2028 年可能会出现负增长。然而，从 2029 年开始，经济逐渐恢复，并进入稳步增长期。2024 年经济预计出现轻微负增长（-0.8362%）。到 2025 年，预计增长率为 1.9082%，经济增速开始回升。2026 年增长率为 3.3855%。然而，2027 至 2028 年可能由于全球局势、经济转型过程中的阵痛等面临较大压力。从 2029 年起，经济预计开始回升，并预计在 2030 年和 2031 年达到 3.6987% 和 4.2741% 的强劲增长。2032 年开始经济增速放缓，这表明了大湾区经历了调整和转型后，可能已进入可持续、稳定的增长阶段。

三、政策建言

面对世界多极化、经济全球化、社会信息化、文化多样化的机遇与世界局势不稳定、生态压力增大、人口红利逐步消退等挑战，可制定对应发展政策：

一、 城市分工互补联动，推进区域协调发展。加快发展先进制造业和现代服务业，改善产业结构比例，促进产业优势互补、紧密协作、联动发展，培育若干世界级产业集群。

二、 强化科技创新，推动技术攻关与成果转化。通过政策引导和资金支持，加快成果转化应用，推动科技成果向现实生产力转化，提高区域科技创新能力和经济发展的质量。

三、 加强对外贸易多元化，优化营商环境。面对全球市场不稳定因素和激烈竞争，粤港澳大湾区需拓宽外贸市场，深化与“一带一路”沿线国家的合作，降低对单一市场的依赖。同时，优化营商环境，通过自贸区和特殊经济区的制度创新，推动金融市场的开放与国际化，吸引国际资本，拓展新兴市场和区域性合作机会，增强抗风险能力。

四、 提升绿色与低碳经济发展。加快推动绿色发展，发展低碳、高效的现代能源体系，减少对传统能源的依赖。同时，鼓励绿色技术的研发和应用，促进传统制造业的绿色转型，为经济的长远发展奠定基础。

五、 加快跨境基础设施建设与一体化发展。为提升大湾区内地与港澳的互联互通，需加快跨境基础设施的建设。同时，加强税务和金融制度的一体化，进一步便利资金、人员和信息的自由流动。

在党中央的坚强领导下，粤港澳大湾区未来将进一步发挥自身区位优势和政策红利，全面推进区域高质量发展。通过各方共同努力，粤港澳大湾区必将迈向更高层次、更高水平的发展目标，为国家现代化建设作出更大贡献。

参考文献

[1] 郭跃文, 王廷惠, 向晓梅. 广东经济社会形势分析与预测（2024）[M]. 北京: 社会科学文献出版社, 2024.

[2] ABDI H, WILLIAMS L J. Principal component analysis[J]. Wiley Interdisciplinary Reviews: Computational Statistics, 2010, 2(4):433-459.

[3] GREGORUTTI B, MICHEL B, SAINT-PIERRE P. Correlation and variable importance in random forests[J]. Statistics and Computing, 2017, 27:659-678.

[4] JIEHAN J, LIU Y, MURONG M, 等. 粤港澳大湾区战略耦合模式差异与区域协同[J/OL]. 2022. DOI: 10.13284/j.cnki.rddl.003436.

[5] JIN X, YU X, WANG X, et al. Prediction for time series with cnn and lstm[C]// Proceedings of the 11th International Conference on Modelling, Identification and Control (ICMIC2019). [S.l.]: Springer Singapore, 2020: 631-641.

[6] LIVIERIS I E, PINTELAS E, PINTELAS P. A cnn–lstm model for gold price time-series forecasting[J]. Neural Computing and Applications, 2020, 32:17351-17360.

[7] SHUMWAY R H, STOFFER D S. Arima models[M]. [S.l.: s.n.], 2017: 75-163.

[8] WEYTJENS H, DE WEERDT J. Process outcome prediction: Cnn vs. lstm (with attention)[C]//Business Process Management Workshops: BPM 2020 International Workshops, Seville, Spain, September 13–18, 2020, Revised Selected Papers 18. [S.l.]: Springer International Publishing, 2020: 321-333.

附录 A　文件列表

文件名	功能描述
粤港澳地区总统计.xlsx	粤港澳大湾区相关数据整理
纽约湾区总统计.xlsx	纽约湾区相关数据整理
粤港澳地区统计 __ 可视化 __.py	实现粤港澳地区数据的可视化展示
粤港澳地区统计 __ 预测模型 __.py	基于粤港澳地区统计数据的预测模型
粤港澳地区统计 __ 增长率图像 1__.py	绘制粤港澳地区增长率图像 1
粤港澳地区统计 __ 增长率图像 2__.py	绘制粤港澳地区增长率图像 2
粤港澳地区统计 __ 组合重要性 __.py	计算并展示粤港澳地区各因素的组合重要性
粤港澳地区统计 __PCA 单项重要性 __.py	使用 PCA 计算粤港澳地区各单项因素的重要性
粤港澳地区统计 __RF 单项重要性 __.py	使用随机森林算法计算粤港澳地区各单项因素的重要性
纽约地区统计 __ 预测模型 __.py	基于纽约湾区统计数据的预测模型
纽约湾区统计 __ 增长率图像 1__.py	绘制纽约湾区增长率图像 1
纽约湾区统计 __ 增长率图像 2__.py	绘制纽约湾区增长率图像 2
纽约湾区统计 __ 组合重要性 __.py	计算并展示纽约湾区各因素的组合重要性
纽约湾区统计 __ 组合重要性热力图 __.py	可视化纽约湾区组合重要性数据的热力图
纽约湾区统计 __PCA 单项重要性 __.py	使用 PCA 计算纽约湾区各单项因素的重要性
纽约湾区统计 __RF 单项重要性 __.py	使用随机森林算法计算纽约湾区各单项因素的重要性

附录 B　代码

粤港澳地区统计 __ 可视化 __.py

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# 创建 DataFrame（用提供的数据）
```

```
data = {
    '时间': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
    'GDP生产总值/亿人名币': [74953.26, 80440.72, 87213.05, 89850.38, 100914.59, 104681.82, 110214.71],
    'GDP生产总值增幅/%': [9.9071, 7.3211, 8.4190, 3.0240, 12.3140, 3.7330, 5.2854],
    '人口总量/万': [7338.07, 7545.46, 7683.95, 7823.54, 7860.60, 7829.43, np.nan],
    '进出口货值/亿美元': [9612.32, 10391.83, 9901.13, 9778.64, 12215.72, 11905.82, 11277.14],
    '科技研究机构数/个': [np.nan, np.nan, np.nan, 29548, 34570, np.nan, np.nan],
    '技术合同成交额/亿': [np.nan, np.nan, np.nan, 3223.3056, 3992.2389, 4208.6406, np.nan],
    '第一产业带动增长幅度/%': [0.134321, 0.146338, 0.172580, 0.148384, 0.200000, 0.331547, 0.218879],
    '第二产业带动增长幅度/%': [2.770637, 2.925126, 2.604306, 1.868097, 0.811439, 3.650093, 0.980169],
    '第三产业带动增长幅度/%': [4.614026, 4.421682, 4.034188, 4.134514, 1.300496, 4.157348, 0.654010]
}

df = pd.DataFrame(data)

# 设置时间为索引
df.set_index('时间', inplace=True)

# 使用线性插值填补缺失值
df['人口总量/万'] = df['人口总量/万'].interpolate(method='linear')
df['科技研究机构数/个'] = df['科技研究机构数/个'].interpolate(method='bfill')
df['技术合同成交额/亿'] = df['技术合同成交额/亿'].interpolate(method='bfill')

```

```
# 创建子图
fig, axs = plt.subplots(3, 3, figsize=(11,11))
fig.suptitle('GuangDong Region Indicators by Years', fontsize
   =20)

# 绘制每个指标
axs[0, 0].plot(df['GDP生产总值/亿人名币'], marker='o',
   linestyle='--', color='blue')
axs[0, 0].set_title('GDP Value')
axs[0, 0].set_ylabel('100 million RMB')
axs[0, 0].grid()

axs[0, 1].plot(df['GDP生产总值增幅/%'], marker='o', linestyle=
   '--', color='orange')
axs[0, 1].set_title('GDP Growth Rate')
axs[0, 1].set_ylabel('%')
axs[0, 1].grid()

axs[0, 2].plot(df['人口总量/万'], marker='o', linestyle='--',
   color='green')
axs[0, 2].set_title('Population')
axs[0, 2].set_ylabel('10 thousand')
axs[0, 2].grid()

axs[1, 0].plot(df['进出口货值/亿美元'], marker='o', linestyle=
   '--', color='purple')
axs[1, 0].set_title('Import and export value')
axs[1, 0].set_ylabel('100 million US$')
axs[1, 0].grid()

axs[1, 1].plot(df['第二产业带动增长幅度/%'], marker='o',
   linestyle='--', color='red')
axs[1, 1].set_title('2nd Industry Growth')
axs[1, 1].set_ylabel('%')
axs[1, 1].grid()
```

```
58
59 axs[1, 2].plot(df['科技研究机构数/个'], marker='o', linestyle=
      '--', color='brown')
60 axs[1, 2].set_title('Research Institutions')
61 axs[1, 2].set_ylabel('Amount')
62 axs[1, 2].grid()
63
64 axs[2, 0].plot(df['技术合同成交额/亿'], marker='o', linestyle=
      '--', color='pink')
65 axs[2, 0].set_title('Technology Turnover')
66 axs[2, 0].set_ylabel('100 million RMB')
67 axs[2, 0].grid()
68
69 axs[2, 1].plot(df['第一产业带动增长幅度/%'], marker='o',
      linestyle='--', color='cyan')
70 axs[2, 1].set_title('1st Industry Growth')
71 axs[2, 1].set_ylabel('%')
72 axs[2, 1].grid()
73
74 axs[2, 2].plot(df['第三产业带动增长幅度/%'], marker='o',
      linestyle='--', color='magenta')
75 axs[2, 2].set_title('3rd Industry Growth')
76 axs[2, 2].set_ylabel('%')
77 axs[2, 2].grid()
78
79
80 # 调整布局
81 plt.tight_layout(rect=[0, 0, 1, 0.96])
82 plt.savefig("Sub_plot.png")
83 plt.show()
```

粤港澳地区统计 __ 预测模型 __.py

```
1 import pandas as pd
2 import numpy as np
3 import torch
```

```
import torch.nn as nn
import torch.optim as optim
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

from tqdm import tqdm  # 导入 tqdm 库
import pandas as pd
import numpy as np
import torch
import torch.nn as nn
import torch.optim as optim
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

# 数据转成dict
data = {
    'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
    'GDP': [74953.26, 80440.72, 87213.05, 89850.38, 100914.59,
    104681.82, 110214.71],
    'GDP Growth Rate': [9.9071, 7.3211, 8.4190, 3.0240,
   12.3140, 3.7330, 5.2854],
    'Total Population': [7338.07, 7545.46, 7683.95, 7823.54,
   7860.60, 7829.43, np.nan],
    'Import & Export': [9612.32, 10391.83, 9901.13, 9778.64,
   12215.72, 11905.82, 11277.14],
    'Higher Edu Enroll': [np.nan, np.nan, np.nan, 223.2186,
   236.2014, 248.3100, np.nan],
    'Research Institutions': [np.nan, np.nan, np.nan, 29548,
   34570, np.nan, np.nan],
    'Technology Value': [np.nan, np.nan, np.nan, 3223.3056,
   3992.2389, 4208.6406, np.nan],
    '1st Industry Growth': [0.134321, 0.146338, 0.172580,
   0.148384, 0.200000, 0.331547, 0.218879],
    '2nd Industry Growth': [2.770637, 2.925126, 2.604306,
   1.868097, 0.811439, 3.650093, 0.980169],
```

```
    '3rd Industry Growth': [4.614026, 4.421682, 4.034188, 4.134514, 1.300496, 4.157348, 0.654010]
}


# 创建 df
df = pd.DataFrame(data)

# df1 = pd.DataFrame(new_data)
df.fillna(df.mean(), inplace=True)

# 定义特征和目标变量
X = df.drop(columns=['GDP', 'Year', 'GDP Growth Rate']).values  # 特征集
# X1 = df1.drop(columns=['GDP', 'Year', 'GDP Growth Rate']).values  # 特征

y = df['GDP'].values  # 目标变量
# y1 = df1['GDP'].values  # 目标变量

# 特征标准化
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
# X1_scaled = scaler.fit_transform(df1)

# 创建时间序列数据集函数
def create_dataset(X, y, time_steps=1):
    Xs, ys = [], []
    for i in range(len(X) - time_steps):
        Xs.append(X[i:(i + time_steps)])
        ys.append(y[i + time_steps])
    return np.array(Xs), np.array(ys)

# 转化成时间序列数据标准化表达
time_steps = 2  #
```

```
X_data, y_data = create_dataset(X_scaled, y, time_steps)
# X1_data, y1_data = create_dataset(X1_scaled, y, time_steps)

# 将数据转换为tensor
X_tensor = torch.tensor(X_data, dtype=torch.float32)
# X1_tensor = torch.tensor(X1_data, dtype=torch.float32)
y_tensor = torch.tensor(y_data, dtype=torch.float32).view(-1, 1)

# 拆分数据集
X_train, X_test, y_train, y_test = train_test_split(X_tensor, y_tensor, test_size=0.3, random_state=42)

# 构建卷积神经网络模型
class CNNRegressor(nn.Module):
    def __init__(self):
        super(CNNRegressor, self).__init__()
        self.conv1 = nn.Conv1d(in_channels=X_train.shape[2], out_channels=512, kernel_size=1)
        self.bn1 = nn.BatchNorm1d(512)
        self.conv2 = nn.Conv1d(512, 1024, kernel_size=1)
        self.bn2 = nn.BatchNorm1d(1024)
        self.conv3 = nn.Conv1d(1024, 2048, kernel_size=1)
        self.bn3 = nn.BatchNorm1d(2048)
        self.conv4 = nn.Conv1d(2048, 4056, kernel_size=1)
        self.bn4 = nn.BatchNorm1d(4056)

        # 计算卷积层的输出大小
        self.fc1_input_size = 8112 * (time_steps - 1)  # 注意点
        self.fc1 = nn.Linear(self.fc1_input_size, 100)
        self.fc2 = nn.Linear(100, 1)
        self.dropout = nn.Dropout(0.2)  # Dropout for regularization

```

```
92      def forward(self, x):
93          x = x.permute(0, 2, 1)  # 转为 (batch_size, channels,
    sequence_length)
94          x = nn.functional.relu(self.bn1(self.conv1(x)))
95          x = nn.functional.relu(self.bn2(self.conv2(x)))
96          x = nn.functional.relu(self.bn3(self.conv3(x)))
97          x = nn.functional.relu(self.bn4(self.conv4(x)))
98          x = x.view(x.size(0), -1)  # 扁平化
99          x = nn.functional.relu(self.fc1(x))
100         x = self.dropout(x)
101         return self.fc2(x)
102
103 class CNNRegressor(nn.Module):
104     def __init__(self, input_channels):
105         super(CNNRegressor, self).__init__()
106         self.conv1 = nn.Conv1d(in_channels=input_channels,
    out_channels=512, kernel_size=1)
107         self.bn1 = nn.BatchNorm1d(512)
108         self.conv2 = nn.Conv1d(512, 1024, kernel_size=1)
109         self.bn2 = nn.BatchNorm1d(1024)
110         self.conv3 = nn.Conv1d(1024, 2048, kernel_size=1)
111         self.bn3 = nn.BatchNorm1d(2048)
112         self.conv4 = nn.Conv1d(2048, 4056, kernel_size=1)
113         self.bn4 = nn.BatchNorm1d(4056)
114
115         self.fc1_input_size = 8112 * (time_steps - 1)  # 随时
    调整
116         self.fc1 = nn.Linear(self.fc1_input_size, 100)
117         self.fc2 = nn.Linear(100, 1)
118         self.dropout = nn.Dropout(0.2)
119
120     def forward(self, x):
121         x = x.permute(0, 2, 1)  # 转为 (batch_size, channels,
    sequence_length)
122         x = nn.functional.relu(self.bn1(self.conv1(x)))
```

```
        x = nn.functional.relu(self.bn2(self.conv2(x)))
        x = nn.functional.relu(self.bn3(self.conv3(x)))
        x = nn.functional.relu(self.bn4(self.conv4(x)))
        x = x.view(x.size(0), -1)  # 扁平化
        x = nn.functional.relu(self.fc1(x))
        x = self.dropout(x)
        return self.fc2(x)

# 实例化
input_channels = X_tensor.shape[2]  # 这里应为9
model = CNNRegressor(input_channels)

from prettytable import PrettyTable

# PrettyTable 对象做模型参数
table = PrettyTable()
table.field_names = ["Parameter Name", "Shape"]

for name, param in model.named_parameters():
    if param.requires_grad:
        table.add_row([name, param.data.shape])

# 打印表格
print(table)


# 8. 实例化模型
# model = CNNRegressor()

# 9. 定义损失函数和优化器
criterion = nn.L1Loss()
optimizer = optim.Adam(model.parameters(), lr=0.001)

# 10. 训练模型
num_epochs = 1000
```

```
158 for epoch in tqdm(range(num_epochs), desc="Training Process"):
159     model.train()
160     optimizer.zero_grad()
161     outputs = model(X_train)
162     loss = criterion(outputs, y_train)
163     loss.backward()
164     optimizer.step()
165 
166     if (epoch + 1) % 125 == 0:
167         print(f'Process [{epoch + 1}/{num_epochs}], GDP
    Forecast Amount Loss: {loss.item():.4f}')
168 
169 
170 
171 #
    ##########################################################################
172 
173 
174 # a = int(input("a="))
175 # b = int(input('b='))
176 # 设置随机数种子
177 np.random.seed(40)  # 设置numpy的随机数种子
178 torch.manual_seed(59)  # 设置PyTorch的随机数种子
179 
180 # 1. 数据准备
181 data = {
182     'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
183     'GDP': [74953.26, 80440.72, 87213.05, 89850.38, 100914.59,
    104681.82, 110214.71],
184     'GDP Growth Rate': [9.9071, 7.3211, 8.4190, 3.0240,
    12.3140, 3.7330, 5.2854],
185     'Total Population': [7338.07, 7545.46, 7683.95, 7823.54,
    7860.60, 7829.43, np.nan],
186     'Import & Export': [9612.32, 10391.83, 9901.13, 9778.64,
```

```
    12215.72, 11905.82, 11277.14],
187     'Higher Edu Enroll': [np.nan, np.nan, np.nan, 223.2186,
    236.2014, 248.3100, np.nan],
188     'Research Institutions': [np.nan, np.nan, np.nan, 29548,
    34570, np.nan, np.nan],
189     'Technology Value': [np.nan, np.nan, np.nan, 3223.3056,
    3992.2389, 4208.6406, np.nan],
190     '1st Industry Growth': [0.134321, 0.146338, 0.172580,
    0.148384, 0.200000, 0.331547, 0.218879],
191     '2nd Industry Growth': [2.770637, 2.925126, 2.604306,
    1.868097, 0.811439, 3.650093, 0.980169],
192     '3rd Industry Growth': [4.614026, 4.421682, 4.034188,
    4.134514, 1.300496, 4.157348, 0.654010]
193 }
194
195 # 创建 DataFrame
196 df = pd.DataFrame(data)
197
198 # 处理缺失值，使用均值填充
199 df.fillna(df.mean(), inplace=True)
200
201 # 2. 定义特征和目标变量
202 X = df.drop(columns=['GDP', 'Year']).values  # 特征
203 y = df['GDP'].values  # 目标变量
204
205 # 3. 特征标准化
206 scaler = StandardScaler()
207 X_scaled = scaler.fit_transform(X)
208
209 # 4. 创建时间序列数据集函数
210 def create_dataset(X, y, time_steps=1):
211     Xs, ys = [], []
212     for i in range(len(X) - time_steps):
213         Xs.append(X[i:(i + time_steps)])
214         ys.append(y[i + time_steps])
```

```
    return np.array(Xs), np.array(ys)

# 5. 创建时间序列数据
time_steps = 2  # 根据需要调整
X_data, y_data = create_dataset(X_scaled, y, time_steps)

# 将数据转换为 PyTorch Tensor
X_tensor = torch.tensor(X_data, dtype=torch.float32)
y_tensor = torch.tensor(y_data, dtype=torch.float32).view(-1, 1)

# 6. 拆分数据集
X_train, X_test, y_train, y_test = train_test_split(X_tensor, y_tensor, test_size=0.3, random_state=42)

# 7. 构建 LSTM 模型
class LSTMRegressor(nn.Module):
    def __init__(self, input_size):
        super(LSTMRegressor, self).__init__()
        self.lstm = nn.LSTM(input_size, 100, batch_first=True)
        self.fc = nn.Linear(100, 1)

    def forward(self, x):
        x, _ = self.lstm(x)
        x = x[:, -1, :]  # 获取最后一个时间步的输出
        x = self.fc(x)
        return x

# 8. 实例化模型
input_size = X_tensor.shape[2]  # 特征数量
model = LSTMRegressor(input_size)

from prettytable import PrettyTable

# 创建 PrettyTable 对象
```

```
table = PrettyTable()
table.field_names = ["Parameter Name", "Shape"]

for name, param in model.named_parameters():
    if param.requires_grad:
        table.add_row([name, param.data.shape])

# 打印模型参数表格
print(table)

criterion = nn.MSELoss()
optimizer = optim.Adam(model.parameters(), lr=0.001)

from tqdm import tqdm  # 导入 tqdm 库

num_epochs = 100
# 训练
for epoch in tqdm(range(num_epochs), desc="Training Process"):
    model.train()
    optimizer.zero_grad()
    outputs = model(X_train)
    loss = criterion(outputs, y_train)
    loss.backward()
    optimizer.step()

print(model.state_dict())
print(model.parameters())

# 预测模式打开
model.eval()
with torch.no_grad():
    predictions = model(X_test)

# 预测未来10年
latest_data = {
```

```
    'GDP Growth Rate': df['GDP Growth Rate'].iloc[-1],
    'Total Population': df['Total Population'].iloc[-1],
    'Import & Export': df['Import & Export'].iloc[-1],
    'Higher Edu Enroll': df['Higher Edu Enroll'].iloc[-1],
    'Research Institutions': df['Research Institutions'].iloc[-1],
    'Technology Value': df['Technology Value'].iloc[-1],
    'Industry Growth': df['Industry Growth'].iloc[-1],
    'Industry Growth': df['Industry Growth'].iloc[-1],
    'Industry Growth': df['Industry Growth'].iloc[-1]
}

# 初始化用于存储预测的历史数据
input_history = [list(latest_data.values())] * time_steps  # 重复输入数据以创建初始历史
current_gdp = df['GDP'].iloc[-1]

predictions = []
for year in range(10):
    # 创建特征输入
    input_data = np.array(input_history[-time_steps:]).reshape(1, time_steps, -1)  # 形状为 (1, time_steps, num_features)
    input_tensor = torch.tensor(input_data, dtype=torch.float32)

    # 预测
    model.eval()
    with torch.no_grad():
        predicted_gdp = model(input_tensor).item()

    # 引入现实中随机噪声的影响
    noise = np.random.uniform(-5, 5)  # 随机噪声范围
    predicted_gdp += noise

    # 结果规范化，约束在合理范围内，剔除不合理的结果
```

```
    predicted_gdp = max(-3, min(10, predicted_gdp))

    predictions.append(predicted_gdp)

    # 更新输入数据为最新的预测结果
    latest_data['GDP Growth Rate'] = (predicted_gdp - current_gdp) / current_gdp * 100  # 更新增长率
    current_gdp = predicted_gdp  # 更新当前 GDP

    # 更新特征数据，引入一定的噪音影响
    latest_data['Total Population'] += np.random.normal(0.1, 1)
    latest_data['Import & Export'] *= np.random.normal(1, 0.5)
    latest_data['Higher Edu Enroll'] *= np.random.normal(1, 0.5)
    latest_data['Research Institutions'] *= np.random.normal(1, 0.5)
    latest_data['Technology Value'] *= np.random.normal(1, 0.5)
    latest_data['1st Industry Growth'] += np.random.normal(0, 0.5)
    latest_data['2nd Industry Growth'] += np.random.normal(0, 0.5)
    latest_data['3rd Industry Growth'] += np.random.normal(0, 0.5)

    # 添加新的输入数据到历史中
    input_history.append(list(latest_data.values()))

grow_results = list()
print('\n')
# 输出预测结果
for i, pred in enumerate(predictions, start=2024):
    print(f"Predicted GDP Grow Rate for Year_{i}: {pred:.4f}")
    grow_results.append(pred)
```

```
341
342 print('\n', grow_results)
```

粤港澳地区统计__增长率图像1__.py

```
1  import matplotlib.pyplot as plt
2  import seaborn as sns
3
4  # Seaborn风格
5  sns.set(style='whitegrid')
6
7  # 2023年GDP
8  gdp_2023 = 143922.77
9
10 # 模型预测到未来10年的GDP增长率
11 growth_rates = [-0.8362374421948042, 1.908234796044142,
       3.385525597560968, -3, -3,
12                 0.45658530675561004, 3.698674414236634,
       4.274138749969177,
13                 2.17605323713926, 3.2110826406910222]
14
15 future_gdp = [gdp_2023]
16
17 # 计算每一年的GDP
18 for rate in growth_rates:
19     new_gdp = future_gdp[-1] * (1 + rate / 100)
20     future_gdp.append(new_gdp)
21
22 # 生成年份
23 years = list(range(2023, 2034))
24
25 # 可视化
26 plt.figure(figsize=(12, 6))
27
28 # 绘制GDP折线图
29 plt.subplot(2, 1, 1)  # 2行1列的第1个子图
```

```
plt.plot(years, future_gdp, marker='o', color='royalblue', linestyle='-', linewidth=2, markersize=8)
plt.title('GDP Forecast For Next 10 Years', fontsize=16, fontweight='bold')
plt.xlabel('Year', fontsize=14)
plt.ylabel('GDP (100 million)', fontsize=14)
plt.xticks(years, fontsize=12)
plt.yticks(fontsize=12)
plt.grid(True, linestyle='--', alpha=0.7)

# 绘制增长率图
plt.subplot(2, 1, 2)  # 2行1列的第2个子图
plt.plot(years[1:], growth_rates, marker='x', color='orangered', linestyle='--', linewidth=2, markersize=8)
plt.title('GDP Growth Rate Forecast For Next 10 Years', fontsize=16, fontweight='bold')
plt.xlabel('Year', fontsize=14)
plt.ylabel('Rate (%)', fontsize=14)
plt.xticks(years[1:], fontsize=12)
plt.yticks(fontsize=12)
plt.axhline(0, color='black', linewidth=0.8, linestyle='--')  # 添加水平线表示0%
plt.grid(True, linestyle='--', alpha=0.7)

# 调整布局
plt.tight_layout()
plt.savefig('GDP_Growth_Rate1.png')
plt.show()
```

粤港澳地区统计__增长率图像 2__.py

```
import matplotlib.pyplot as plt

# 2023年GDP
gdp_2023 = 143922.77

```

```
# 未来10年的预测增长率
growth_rates = [-0.8362374421948042, 1.908234796044142,
   3.385525597560968, -3, -3,
                0.45658530675561004, 3.698674414236634,
   4.274138749969177,
                2.17605323713926, 3.2110826406910222]

# 初始化列表存储未来GDP
future_gdp = [gdp_2023]

# 计算每一年的GDP
for rate in growth_rates:
    new_gdp = future_gdp[-1] * (1 + rate / 100)
    future_gdp.append(new_gdp)

# 生成年份
years = list(range(2023, 2034))

# 可视化
fig, ax1 = plt.subplots(figsize=(10, 5))

# 绘制GDP折线图
ax1.set_xlabel('Year')
ax1.set_ylabel('GDP (100million)', color='tab:blue')
ax1.plot(years, future_gdp, color='tab:blue', marker='o',
   label='GDP')
ax1.tick_params(axis='y', labelcolor='tab:blue')
ax1.set_title('GDP Value & Growth Rate Forecast For Next 10
   Years')

# 创建第二个y轴绘制增长率
ax2 = ax1.twinx()
ax2.set_ylabel('Rate (%)', color='tab:red')
ax2.plot(years[1:], growth_rates, color='tab:red', marker='x',
    linestyle='--', label='Growth Rate')
```

```
ax2.tick_params(axis='y', labelcolor='tab:red')

# 添加图例
ax1.legend(loc='upper left')
ax2.legend(loc='upper right')

# 显示网格
ax1.grid()

# 显示图表
plt.tight_layout()
plt.savefig('GDP_Growth_Rate2.png')
plt.show()
```

粤港澳地区统计__组合重要性__.py

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error

# 将序列数据转为dict
data = {
    'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
    'GDP': [74953.26, 80440.72, 87213.05, 89850.38, 100914.59,
    104681.82, 110214.71],
    'GDP Growth Rate': [9.9071, 7.3211, 8.4190, 3.0240,
   12.3140, 3.7330, 5.2854],
    'Total Population': [7338.07, 7545.46, 7683.95, 7823.54,
   7860.60, 7829.43, np.nan],
    'Import & Export': [9612.32, 10391.83, 9901.13, 9778.64,
   12215.72, 11905.82, 11277.14],
    'Higher Edu Enroll': [np.nan, np.nan, np.nan, 223.2186,
   236.2014, 248.3100, np.nan],
```

```
    'Research Institutions': [np.nan, np.nan, np.nan, 29548, 34570, np.nan, np.nan],
    'Technology Value': [np.nan, np.nan, np.nan, 3223.3056, 3992.2389, 4208.6406, np.nan],
    '1st Industry Growth': [0.134321, 0.146338, 0.172580, 0.148384, 0.200000, 0.331547, 0.218879],
    '2nd Industry Growth': [2.770637, 2.925126, 2.604306, 1.868097, 0.811439, 3.650093, 0.980169],
    '3rd Industry Growth': [4.614026, 4.421682, 4.034188, 4.134514, 1.300496, 4.157348, 0.654010]
}

# 创建df
df = pd.DataFrame(data)
df.fillna(df.mean(), inplace=True)

# 定义特征和目标变量
X = df.drop(columns=['GDP', 'Year'])  # 特征集合
y = df['GDP']  # 目标变量

# 组合特征
feature_combinations = [('Higher Edu Enroll', 'Total Population'),
                        ('Import & Export', 'Higher Edu Enroll'),
                        ('Research Institutions', 'Technology Value'),
                        ('2nd Industry Growth', 'Import & Export'),
                        ('Import & Export', 'Total Population'),
                        ('Higher Edu Enroll', 'Technology Value'),
                        ('Total Population', '3rd Industry Growth'),
```

```
                        ('Total Population', '2nd Industry Growth'),
                        ('Higher Edu Enroll', 'Research Institutions'),
                        ('3rd Industry Growth', 'Import & Export')
                        ]

# 评估每个组合特征
results = {}

for combo, num in zip(feature_combinations, list(range(1, len(feature_combinations)+1))):
    combo_name = f"Pair{num}:\n{combo[0]}\n + {combo[1]}"
    df[combo_name] = df[combo[0]] * df[combo[1]]

    # 定义特征集合
    X_combined = df[list(combo) + [combo_name]]

    # 拆分数据集
    X_train, X_test, y_train, y_test = train_test_split(X_combined, y, test_size=0.3, random_state=42)

    # 训练模型并评估
    model = RandomForestRegressor(n_estimators=100, random_state=42)

    try:
        model.fit(X_train, y_train)
        y_pred = model.predict(X_test)
        rmse = mean_squared_error(y_test, y_pred, squared=False)
        results[combo_name] = rmse
    except ValueError as e:
        print(f"Error with combination {combo_name}: {e}")
```

```
        results[combo_name] = np.nan

# 可视化结果
plt.figure(figsize=(14, 8))

# 计算颜色渐变
cmap = plt.get_cmap("Blues")
normed_rmse = (np.array(list(results.values())) - np.nanmin(
   list(results.values()))) / (np.nanmax(list(results.values()
   )) - np.nanmin(list(results.values())))
colors = [cmap(value) for value in normed_rmse]

# 绘制柱状图
bars = plt.barh(list(results.keys()), list(results.values()),
   color=colors, edgecolor='black')

# 添加数值标签
for bar in bars:
    plt.text(bar.get_width(), bar.get_y() + bar.get_height()
   /2,
             f'{bar.get_width():.2f}',
             va='center', ha='left', fontsize=10)

plt.xlabel('RF Sub-Tree Model RMSE Evaluation Value', fontsize
   =14)
plt.title('Feature Combination Impact on GDP', fontsize=16)
plt.grid(axis='x', linestyle='--', alpha=0.7)
plt.tight_layout()
plt.savefig("importance_Pair_plot")
plt.show()
```

粤港澳地区统计 __PCA 单项重要性 __.py

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

```
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
from matplotlib.colors import LinearSegmentedColormap

# 将序列数据转为dict
data = {
    'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
    'GDP': [74953.26, 80440.72, 87213.05, 89850.38, 100914.59,
    104681.82, 110214.71],
    'GDP Growth Rate': [9.9071, 7.3211, 8.4190, 3.0240,
   12.3140, 3.7330, 5.2854],
    'Total Population': [7338.07, 7545.46, 7683.95, 7823.54,
   7860.60, 7829.43, np.nan],
    'Import & Export': [9612.32, 10391.83, 9901.13, 9778.64,
   12215.72, 11905.82, 11277.14],
    'Higher Edu Enroll': [np.nan, np.nan, np.nan, 223.2186,
   236.2014, 248.3100, np.nan],
    'Research Institutions': [np.nan, np.nan, np.nan, 29548,
   34570, np.nan, np.nan],
    'Technology Value': [np.nan, np.nan, np.nan, 3223.3056,
   3992.2389, 4208.6406, np.nan],
    '1st Industry Growth': [0.134321, 0.146338, 0.172580,
   0.148384, 0.200000, 0.331547, 0.218879],
    '2nd Industry Growth': [2.770637, 2.925126, 2.604306,
   1.868097, 0.811439, 3.650093, 0.980169],
    '3rd Industry Growth': [4.614026, 4.421682, 4.034188,
   4.134514, 1.300496, 4.157348, 0.654010]
}

# 创建df
df = pd.DataFrame(data)
df.fillna(df.mean(), inplace=True)

# 2. 定义特征目标变量
X = df.drop(columns=['GDP', 'Year', 'GDP Growth Rate'])  # 特
```

```
    征集合
y = df['GDP']  # 目标变量

# 标准化
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# PCA分析
pca = PCA(n_components=min(len(X.columns), len(X)))  # 最小值
pca.fit(X_scaled)

# 计算每个特征对主成分的贡献
explained_variance = pca.explained_variance_ratio_

# 可视化特征重要性
plt.figure(figsize=(11, 7))
plt.title("Feature Importance based on PCA (By Years)")

# 渐变色的颜色映射
cmap = LinearSegmentedColormap.from_list("gradient", ['#f7fbff', '#2171b5'], N=len(explained_variance))

# 绘制柱状图
bars = plt.bar(range(len(explained_variance)), explained_variance, align="center",
               color=cmap(explained_variance / max(explained_variance)), edgecolor='black')

for bar, value in zip(bars, explained_variance):
    yval = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, yval, f"{value:.4f}", ha='center', va='bottom')

# 图例
for i, bar in enumerate(bars):
```

```
    plt.plot([], [], color=cmap(explained_variance[i] / max(explained_variance)),
             label=f"{X.columns[i]}: {explained_variance[i]:.4f}")

plt.legend(title="Feature Contribution", loc='upper right', fontsize='large', framealpha=0.9)

plt.xticks(range(len(X.columns)), X.columns, rotation=20, ha='right')
plt.xlim([-1, len(X.columns)])
plt.ylabel('Explained Variance Ratio')
plt.xlabel('Features')

# 保存图形
plt.savefig("importance_PCA_plot.png", bbox_inches='tight')
plt.show()
```

粤港澳地区统计 __RF 单项重要性 __.py

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import train_test_split
from matplotlib.colors import LinearSegmentedColormap

# 将序列数据转为dict
data = {
    'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
    'GDP': [74953.26, 80440.72, 87213.05, 89850.38, 100914.59, 104681.82, 110214.71],
    'GDP Growth Rate': [9.9071, 7.3211, 8.4190, 3.0240, 12.3140, 3.7330, 5.2854],
    'Total Population': [7338.07, 7545.46, 7683.95, 7823.54, 7860.60, 7829.43, np.nan],
```

```
    'Import & Export': [9612.32, 10391.83, 9901.13, 9778.64, 12215.72, 11905.82, 11277.14],
    'Higher Edu Enroll': [np.nan, np.nan, np.nan, 223.2186, 236.2014, 248.3100, np.nan],
    'Research Institutions': [np.nan, np.nan, np.nan, 29548, 34570, np.nan, np.nan],
    'Technology Value': [np.nan, np.nan, np.nan, 3223.3056, 3992.2389, 4208.6406, np.nan],
    '1st Industry Growth': [0.134321, 0.146338, 0.172580, 0.148384, 0.200000, 0.331547, 0.218879],
    '2nd Industry Growth': [2.770637, 2.925126, 2.604306, 1.868097, 0.811439, 3.650093, 0.980169],
    '3rd Industry Growth': [4.614026, 4.421682, 4.034188, 4.134514, 1.300496, 4.157348, 0.654010]
}

# 创建df
df = pd.DataFrame(data)
df.fillna(df.mean(), inplace=True)

# 定义特征和目标变量
X = df.drop(columns=['GDP', 'Year'])  # 特征集合
y = df['GDP']  # 目标变量

# 拆分数据集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# 训练RF模型
model = RandomForestRegressor(n_estimators=100, random_state=42)
model.fit(X_train, y_train)

# 提取特征重要性
importances = model.feature_importances_
```

```
indices = np.argsort(importances)[::-1]

# 可视化特征重要性
plt.figure(figsize=(13, 9))
plt.title("Feature Importance")

# 渐变色的颜色映射
cmap = LinearSegmentedColormap.from_list("gradient", ['#f7fbff', '#2171b5'], N=len(importances))

# 绘制柱状图
bars = plt.bar(range(X.shape[1]), importances[indices], align="center",
               color=cmap(importances[indices] / max(importances)), edgecolor='black')

for bar, value in zip(bars, importances[indices]):
    plt.text(bar.get_x() + bar.get_width()/2, bar.get_height(), f"{value:.4f}",
             ha='center', va='bottom')

# 图例
for i, bar in enumerate(bars):
    plt.plot([], [], color=cmap(importances[indices[i]] / max(importances)),
             label=f"{X.columns[indices[i]]}: {importances[indices[i]]:.4f}")

plt.legend(title="Feature Contribution", loc='upper right', fontsize='large', framealpha=0.9)

# 设置 x 轴标签
plt.xticks(range(X.shape[1]), np.array(X.columns)[indices], rotation=20)
plt.xlim([-1, X.shape[1]])
```

```
plt.ylabel('Importance Score')
plt.xlabel('Features')

# 保存图形
plt.savefig("importance_RF_plot.png", bbox_inches='tight')
plt.show()
```

纽约地区统计__预测模型__.py

```
import pandas as pd
import numpy as np
import torch
import torch.nn as nn
import torch.optim as optim
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

from tqdm import tqdm  # 导入 tqdm 库
import pandas as pd
import numpy as np
import torch
import torch.nn as nn
import torch.optim as optim
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

# 数据转成dict
data = {
    'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
    'GDP': [178195.395, 186914.7499, 194554.4198, 192099.3274,
    208761.0985, 224303.7472, 238040.4077],
    'GDP Growth Rate': [3.2129, 4.8931, 4.0872, -1.2619,
   8.6735, 7.4451, 6.1241],
    'Total Population': [320.5732, 320.10389, 319.20411,
   329.54688, 327.27392, 325.42723, 324.79233],
    'Import & Export': [27580.32, 30215.2, 29098.24, 28976.52,
```

```
    34869.2, 38449.2, 32434.8],
    'Higher Edu Enroll': [187.7128, 186.2156, 184.248,
176.386, 171.3124, 168.4206, 169.2476],
    'Research Institutions': [31171, 46757, 70134, 80874,
94619, 110678, 129724],
    'Technology Fundings': [1881.992, 2016.485, 2192.136,
2461.808, 2776.54, 2919.31, np.nan],
    '1st Industry Value': [905866.1, 13940538.2, 13770004.8,
10199432.2, 11020702.4, 13273225.6, np.nan],
    '2nd Industry Value': [13984020, 13984020, 14271887.7,
4920639, 10386978.9, 17168890.6, np.nan],
    '3rd Industry Value': [223211414.3, 237599860.3,
249919458.1, 174760351.1, 213917275.5, 275926305.6, np.nan]
}


# 创建 df
df = pd.DataFrame(data)

# df1 = pd.DataFrame(new_data)
df.fillna(df.mean(), inplace=True)

# 定义特征和目标变量
X = df.drop(columns=['GDP', 'Year', 'GDP Growth Rate']).values
    # 特征集
# X1 = df1.drop(columns=['GDP', 'Year', 'GDP Growth Rate']).
  values  # 特征

y = df['GDP'].values  # 目标变量
# y1 = df1['GDP'].values  # 目标变量

# 特征标准化
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
# X1_scaled = scaler.fit_transform(df1)
```

```
51
52  # 创建时间序列数据集函数
53  def create_dataset(X, y, time_steps=1):
54      Xs, ys = [], []
55      for i in range(len(X) - time_steps):
56          Xs.append(X[i:(i + time_steps)])
57          ys.append(y[i + time_steps])
58      return np.array(Xs), np.array(ys)
59
60  # 转化成时间序列数据标准化表达
61  time_steps = 2  #
62  X_data, y_data = create_dataset(X_scaled, y, time_steps)
63  # X1_data, y1_data = create_dataset(X1_scaled, y, time_steps)
64
65  # 将数据转换为tensor
66  X_tensor = torch.tensor(X_data, dtype=torch.float32)
67  # X1_tensor = torch.tensor(X1_data, dtype=torch.float32)
68  y_tensor = torch.tensor(y_data, dtype=torch.float32).view(-1,
       1)
69
70  # 拆分数据集
71  X_train, X_test, y_train, y_test = train_test_split(X_tensor,
       y_tensor, test_size=0.3, random_state=42)
72
73  # 构建卷积神经网络模型
74  class CNNRegressor(nn.Module):
75      def __init__(self):
76          super(CNNRegressor, self).__init__()
77          self.conv1 = nn.Conv1d(in_channels=X_train.shape[2],
       out_channels=512, kernel_size=1)
78          self.bn1 = nn.BatchNorm1d(512)
79          self.conv2 = nn.Conv1d(512, 1024, kernel_size=1)
80          self.bn2 = nn.BatchNorm1d(1024)
81          self.conv3 = nn.Conv1d(1024, 2048, kernel_size=1)
82          self.bn3 = nn.BatchNorm1d(2048)
```

```
83          self.conv4 = nn.Conv1d(2048, 4056, kernel_size=1)
84          self.bn4 = nn.BatchNorm1d(4056)
85
86          # 计算卷积层的输出大小
87          self.fc1_input_size = 8112 * (time_steps - 1)  # 注意
    点
88          self.fc1 = nn.Linear(self.fc1_input_size, 100)
89          self.fc2 = nn.Linear(100, 1)
90          self.dropout = nn.Dropout(0.2)  # Dropout for
    regularization
91
92      def forward(self, x):
93          x = x.permute(0, 2, 1)  # 转为 (batch_size, channels,
    sequence_length)
94          x = nn.functional.relu(self.bn1(self.conv1(x)))
95          x = nn.functional.relu(self.bn2(self.conv2(x)))
96          x = nn.functional.relu(self.bn3(self.conv3(x)))
97          x = nn.functional.relu(self.bn4(self.conv4(x)))
98          x = x.view(x.size(0), -1)  # 扁平化
99          x = nn.functional.relu(self.fc1(x))
100         x = self.dropout(x)
101         return self.fc2(x)
102
103 class CNNRegressor(nn.Module):
104     def __init__(self, input_channels):
105         super(CNNRegressor, self).__init__()
106         self.conv1 = nn.Conv1d(in_channels=input_channels,
    out_channels=512, kernel_size=1)
107         self.bn1 = nn.BatchNorm1d(512)
108         self.conv2 = nn.Conv1d(512, 1024, kernel_size=1)
109         self.bn2 = nn.BatchNorm1d(1024)
110         self.conv3 = nn.Conv1d(1024, 2048, kernel_size=1)
111         self.bn3 = nn.BatchNorm1d(2048)
112         self.conv4 = nn.Conv1d(2048, 4056, kernel_size=1)
113         self.bn4 = nn.BatchNorm1d(4056)
```

```
114
115         self.fc1_input_size = 8112 * (time_steps - 1)  # 随时
    调整
116         self.fc1 = nn.Linear(self.fc1_input_size, 100)
117         self.fc2 = nn.Linear(100, 1)
118         self.dropout = nn.Dropout(0.2)
119
120     def forward(self, x):
121         x = x.permute(0, 2, 1)  # 转为 (batch_size, channels,
    sequence_length)
122         x = nn.functional.relu(self.bn1(self.conv1(x)))
123         x = nn.functional.relu(self.bn2(self.conv2(x)))
124         x = nn.functional.relu(self.bn3(self.conv3(x)))
125         x = nn.functional.relu(self.bn4(self.conv4(x)))
126         x = x.view(x.size(0), -1)  # 扁平化
127         x = nn.functional.relu(self.fc1(x))
128         x = self.dropout(x)
129         return self.fc2(x)
130
131 # 实例化
132 input_channels = X_tensor.shape[2]  # 这里应为9
133 model = CNNRegressor(input_channels)
134
135 from prettytable import PrettyTable
136
137 # PrettyTable 对象做模型参数
138 table = PrettyTable()
139 table.field_names = ["Parameter Name", "Shape"]
140
141 for name, param in model.named_parameters():
142     if param.requires_grad:
143         table.add_row([name, param.data.shape])
144
145 # 打印表格
146 print(table)
```

```
147
148
149 # 8. 实例化模型
150 # model = CNNRegressor()
151
152 # 9. 定义损失函数和优化器
153 criterion = nn.L1Loss()
154 optimizer = optim.Adam(model.parameters(), lr=0.001)
155
156 # 10. 训练模型
157 num_epochs = 1000
158 for epoch in tqdm(range(num_epochs), desc="Training Process"):
159     model.train()
160     optimizer.zero_grad()
161     outputs = model(X_train)
162     loss = criterion(outputs, y_train)
163     loss.backward()
164     optimizer.step()
165
166     if (epoch + 1) % 125 == 0:
167         print(f'Process [{epoch + 1}/{num_epochs}], GDP
    Forecast Amount Loss: {loss.item():.4f}')
168
169
170
171 #
    ##########################################################################
172
173
174 # a = int(input("a="))
175 # b = int(input('b='))
176 # 设置随机数种子
177 np.random.seed(40)  # 设置numpy的随机数种子
178 torch.manual_seed(59)  # 设置PyTorch的随机数种子
```

```
179
180 # 1. 数据准备
181 data = {
182     'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
183     'GDP': [178195.395, 186914.7499, 194554.4198, 192099.3274,
    208761.0985, 224303.7472, 238040.4077],
184     'GDP Growth Rate': [3.2129, 4.8931, 4.0872, -1.2619,
   8.6735, 7.4451, 6.1241],
185     'Total Population': [320.5732, 320.10389, 319.20411,
   329.54688, 327.27392, 325.42723, 324.79233],
186     'Import & Export': [27580.32, 30215.2, 29098.24, 28976.52,
    34869.2, 38449.2, 32434.8],
187     'Higher Edu Enroll': [187.7128, 186.2156, 184.248,
   176.386, 171.3124, 168.4206, 169.2476],
188     'Research Institutions': [31171, 46757, 70134, 80874,
   94619, 110678, 129724],
189     'Technology Fundings': [1881.992, 2016.485, 2192.136,
   2461.808, 2776.54, 2919.31, np.nan],
190     '1st Industry Value': [905866.1, 13940538.2, 13770004.8,
   10199432.2, 11020702.4, 13273225.6, np.nan],
191     '2nd Industry Value': [13984020, 13984020, 14271887.7,
   4920639, 10386978.9, 17168890.6, np.nan],
192     '3rd Industry Value': [223211414.3, 237599860.3,
   249919458.1, 174760351.1, 213917275.5, 275926305.6, np.nan]
193 }
194
195 # 创建 DataFrame
196 df = pd.DataFrame(data)
197
198 # 处理缺失值，使用均值填充
199 df.fillna(df.mean(), inplace=True)
200
201 # 2. 定义特征和目标变量
202 X = df.drop(columns=['GDP', 'Year']).values  # 特征
203 y = df['GDP'].values  # 目标变量
```

```
204
205 # 3. 特征标准化
206 scaler = StandardScaler()
207 X_scaled = scaler.fit_transform(X)
208
209 # 4. 创建时间序列数据集函数
210 def create_dataset(X, y, time_steps=1):
211     Xs, ys = [], []
212     for i in range(len(X) - time_steps):
213         Xs.append(X[i:(i + time_steps)])
214         ys.append(y[i + time_steps])
215     return np.array(Xs), np.array(ys)
216
217 # 5. 创建时间序列数据
218 time_steps = 2  # 根据需要调整
219 X_data, y_data = create_dataset(X_scaled, y, time_steps)
220
221 # 将数据转换为 PyTorch Tensor
222 X_tensor = torch.tensor(X_data, dtype=torch.float32)
223 y_tensor = torch.tensor(y_data, dtype=torch.float32).view(-1,
    1)
224
225 # 6. 拆分数据集
226 X_train, X_test, y_train, y_test = train_test_split(X_tensor,
    y_tensor, test_size=0.3, random_state=42)
227
228 # 7. 构建 LSTM 模型
229 class LSTMRegressor(nn.Module):
230     def __init__(self, input_size):
231         super(LSTMRegressor, self).__init__()
232         self.lstm = nn.LSTM(input_size, 100, batch_first=True)
233         self.fc = nn.Linear(100, 1)
234
235     def forward(self, x):
236         x, _ = self.lstm(x)
```

```
        x = x[:, -1, :]  # 获取最后一个时间步的输出
        x = self.fc(x)
        return x

# 8. 实例化模型
input_size = X_tensor.shape[2]  # 特征数量
model = LSTMRegressor(input_size)

from prettytable import PrettyTable

# 创建 PrettyTable 对象
table = PrettyTable()
table.field_names = ["Parameter Name", "Shape"]

for name, param in model.named_parameters():
    if param.requires_grad:
        table.add_row([name, param.data.shape])

# 打印模型参数表格
print(table)

criterion = nn.MSELoss()
optimizer = optim.Adam(model.parameters(), lr=0.001)

from tqdm import tqdm  # 导入 tqdm 库

num_epochs = 100
# 训练
for epoch in tqdm(range(num_epochs), desc="Training Process"):
    model.train()
    optimizer.zero_grad()
    outputs = model(X_train)
    loss = criterion(outputs, y_train)
    loss.backward()
    optimizer.step()
```

```
272
273 print(model.state_dict())
274 print(model.parameters())
275
276 # 预测模式打开
277 model.eval()
278 with torch.no_grad():
279     predictions = model(X_test)
280
281 # 预测未来10年
282 latest_data = {
283     'GDP Growth Rate': df['GDP Growth Rate'].iloc[-1],
284     'Total Population': df['Total Population'].iloc[-1],
285     'Import & Export': df['Import & Export'].iloc[-1],
286     'Higher Edu Enroll': df['Higher Edu Enroll'].iloc[-1],
287     'Research Institutions': df['Research Institutions'].iloc
    [-1],
288     'Technology Fundings': df['Technology Fundings'].iloc[-1],
289     '1st Industry Value': df['1st Industry Value'].iloc[-1],
290     '2nd Industry Value': df['2nd Industry Value'].iloc[-1],
291     '3rd Industry Value': df['3rd Industry Value'].iloc[-1]
292 }
293
294 # 初始化用于存储预测的历史数据
295 input_history = [list(latest_data.values())] * time_steps  #
    重复输入数据以创建初始历史
296 current_gdp = df['GDP'].iloc[-1]
297
298 predictions = []
299 for year in range(10):
300     # 创建特征输入
301     input_data = np.array(input_history[-time_steps:]).reshape
    (1, time_steps, -1)  # 形状为 (1, time_steps, num_features)
302     input_tensor = torch.tensor(input_data, dtype=torch.
    float32)
```

```
303
304     # 预测
305     model.eval()
306     with torch.no_grad():
307         predicted_gdp = model(input_tensor).item()
308
309     # 引入现实中随机噪声的影响
310     noise = np.random.uniform(-5, 5)  # 随机噪声范围
311     predicted_gdp += noise
312
313     # 结果规范化，约束在合理范围内，剔除不合理的结果
314     predicted_gdp = max(-3, min(10, predicted_gdp))
315
316     predictions.append(predicted_gdp)
317
318     # 更新输入数据为最新的预测结果
319     latest_data['GDP Growth Rate'] = (predicted_gdp -
    current_gdp) / current_gdp * 100  # 更新增长率
320     current_gdp = predicted_gdp  # 更新当前 GDP
321
322     # 更新特征数据，引入一定的噪音影响
323     latest_data['Total Population'] += np.random.normal(0.1,
    1)
324     latest_data['Import & Export'] *= np.random.normal(1, 0.5)
325     latest_data['Higher Edu Enroll'] *= np.random.normal(1,
    0.5)
326     latest_data['Research Institutions'] *= np.random.normal
    (1, 0.5)
327     latest_data['Technology Fundings'] *= np.random.normal(1,
    0.5)
328     latest_data['1st Industry Value'] += np.random.normal(0,
    0.5)
329     latest_data['2nd Industry Value'] += np.random.normal(0,
    0.5)
330     latest_data['3rd Industry Value'] += np.random.normal(0,
```

```
    0.5)

    # 添加新的输入数据到历史中
    input_history.append(list(latest_data.values()))

grow_results = list()
print('\n')
# 输出预测结果
for i, pred in enumerate(predictions, start=2024):
    print(f"Predicted GDP Grow Rate for Year_{i}: {pred:.4f}")
    grow_results.append(pred)

print('\n', grow_results)
```

纽约湾区统计__增长率图像1__.py

```
import matplotlib.pyplot as plt
import seaborn as sns

# Seaborn风格
sns.set(style='whitegrid')

# 2023年GDP
gdp_2023 = 143922.77

# 模型预测到未来10年的GDP增长率
# growth_rates = [-0.9337336760753239, 2.0758475647538015,
    3.3227285503631485, -3, -3, 0.08920186393649132,
    3.787964608450025, 4.311998107862644, 2.0970836020698895,
    3.0653362680508884]

growth_rates = [0.04922648102106186, 3.0588077218501875,
    4.305688707459535, -2.5777403281167874,
    -3.7170036136809266, 1.0721620210328775, 4.77092476554641,
    5.29495826495903, 3.0800437591662755, 4.048296425147275]

```

```
future_gdp = [gdp_2023]

# 计算每一年的GDP
for rate in growth_rates:
    new_gdp = future_gdp[-1] * (1 + rate / 100)
    future_gdp.append(new_gdp)

# 生成年份
years = list(range(2023, 2034))

# 可视化
plt.figure(figsize=(12, 6))

# 绘制GDP折线图
plt.subplot(2, 1, 1)  # 2行1列的第1个子图
plt.plot(years, future_gdp, marker='o', color='royalblue',
   linestyle='-', linewidth=2, markersize=8)
plt.title('New York GDP Forecast For Next 10 Years', fontsize
   =16, fontweight='bold')
plt.xlabel('Year', fontsize=14)
plt.ylabel('GDP (100 million)', fontsize=14)
plt.xticks(years, fontsize=12)
plt.yticks(fontsize=12)
plt.grid(True, linestyle='--', alpha=0.7)

# 绘制增长率图
plt.subplot(2, 1, 2)  # 2行1列的第2个子图
plt.plot(years[1:], growth_rates, marker='x', color='orangered
   ', linestyle='--', linewidth=2, markersize=8)
plt.title('New York GDP Growth Rate Forecast For Next 10 Years
   ', fontsize=16, fontweight='bold')
plt.xlabel('Year', fontsize=14)
plt.ylabel('Rate (%)', fontsize=14)
plt.xticks(years[1:], fontsize=12)
plt.yticks(fontsize=12)
```

```
plt.axhline(0, color='black', linewidth=0.8, linestyle='--')  # 添加水平线表示0%
plt.grid(True, linestyle='--', alpha=0.7)

# 调整布局
plt.tight_layout()
plt.savefig('NY_GDP_Growth_Rate1 (New York).png')
plt.show()
```

纽约湾区统计__增长率图像2__.py

```
import matplotlib.pyplot as plt

# 2023年GDP
gdp_2023 = 143922.77

# 未来10年的预测增长率
# growth_rates = [-0.9337336760753239, 2.0758475647538015, 3.3227285503631485, -3, -3, 0.08920186393649132, 3.787964608450025, 4.311998107862644, 2.0970836020698895, 3.0653362680508884]

growth_rates = [0.04922648102106186, 3.0588077218501875, 4.305688707459535, -2.5777403281167874, -3.7170036136809266, 1.0721620210328775, 4.77092476554641, 5.29495826495903, 3.0800437591662755, 4.048296425147275]

# 初始化列表存储未来GDP
future_gdp = [gdp_2023]

# 计算每一年的GDP
for rate in growth_rates:
    new_gdp = future_gdp[-1] * (1 + rate / 100)
    future_gdp.append(new_gdp)

# 生成年份
```

```
years = list(range(2023, 2034))

# 可视化
fig, ax1 = plt.subplots(figsize=(10, 5))

# 绘制GDP折线图
ax1.set_xlabel('Year')
ax1.set_ylabel('GDP (100million)', color='tab:blue')
ax1.plot(years, future_gdp, color='tab:blue', marker='o',
   label='GDP')
ax1.tick_params(axis='y', labelcolor='tab:blue')
ax1.set_title('New York GDP Value & Growth Rate Forecast For
   Next 10 Years')

# 创建第二个y轴绘制增长率
ax2 = ax1.twinx()
ax2.set_ylabel('Rate (%)', color='tab:red')
ax2.plot(years[1:], growth_rates, color='tab:red', marker='x',
    linestyle='--', label='Growth Rate')
ax2.tick_params(axis='y', labelcolor='tab:red')

# 添加图例
ax1.legend(loc='upper left')
ax2.legend(loc='upper right')

# 显示网格
ax1.grid()

# 显示图表
plt.tight_layout()
plt.savefig('NY_GDP_Growth_Rate2 (New York).png')
plt.show()
```

纽约湾区统计__组合重要性__.py

```
import pandas as pd
```

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error

# 将序列数据转为dict
data = {
    'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
    'GDP': [178195.395, 186914.7499, 194554.4198, 192099.3274,
    208761.0985, 224303.7472, 238040.4077],
    'GDP Growth Rate': [3.2129, 4.8931, 4.0872, -1.2619,
   8.6735, 7.4451, 6.1241],
    'Total Population': [320.5732, 320.10389, 319.20411,
   329.54688, 327.27392, 325.42723, 324.79233],
    'Import & Export': [27580.32, 30215.2, 29098.24, 28976.52,
    34869.2, 38449.2, 32434.8],
    'Higher Edu Enroll': [187.7128, 186.2156, 184.248,
   176.386, 171.3124, 168.4206, 169.2476],
    'Research Institutions': [31171, 46757, 70134, 80874,
   94619, 110678, 129724],
    'Technology Fundings': [1881.992, 2016.485, 2192.136,
   2461.808, 2776.54, 2919.31, np.nan],
    '1st Industry Value': [905866.1, 13940538.2, 13770004.8,
   10199432.2, 11020702.4, 13273225.6, np.nan],
    '2nd Industry Value': [13984020, 13984020, 14271887.7,
   4920639, 10386978.9, 17168890.6, np.nan],
    '3rd Industry Value': [223211414.3, 237599860.3,
   249919458.1, 174760351.1, 213917275.5, 275926305.6, np.nan]
}


# 创建df
df = pd.DataFrame(data)
df.fillna(df.mean(), inplace=True)
```

```
27
28 # 定义特征和目标变量
29 X = df.drop(columns=['GDP', 'Year'])  # 特征集合
30 y = df['GDP']  # 目标变量
31
32 # 组合特征
33 feature_combinations = [('Higher Edu Enroll', 'Total
      Population'),
34                         ('Import & Export', 'Higher Edu Enroll
      '),
35                         ('Research Institutions', 'Technology
      Fundings'),
36                         ('2nd Industry Value', 'Import &
      Export'),
37                         ('Import & Export', 'Total Population'
      ),
38                         ('Higher Edu Enroll', 'Technology
      Fundings'),
39                         ('Total Population', '3rd Industry
      Value'),
40                         ('Total Population', '2nd Industry
      Value'),
41                         ('Higher Edu Enroll', 'Research
      Institutions'),
42                         ('3rd Industry Value', 'Import &
      Export')
43                         ]
44
45 # 评估每个组合特征
46 results = {}
47
48 for combo, num in zip(feature_combinations, list(range(1, len(
      feature_combinations)+1))):
49     combo_name = f"Pair{num}:\n{combo[0]}\n + {combo[1]}"
50     df[combo_name] = df[combo[0]] * df[combo[1]]
```

```
51
52      # 定义特征集合
53      X_combined = df[list(combo) + [combo_name]]
54
55      # 拆分数据集
56      X_train, X_test, y_train, y_test = train_test_split(
    X_combined, y, test_size=0.3, random_state=2)
57
58      # 训练模型并评估
59      model = RandomForestRegressor(n_estimators=100,
    random_state=42)
60
61      try:
62          model.fit(X_train, y_train)
63          y_pred = model.predict(X_test)
64          rmse = mean_squared_error(y_test, y_pred, squared=
    False)
65          results[combo_name] = rmse
66      except ValueError as e:
67          print(f"Error with combination {combo_name}: {e}")
68          results[combo_name] = np.nan
69
70  # 可视化结果
71  plt.figure(figsize=(14, 8))
72
73  # 计算颜色渐变
74  cmap = plt.get_cmap("Blues")
75  normed_rmse = (np.array(list(results.values())) - np.nanmin(
    list(results.values()))) / (np.nanmax(list(results.values()
    )) - np.nanmin(list(results.values())))
76  colors = [cmap(value) for value in normed_rmse]
77
78  # 绘制柱状图
79  bars = plt.barh(list(results.keys()), list(results.values()),
    color=colors, edgecolor='black')
```

```
80
81  # 添加数值标签
82  for bar in bars:
83      plt.text(bar.get_width(), bar.get_y() + bar.get_height()
    /2,
84               f'{bar.get_width():.2f}',
85               va='center', ha='left', fontsize=10)
86
87  plt.xlabel('RF Sub-Tree Model RMSE Evaluation Value', fontsize
    =14)
88  plt.title('New York Feature Combination Impact on GDP (NY)',
    fontsize=16)
89  plt.grid(axis='x', linestyle='--', alpha=0.7)
90  plt.tight_layout()
91  plt.savefig("NY_importance_Pair_plot")
92  plt.show()
```

纽约湾区统计 __ 组合重要性热力图 __.py

```
1   import pandas as pd
2   import numpy as np
3   import matplotlib.pyplot as plt
4   import seaborn as sns
5   from sklearn.model_selection import train_test_split
6   from sklearn.ensemble import RandomForestRegressor
7   from sklearn.metrics import mean_squared_error
8
9   # 将序列数据转为dict
10  data = {
11      'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
12      'GDP': [178195.395, 186914.7499, 194554.4198, 192099.3274,
      208761.0985, 224303.7472, 238040.4077],
13      'GDP Growth Rate': [3.2129, 4.8931, 4.0872, -1.2619,
    8.6735, 7.4451, 6.1241],
14      'Total Population': [320.5732, 320.10389, 319.20411,
    329.54688, 327.27392, 325.42723, 324.79233],
```

```
    'Import & Export': [27580.32, 30215.2, 29098.24, 28976.52, 34869.2, 38449.2, 32434.8],
    'Higher Edu Enroll': [187.7128, 186.2156, 184.248, 176.386, 171.3124, 168.4206, 169.2476],
    'Research Institutions': [31171, 46757, 70134, 80874, 94619, 110678, 129724],
    'Technology Fundings': [1881.992, 2016.485, 2192.136, 2461.808, 2776.54, 2919.31, np.nan],
    '1st Industry Value': [905866.1, 13940538.2, 13770004.8, 10199432.2, 11020702.4, 13273225.6, np.nan],
    '2nd Industry Value': [13984020, 13984020, 14271887.7, 4920639, 10386978.9, 17168890.6, np.nan],
    '3rd Industry Value': [223211414.3, 237599860.3, 249919458.1, 174760351.1, 213917275.5, 275926305.6, np.nan]
}

# 创建df
df = pd.DataFrame(data)
df.fillna(df.mean(), inplace=True)

# 定义特征和目标变量
X = df.drop(columns=['GDP', 'Year'])  # 特征集合
y = df['GDP']  # 目标变量

# 组合特征
feature_combinations = [('Higher Edu Enroll', 'Total Population'),
                        ('Import & Export', 'Higher Edu Enroll'),
                        ('Research Institutions', 'Technology Fundings'),
                        ('2nd Industry Value', 'Import & Export'),
                        ('Import & Export', 'Total Population'),
```

```
                        ('Higher Edu Enroll', 'Technology Fundings'),
                        ('Total Population', '3rd Industry Value'),
                        ('Total Population', '2nd Industry Value'),
                        ('Higher Edu Enroll', 'Research Institutions'),
                        ('3rd Industry Value', 'Import & Export')
                        ]

# 评估每个组合特征
importance_matrix = pd.DataFrame(np.zeros((len(X.columns), len(X.columns))), columns=X.columns, index=X.columns)

for combo in feature_combinations:
    # 创建新特征
    combo_name = f"{combo[0]} * {combo[1]}"
    df[combo_name] = df[combo[0]] * df[combo[1]]

    # 定义特征集合
    X_combined = df[list(combo) + [combo_name]]

    # 拆分数据集
    X_train, X_test, y_train, y_test = train_test_split(X_combined, y, test_size=0.3, random_state=2)

    # 训练模型并评估
    model = RandomForestRegressor(n_estimators=100, random_state=42)

    try:
        model.fit(X_train, y_train)
        y_pred = model.predict(X_test)
```

```
        rmse = mean_squared_error(y_test, y_pred, squared=False)

        # 将RMSE值赋值给矩阵
        for feature1 in combo:
            for feature2 in combo:
                importance_matrix.loc[feature1, feature2] += rmse

    except ValueError as e:
        print(f"Error with combination {combo}: {e}")

# 将重要性矩阵标准化
importance_matrix = importance_matrix / len(feature_combinations)

# 绘制蓝色渐变的热力图
plt.figure(figsize=(12, 8))
sns.heatmap(importance_matrix, annot=True, cmap="Blues", fmt='.2f', linewidths=0.5)

# 旋转x轴的标签
plt.xticks(rotation=20, ha='right', fontsize=10)

# 旋转y轴的标签
plt.yticks(rotation=0, fontsize=10)

# 添加标题
plt.title('New York Feature Importance of Each Combination (NY Matrix View)', fontsize=16)

# 显示图形
plt.tight_layout()
plt.savefig("NY_importance_HeatMap_plot.png")
plt.show()
```

纽约湾区统计 __PCA 单项重要性 __.py

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
from matplotlib.colors import LinearSegmentedColormap

# 将序列数据转为dict
data = {
    'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
    'GDP': [178195.395, 186914.7499, 194554.4198, 192099.3274, 208761.0985, 224303.7472, 238040.4077],
    'GDP Growth Rate': [3.2129, 4.8931, 4.0872, -1.2619, 8.6735, 7.4451, 6.1241],
    'Total Population': [320.5732, 320.10389, 319.20411, 329.54688, 327.27392, 325.42723, 324.79233],
    'Import & Export': [27580.32, 30215.2, 29098.24, 28976.52, 34869.2, 38449.2, 32434.8],
    'Higher Edu Enroll': [187.7128, 186.2156, 184.248, 176.386, 171.3124, 168.4206, 169.2476],
    'Research Institutions': [31171, 46757, 70134, 80874, 94619, 110678, 129724],
    'Technology Fundings': [1881.992, 2016.485, 2192.136, 2461.808, 2776.54, 2919.31, np.nan],
    '1st Industry Value': [905866.1, 13940538.2, 13770004.8, 10199432.2, 11020702.4, 13273225.6, np.nan],
    '2nd Industry Value': [13984020, 13984020, 14271887.7, 4920639, 10386978.9, 17168890.6, np.nan],
    '3rd Industry Value': [223211414.3, 237599860.3, 249919458.1, 174760351.1, 213917275.5, 275926305.6, np.nan]
}

# 创建df
df = pd.DataFrame(data)
```

```
df.fillna(df.mean(), inplace=True)

# 2. 定义特征目标变量
X = df.drop(columns=['GDP', 'Year', 'GDP Growth Rate'])  # 特征集合
y = df['GDP']  # 目标变量

# 标准化
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# PCA分析
pca = PCA(n_components=min(len(X.columns), len(X)))  # 最小值
pca.fit(X_scaled)

# 计算每个特征对主成分的贡献
explained_variance = pca.explained_variance_ratio_

# 可视化特征重要性
plt.figure(figsize=(11, 7))
plt.title("Feature Importance based on PCA (By Years)")

# 渐变色的颜色映射
cmap = LinearSegmentedColormap.from_list("gradient", ['#f7fbff', '#2171b5'], N=len(explained_variance))

# 绘制柱状图
bars = plt.bar(range(len(explained_variance)), explained_variance, align="center",
               color=cmap(explained_variance / max(explained_variance)), edgecolor='black')

for bar, value in zip(bars, explained_variance):
    yval = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, yval, f"{value
```

```
    :.4f}", ha='center', va='bottom')

# 图例
for i, bar in enumerate(bars):
    plt.plot([], [], color=cmap(explained_variance[i] / max(explained_variance)),
             label=f"{X.columns[i]}: {explained_variance[i]:.4f}")

plt.legend(title="Feature Contribution", loc='upper right', fontsize='large', framealpha=0.9)

plt.xticks(range(len(X.columns)), X.columns, rotation=20, ha='right')
plt.xlim([-1, len(X.columns)])
plt.ylabel('Explained Variance Ratio')
plt.xlabel('Features')

# 保存图形
plt.savefig("importance_PCA_plot.png", bbox_inches='tight')
plt.show()
```

纽约湾区统计 __RF 单项重要性 __.py

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import train_test_split
from matplotlib.colors import LinearSegmentedColormap

# 将序列数据转为dict
data = {
    'Year': [2017, 2018, 2019, 2020, 2021, 2022, 2023],
    'GDP': [178195.395, 186914.7499, 194554.4198, 192099.3274, 208761.0985, 224303.7472, 238040.4077],
```

```
    'GDP Growth Rate': [3.2129, 4.8931, 4.0872, -1.2619, 8.6735, 7.4451, 6.1241],
    'Total Population': [320.5732, 320.10389, 319.20411, 329.54688, 327.27392, 325.42723, 324.79233],
    'Import & Export': [27580.32, 30215.2, 29098.24, 28976.52, 34869.2, 38449.2, 32434.8],
    'Higher Edu Enroll': [187.7128, 186.2156, 184.248, 176.386, 171.3124, 168.4206, 169.2476],
    'Research Institutions': [31171, 46757, 70134, 80874, 94619, 110678, 129724],
    'Technology Fundings': [1881.992, 2016.485, 2192.136, 2461.808, 2776.54, 2919.31, np.nan],
    '1st Industry Value': [905866.1, 13940538.2, 13770004.8, 10199432.2, 11020702.4, 13273225.6, np.nan],
    '2nd Industry Value': [13984020, 13984020, 14271887.7, 4920639, 10386978.9, 17168890.6, np.nan],
    '3rd Industry Value': [223211414.3, 237599860.3, 249919458.1, 174760351.1, 213917275.5, 275926305.6, np.nan]
}

# 创建df
df = pd.DataFrame(data)
df.fillna(df.mean(), inplace=True)

# 定义特征和目标变量
X = df.drop(columns=['GDP', 'Year'])  # 特征集合
y = df['GDP']  # 目标变量

# 拆分数据集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=38)

# 训练RF模型
model = RandomForestRegressor(n_estimators=100, random_state=42)
```

```
model.fit(X_train, y_train)

# 提取特征重要性
importances = model.feature_importances_
indices = np.argsort(importances)[::-1]

# 可视化特征重要性
plt.figure(figsize=(13, 9))
plt.title("New York Feature Importance")

# 渐变色的颜色映射
cmap = LinearSegmentedColormap.from_list("gradient", ['#f7fbff', '#2171b5'], N=len(importances))

# 绘制柱状图
bars = plt.bar(range(X.shape[1]), importances[indices], align="center",
               color=cmap(importances[indices] / max(importances)), edgecolor='black')

for bar, value in zip(bars, importances[indices]):
    plt.text(bar.get_x() + bar.get_width()/2, bar.get_height(), f"{value:.4f}",
             ha='center', va='bottom')

# 图例
for i, bar in enumerate(bars):
    plt.plot([], [], color=cmap(importances[indices[i]] / max(importances)),
             label=f"{X.columns[indices[i]]}: {importances[indices[i]]:.4f}")

plt.legend(title="New York Feature Contribution", loc='upper right', fontsize='large', framealpha=0.9)

```

```
# 设置 x 轴标签
plt.xticks(range(X.shape[1]), np.array(X.columns)[indices],
   rotation=20)
plt.xlim([-1, X.shape[1]])
plt.ylabel('Importance Score')
plt.xlabel('Features')

# 保存图形
plt.savefig("NY_importance_RF_plot.png", bbox_inches='tight')
plt.show()
```